

追踪热议：关于大黄蜂报道的综合研究

摘要

随着贸易和旅游业的迅速发展，入侵物种已成为一个全球性问题。本文旨在帮助政府充分利用公众报告，合理调配有限资源，对雀蜂展开调查。

对于问题（a），为了预测雀蜂的扩散情况，我们构建了一个组合预测模型。从空间角度，我们采用因子分析进行变量选择（见表 4.1），以衡量特定区域的环境适宜性。从时间角度，我们对不同月份的三种目击情况（确认、未验证、未处理）进行 K 均值聚类。应用高斯混合模型（GMM）来计算不同月份雀蜂的似然分布。这两个模型的结合说明了雀蜂的扩散趋势。结果显示， V_s 在整个期间均小于 0.1，表明我们的模型具有较高的精度。

对于问题（b），我们旨在预测错误分类的可能性。首先，我们构建了一个用于图像识别的卷积神经网络（CNN），然后使用改进的 tf-idf 模型进行文本挖掘。最后，我们将两者结合以获得更好的估计结果。卷积神经网络的预测效果非常好，而文本挖掘可以告诉我们相对可能性。将这两种方法结合后，AUC（一种准确性度量指标）提高了 1.08%。

对于问题（c），为了优先调查阳性报告，我们结合问题（a）和问题（b）中的两个模型，建立了一个基于正则化逻辑回归的综合模型。该模型能够做出更全面的判断，准确率超过 99%。

对于问题（d），为了用新报告更新我们的模型，引入了伪标签来利用未使用的（新）数据。与不使用伪标签的结果相比，AUC 提高到了 0.96，提升了 2.13%。在适当的更新频率方面，我们采用主观评估方法，基于五个因素对每个区域进行评分。最后，我们根据特定区域的客观条件计算其报告频率，发现 7 月和 8 月的报告数量最多（每月 5.2 次）。

对于问题（e），为确定华盛顿州的根除证据，我们使用带有纵向数据的回归模型来修改问题（a）中的模型。改进后的模型的优势在于其能够预测在人类干预下物种数量的变化。我们选取 20 个地区的本地蜜蜂和雀蜂数量作为样本。种群曲线两个极值点之间的状态表明了根除证据。

最后，我们分析了我们模型的优缺点及其敏感性，结果表明我们的模型具有较高的鲁棒性、精确性和准确性。之后，附上了一份备忘录。

关键词：环境适宜性；K 均值聚类；卷积神经网络；文本挖掘；伪标签；纵向数据回归模型

目录

1 引言	2
1.2 问题重述	
1.3 问题分析	2
2 假设与理由	3
3 符号说明	3
4 分析与建模	4
4.1.2 模型 1: 因子分析法	4
4.1.3 模型 2: K 均值聚类算法与高斯混合模型	6
4.1.4 组合预测模型	8
4.2 错误分类预测	9
4.2.1 模型 3: 基于 CNN 的图像识别	9
4.2.2 模型 4: 词语和句子层面的文本挖掘	10
4.2.3 图像识别与文本挖掘的结合	13
4.3 确定阳性报告的可能性	14
4.4 模型更新	15
4.4.1 模型 3*: 带伪标签的改进 CNN	15
4.4.2 主观评价方法	16
4.5 华盛顿州根除证据	18
4.5.1 纵向数据回归模型	18
5 敏感性分析	20
5.1 问题 (c) 中模型的敏感性	20
5.2 问题 (c) 中模型的敏感性	21
6 模型评估	21

1 引言

1.1 背景

如今, 生物入侵是农业、粮食生产和生物多样性领域的全球关注问题。入侵物种会对新定植的区域产生不利影响, 例如导致当地物种群落减少, 以及提供植食性昆虫控制和授粉服务的关键昆虫数量下降 [1]。

最近在加拿大和美国发现了亚洲大虎头蜂 (*Vespa mandarinia*), 这引发了人们对其可能成为入侵物种的担忧。在美国昆虫学会确定亚洲大虎头蜂的官方通用名称之前, 建议我们使用“麻雀蜂” [2]。麻雀蜂倾向于在低山山麓、低地森林或城市景观中的绿地筑巢 [3]。麻雀蜂是美国的检疫性害虫, 因为它会给养蜂人造成重大损失 [4]。因此, 应格外注意预测这些大黄蜂随时间的迁徙情况, 并识别人工报告, 以便更有效地调配政府资源来调查这一问题。

1.2 问题重述

(a) 开发一个模型来预测麻雀蜂随时间的扩散情况, 并分析该模型的精确程度。

(b) 考虑到相似物种, 研究如何仅使用提供的数据集文件以及 (可能的) 图像文件来预测错误分类的可能性。

(c) 设定一个目标, 优先调查那些最有可能是阳性目击的报告, 并讨论进行分类分析的方法。

(d) 说明如何利用随时间推移获得的额外新报告来更新先前的模型, 并确定新报告的最佳频率。

(e) 基于该模型, 找出哪些情况可构成华盛顿州害虫已被根除的证据。

1.3 问题分析

对于问题 (a), 我们计划从空间和时间两个角度预测雀蜂的扩散情况。首先, 蜂类的扩散可能会受到许多自然因素的限制, 因此我们考虑使用因子分析来计算环境适宜性, 因为这种方法适用于数据不可得或质量较低的情况 [5]; 其次, 扩散可能会受到季节性和周期性因素的影响, 因此我们可以尝试使用聚类方法来确定不同时期蜂类的聚集情况。

对于问题 (b), 我们可以利用的数据是记者们的图像和笔记。我们应该通过统计方法充分利用这些数据。

对于问题 (c), 为了确定如何估计报告为阳性的可能性并优先对其进行调查, 我们决定综合考虑上述涉及的所有信息方面, 并基于在问题 (a) 和问题 (b) 中应用的模型建立一个新的评估模型。

对于问题 (d), 当有更多未标记数据可用时, 伪标签是提高模型准确性的好方法 [6]; 因此, 我们希望使用它来更新我们的模型。基于

关于新增的报告。由于模型更新的频率与报告提交的频率密切相关，我们需要确定在特定时间段内合适的报告数量。

对于问题（e），为了确定控制措施是否已经根除害虫，我们可以使用带有纵向数据的回归模型，通过考虑人为干预下害虫种群的变化来修正传播模型。利用采取控制措施后的种群变化数据，我们可以确定害虫被根除的时间点和证据。

2 假设与理由

为简化我们的问题，我们做出以下基本假设，每一条假设都有充分的理由。

（a）每个月，雀蜂的聚类中心数量与其活动水平呈正相关，在 7 月和 8 月达到峰值。

（b）雀蜂的活动期为每年 4 月至 10 月。在其他时间，雀蜂处于冬眠状态。公众在这些非活动期发现雀蜂的情况可视为不可靠信息，予以忽略。

（c）雀蜂的种族影响随距离呈正态分布。

（d）同一地区的环境适宜性通常每年都保持一致。

3 符号说明

Symbol	Description
$N(x, u_i, d_i)$	The probability density function of the i-th Gaussian model
$P(x)$	The likelihood of sparrow hornets appearing in the position x
π_i	weight of the i-th Gaussian model
β	Weight of Model 2
V_s	coefficient of variation
c	Term frequency
$P(Neg)$	Likelihood of negative things
$P(Pos)$	Likelihood of positive things
P	The actual number of positive reports
N	The actual number of negative reports
θ	Regression parameters
λ	regularization coefficient
b_k	Fixed effect factor
η_{ki}	Random effect factor

4 分析与建模

4.1 雀蜂随时间的扩散

分析提供的数据集后，我们可以确定雀蜂的传播是可预测的。

理解生物因素（物种生态学、捕食和种间竞争）和非生物因素（人为作用、气候变化、地理障碍）的作用已成为生态学和生物地理学中的主要挑战。然而，在这个问题中，我们依赖非生物变量，因为对其他生物因素（如物种进化、捕食者和竞争者）知之甚少，这些因素可能会影响麻雀蜂的分布位置 [7]。




图 4 1. 建立组合预测模型的步骤

4.1.1 数据预处理

我们首先剔除了日期格式不正确的事件，不过这类事件的数量很少。我们筛选掉了 2019 年 9 月之前的数据。这是因为 2019 年 9 月在温哥华岛首次发现了雀蜂，2019 年 12 月在华盛顿州也发现了雀蜂。因此，2019 年 9 月之前的任何报告肯定都是阴性的；对于每一年，我们选取 4 月至 10 月的数据。根据参考文献 [8]，雀蜂在这个时间段之外会进入冬眠。所以 4 月至 10 月的报告更具意义和价值。

4.1.2 模型 1：因子分析法

因子分析的基本思想是根据相关性对变量进行分组，使同一组内的变量相关性较高，而不同组间的变量相关性较低。每一组变量代表一种基本结构，这被称为公共因子。因此，可以用未测量的公共因子和特殊因子的线性函数来描述原始观测的每个成分。

因子分析可以用以下模型表示：

$$\begin{cases} x_1 = a_{11}F_1 + a_{12}F_2 + \cdots + a_{1m}F_m \\ x_2 = a_{21}F_1 + a_{22}F_2 + \cdots + a_{2m}F_m \\ \vdots \\ x_p = a_{p1}F_1 + a_{p2}F_2 + \cdots + a_{pm}F_m \end{cases} \quad (m < p)$$

其中， $x_1, x_2, \dots, x_p$ 表示 p 个标准化变量，其均值为 0，标准差为 1； $F_1, F_2, \dots, F_m$ 指的是 m 个因子变量。此外，该模型可以转化为矩阵形式。

$$X = AF + \epsilon$$

其中， F 是公因子； A 是因子载荷矩阵，表示第 i 个原始变量在第 j 个因子变量上的载荷； a_{ji} 是 x_i 在坐标轴 F_j 上的投影（若将变量 x_i 视为 m 维因子空间中的一个向量）； ε 是特殊因子，表示原始变量中无法被因子变量解释的部分（可视为多元回归模型中的残差）。

模型 1 的结果

环境适宜性被定义为在某个地点的环境状态下，一个物种出现的条件概率 [9]。许多非生物驱动因素决定了麻雀蜂群落的分布。例如，麻雀蜂的数量与城市景观中的绿地呈正相关 [3]。另一方面，麻雀蜂被描述为对高温和极端气候条件高度敏感的物种，且与高温呈负相关 [10]。因此，在进行因子分析时，我们会考虑尽可能多的有记录或相关的影响变量，以便充分评估美国西北部的环境适宜性。最终，筛选出了 16 个能够解释麻雀蜂当前分布的变量。

表 4.1: 分析中使用的变量

Classification	Factor	Abbreviation
Climate	Annual mean temperature ($^{\circ}\text{C}$)	T_m
	...	
	Annual mean radiation (MJ/m^2)	R_m
Habitat structure	Forest stands (%)	H_for
	...	
	Scrubland (%)	H_scr
Vegetation productivity	Normalised difference vegetation index	HDVI
Hydrography	Average distance to rivers (m)	Dist_riv
Topography	Elevation (m)	Elv
Human activity	Average population	D_pop

最后，所有变量的值都被转换为 z 分数。

从方差累积百分比可以看出，前四个主成分已经解释了近 87.9% 的总方差，因此可以选择这些主成分进行分析。右侧的碎石图显示，前四个主成分的折线斜率较陡，而之后则逐渐平缓，这进一步证明选择前四个主成分是合适的。

数据来源：气候变量来自 Weather Atlas (<https://www.weather-us.com>)。美国海拔与距离网站 (<https://pubs.usgs.gov/gip/Elevations-Distances/elvadist.html>) 用于收集地形数据。植被生产力和水文数据可从<http://glovis.usgs.gov/>获取。人口等人为驱动因素来自美国人口普查局 (<https://www.census.gov/>)。




图 4.2: 总方差解释结果与碎石图

接下来, 我们应用公式 $V = Z \times t$, 其中 Z 是归一化矩阵, t 是归一化正交特征向量矩阵, 以获得四个主成分的值。基于图 4.2 中用于加权的方差百分比, 我们可以计算 14260 个选定地点的总分和环境适宜性。

$$V_{4 \times 14260} = 0.50196V_1 + 0.18929V_2 + 0.11459V_3 + 0.07326V_4$$

$$ES = 500 + 100V_{4 \times 14260}$$

从下面的两个图表中可以看出, 美国和加拿大的西海岸是大黄蜂生存的理想之地。第二个高峰出现在罗萨里奥海峡东海岸的北喀斯喀特国家公园及其周边地区。内陆的库特尼国家森林公园是大黄蜂的第三理想栖息地 —— 尽管其适宜性不如沿海地区, 但环境适宜度基本维持在 300 左右。通过对比可以发现, 高分区域都具有一些共同的显著特征, 例如高森林覆盖率、高归一化植被指数 (NDVI)、靠近水源、人类活动较少等。这些发现与相关研究资料 [3][10] 中记录的麻雀蜂习性相符, 因此我们认为通过因子分析计算出的环境适宜度在一定程度上是具有说服力的。




图 4.3: 环境适宜性的二维地图



图 4.4: 环境适宜性等高线图

4.1.3 模型 2: K 均值聚类算法和高斯混合模型

在模型 2 中, 考虑到雀蜂是群居生活且分布在蜂后周围, 我们首先想到应用 K-means 聚类算法来寻找雀蜂的聚类中心。在应用 K-means 聚类算法寻找聚类中心时, 为了提高数据的可靠性, 我们直接删除了被判定为 “Negative ID” 的数据, 只使用剩余部分。

根据参考文献 [8], 雀蜂的生长可分为六个阶段, 并且

我们将月份进行对应，以确定每个月的聚类中心数量。我们在雀蜂活跃的月份预设了更多的聚类中心。具体设置已在下图中显示。




图 4.5: 聚类中心数量按月变化情况

由于 K-means 算法的初始点选择是随机的，该算法可能会陷入局部最优解而非全局最优解。为避免这种情况，我们进行了多次计算，并将输出结果相对较好的情况作为全局最优解。基于处理后的数据，我们最终使用 K-means 聚类算法找到了每个月的聚类中心位置，并计算了每个事件的类别。结果如图 4.6 所示。

在获取每个聚类中心的位置以及每个月的族群数量后，我们开始应用高斯混合模型来计算特定地理区域内各地麻雀蜂的似然分布。

让我们简要介绍一下高斯混合模型。高斯混合模型利用高斯概率密度函数（正态分布曲线）对事物进行精确量化。它是一种基于高斯概率密度函数（正态分布曲线）的模型，可将事物分解为若干部分。




图 4.6: 聚类中心的分布

混合高斯模型由 K 个高斯模型组成（即数据包含 K 个聚类中心）。GMM 的概率密度函数如下：

$$p(x) = \sum_{i=1}^K p(i) p(x|i) = \sum_{i=1}^K \pi_i N(x, u_i, d_i)$$

其中 x 表示样本的位置, $p(x|i)$ 表示麻雀蜂出现在位置 x 的可能性, $p(x|i) = \mathcal{N}(x; \mu_i, \sigma_i^2)$ 表示第 i 个高斯模型的概率密度函数, μ_i 、 σ_i 、 π_i 分别表示第 i 个高斯模型的均值、标准差和权重。

π_i 与族群成员数量成正比, 并且

$\sum_{i=1}^K \pi_i = 1$ 。族群成员数量越多, 影响力就越大, 这 1 点是非常合理的。

在我们的模型中, 特定地理区域内各个地方出现雀蜂的概率会受到该区域内多个聚类中心的影响。这种影响随距离变化的曲线是正态分布的概率密度曲线。


模型 2 的结果 我们计算了每个月在特定地理区域内各处出现雀蜂的可能性, 并将其重新调整到 0 到 1 之间, 最后在图 7 (a) 中绘制了等高线图。

4.1.4 组合预测模型


模型 1 根据该地区的自然条件计算环境适宜性, 并将其缩放至 0 到 1 之间, 以获得雀蜂的可能性分布。模型 2 基于现有的雀蜂分布数据, 预测不同月份雀蜂的可能性分布。然后, 我们以 $1:\beta$ 的比例结合这两个模型的结果。在本部分中, 我们设定 $\beta = 1$ 。此外, 我们将在敏感性分析中研究如何选择其值。最后, 我们得到了近年来不同月份雀蜂的可能性分布, 如图 7 (b) 所示。

由于 K-means 聚类算法每次运行的结果不一定一致, 但较为相似, 这导致我们最终模型得到的结果会在特定范围内波动。因此, 我们需要计算模型预测的精确度。我们对精确度的定义是综合预测模型的预测结果中的误差程度, 它与误差大小相对应。因此, 我们使用变异系数 V_s 来反映精确度水平。变异系数 V_s 越小, 预测结果的变异范围就越小, 意味着精确度水平越高。变异系数的计算如下, 其中 σ 和 $\bar{X}$ 分别代表数据 X 的标准差和平均值

$$V_s = \frac{\sigma}{\bar{X}} \quad (4.1.1)$$



(a) 模型 2 的结果



(b) 问题 (a) 中组合模型的结果

图 4.7: 不同月份雀蜂的 likelihood 分布

我们按月计算了预测输出的变异系数。从图 4.8 中,

我们可以确保我们的模型精度足够高，能够估计该可能性。




图 4 8. 按月份统计的 γ 输出

4.2 错误分类预测

检查给定的电子表格后，我们发现大多数报告的目击事件都被认定为误报。因此，在本部分中，我们将建立一个模型来帮助预测误分类的可能性。

注意：在下文当中，我们可能会将报告、图表、注释甚至词语等称为“阳性”或“阴性”。这表示其对应的“实验室状态”为阳性或阴性。

4.2.1 模型 3：基于卷积神经网络的图像识别

数据预处理 虽然在上一部分对给定的数据进行了清洗，但数据分布仍然存在严重的不平衡问题，即有 2028 份负面报告，而正面报告仅有 14 份。这对接下来学习蜜蜂的特征是不利的。我们提出了两种解决方法。一方面，我们增加了正面样本的数量。具体来说，

- 我们将阳性图像进行垂直和水平翻转，使其数量增加两倍；
- 我们从可靠的网站上下载了一些图片。

另一方面，我们减少了负样本的数量。具体来说，我们随机选取了一些负样本，使其数量与正样本相等。

经过预处理，现在有 258 个正样本和 258 个负样本。我们将它们均匀混合，并按照 7:3 的比例分为训练集和测试集。

关于目标，我们将正向目标和负向目标分别标记为 1 和 0，以表示正向目标的可能性。最终，有 411 个训练样本及目标，177 个测试样本及目标。

卷积神经网络 卷积神经网络（CNN）在深度学习历史上发挥了重要作用，尤其是在目标识别方面。例如，它们

实际上，我们曾经尝试过使用所有这些数据来训练我们的模型。结果发现，无论真实目标是什么，该模型都倾向于将所有样本预测为阳性。

预处理中还包含了裁剪缩放和归一化操作。由于它们对正样本数量的增加没有贡献，因此在正文中没有提及。

数据来源：亚洲巨型大黄蜂 (https://en.wikipedia.org/wiki/Asian_giant_hornet)、了解亚洲巨型大黄蜂，即“杀人大黄蜂” (<https://agrillifetoday.tamu.edu/2020/05/11/get-to-know-the-asian-giant-hornet-or-murder-hornet/>)

它们被用于赢得许多竞赛, 包括 ImageNet 目标识别挑战赛 [11]。因此, 我们在这里构建了一个卷积神经网络 (CNN) 用于初步预测。




图 4.9: 我们的 CNN 架构 图 4.10: CNN 预测的 ROC 曲线

我们使用 PyTorch 构建了卷积神经网络 (CNN)。该网络的架构如图 4.9 所示 (使用 *TikZ* 绘制)。网络包含两个卷积层、两个池化层和两个全连接层。输入的形状为 $(b \times 3 \times 96 \times 96)$, 其中 b 表示批处理大小, 3 表示通道数, 96×96 表示高度和宽度。输出的形状为 (b) 。训练进行 200 个 epoch。

测试准确率在第 93 个 epoch 达到 0.8968 的峰值。该 epoch 下的模型被保存为最终预测器。我们在图 4.4.10 中绘制了 ROC 曲线。横轴和纵轴分别是假阳性率 (FPR) 和真阳性率 (TPR)。AUC 表示 ROC 曲线下面积。AUC 越接近 1 的模型, 其预测性能越好。目前我们模型的 AUC 为 0.93。仅使用 411 个训练样本, 这个结果是相当可接受的。

4.2.2 模型 4: 词语和句子层面的文本挖掘

所提供的数据集还包含记者附上的一些注释, 这些注释不容忽视。我们刚刚基于图像对 $P(Pos)$ 和 $P(Neg)$ 进行了预测建模, 而这些注释也被认为对我们的预测有帮助。

改进的 tf-idf 模型介绍 在信息检索中, tf-idf 是词频 - 逆文档频率的缩写, 它是一种旨在反映一个词对集合或语料库中某一文档的重要性的数值统计 [12]。从字面上看, 这种模型由两部分组成。

词频, 即 c_m , 是术语 w 在文档中出现的次数, 而逆文档频率是衡量一个词所提供信息量的指标, 即该词在所有文档中是常见的还是罕见的。在大多数情况下, 具有较高 c_m 的术语往往对文档的贡献更大。然而, 像 “the” 或 $I'm$ 这样的停用词几乎不能给我们提供任何信息。

这启发我们根据每个词的 c_m 来估计其 “积极” 可能性, 即 $P_{pos}(Pos)$ 。这里的不同之处在于 “实验室状态”。例如, 一个 “消极” 的词会对注释产生相反的影响。因此, 我们结合实验室状态, 根据其 c_m 提出了一种改进的 tf-idf 模型。

没有上限。因此, 我们将其除以它出现的总次数, 即 $\sum_i c_i(w)$ 。我们将此值定义为 $P_{in}(Pos)$ 。

显然, $P_{in}(Pos)$ 介于 0 和 1 之间。

$$P_{in}(Pos) \stackrel{def}{=} \frac{\sum_i c_i(w) \times P_i(Pos)}{\sum_i c_i(w)}, i \in \{pos, neg, uv, up\} \quad (4.2.3)$$

如果我们将公式 4.2.3 重写为

$$P_{in}(Pos) = \sum_i P_i(Pos) \times \frac{c_i(w)}{\sum_i c_i(w)}, i \in \{pos, neg, uv, up\} \quad (4.2.4)$$

da $P_{in}(Pos)$ 是 $P_i(Pos)$ 的加权平均值, 其权重等于 $\frac{c_i(w)}{\sum_i c_i(w)}$

笔记的建模

笔记由若干词语组成。因此, 某个笔记 (即 $P_n(Pos)$) 的正似然值也是 $P_{in}(Pos)$ 的组合。研究发现, 像 “曼森” 和 “事件” 这样的一些词语只出现一次, 这使得它们在正似然值方面的可靠性低得多。从这个意义上说, 它们对 $P_n(Pos)$ 的贡献应该更小。这意味着 $P_n(Pos)$ 与词语的词频呈正相关, 即 c_w 。基于上述内容, 我们将 $P_n(Pos)$ 定义为

$$P_n(Pos) \stackrel{def}{=} \begin{cases} \frac{\sum_{w \in S_n} \ln c_w \times P_w(Pos)}{\sum_{w \in S_n} \ln c_w}, & S_n \neq \emptyset; \\ \frac{P}{P+N}, & S_n = \emptyset. \end{cases}$$

, 其中 S_n 是笔记 n 中所有词语的集合。如最后一部分所述, 数据分布显示阴性和阳性之间存在严重的不平衡。因此, 如果笔记非空, 我们将对 c_w 取对数以缩小差距。然而, 也存在一些没有笔记的报告。在这种情况下, 我们选择数学期望作为它们的值。

根据这个定义, 让我们重新计算每个音符的阳性似然。音符按 “实验室状态” (标记为 G1、G2、G3、G4) 分组。每组的 $P_n(Pos)$ 分布如图 4.12 所示。副标题代表 $P_n(Pos)$ 的平均值。




图 4.12: 四组 $P_n(Pos)$ 的分布直方图

总体而言, G1 的平均 $P_n(Pos)$ 最大, G2 的平均 $P_n(Pos)$ 最小, 这与实际情况相符。但 G1 的 $P_n(Pos)$ 的最大值小于 0.5, 这是正常的。

因为许多出现在正面笔记中的词汇也会出现在负面笔记中。此外, $\frac{1}{N}$ 的计算值为 0.262045。由此可见, 当 $P_n(Pos) \approx 0.26$ 时, G2 和 G3 都出现了峰值, 这可以归因于它们的“空白”笔记。

为了检验对数的效果, 我们比较了 G1 的 $P_n(Pos)$ 在考虑对数和不考虑对数情况下的分布。对于非空注释, 后者对应的公式为

$$P'_n(Pos) \stackrel{def}{=} \begin{cases} \frac{\sum_{w \in S_n} c_w \times P_w(Pos)}{\sum_{w \in S_n} c_w} & , S_n \neq \emptyset ; \\ \frac{P}{P+N} & , S_n = \emptyset . \end{cases}$$

Σ

图 4.13 告诉我们, G1 的 $P_n(Pos)$ 总体上向 1 靠近, 均值从 0.301 上升到 0.326, 增幅为 8.31%。因此, 定义 4.2.5 被证明比定义 4.2.6 更可靠。




图 4.13. G1 的 $P_n(Pos)$ 分布对比

4.2.3 图像识别与文本挖掘的结合

尽管我们改进后的 tf-idf 模型预测效果不如 CNN, 但相对可能性是准确的。此外, 它从另一个角度对报告进行评估。从这个意义上说, 我们可以结合这两个模型来提高预测的准确性。

我们在图 4.14 中绘制了预测结果的分布。这两个直方图的形状差异显著, 不适合进行线性组合。在这种情况下, 我们转而采用非线性形式对它们进行组合。



图 4.14: 结果分布 图 4.15: 训练数据结果分布的二维可视化

为了体现图像和注释的贡献, 我们引入系数 C_1 和 C_2 作为它们的指数。一般形式如下。

$$\ln \hat{P}(Pos) = \ln m \times \{k \times [P_{im}(Pos)]^{C_1} \times [P_n(Pos)]^{C_2} + b\} \quad (4.2.7)$$

通过拟合训练数据, 系数值为

$$m = 0.6489, k = 0.0956, C_1 = -39.3, C_2 = -4.4, b = -3.806$$

, C_1 几乎是 C_2 的九倍, 这表明结果更多地取决于图像而非文本部分。这也与图 4.15 一致,

在该图中, 只有当 $P_m(Pos)$ 大于 0.9 时, 才会出现实际的正点。

我们计算了测试样本的结果, 并在图 4.16 中展示了其分布。AUC 值提高了 1.08%, 达到 0.94。



图 4.16: 测试数据结果分布的 3D 可视化图 4.17: 问题 (b) 中基于组合模型的 ROC 曲线

4.3 确定阳性报告的可能性

基于上述工作, 我们打算通过正则化逻辑回归整合这两个模型, 以提高预测准确性。

正则化逻辑回归 我们取麻雀蜂出现的可能性

由问题 (a) 和 (b) 中的两个模型获得。作为输入值, 分别标记为 x_1 和 x_2 。

以及 n_{ah} , 而实际可能性是输出值, 标记为 y 。我们选择的数据集涉及提供图片并被判定为正面或负面的事件, 其中正面 ID 对应 1, 负面 ID 对应 0。然后我们将该数据集随机分为训练集和测试集。

训练前, 考虑到输入只有两个特征, 我们需要应用特征映射方法将这两个特征扩展为 28 个特征。

$$mapFeature(n_{ah}) = [1, n_{ah1}, n_{ah2}, n_{ah1}^2, n_{ah1}n_{ah2}, n_{ah2}^2, \dots, n_{ah1}^6, n_{ah2}^6]^T$$

其中 n_{ah} 和 $mapFeature(n_{ah})$ 分别表示二维向量和 28 维向量。

之后, 我们开始在训练集上训练模型。成本函数 $J(\theta)$ 的计算方式如下。

$$h_{\theta}(p_{ah}) = \frac{1}{1 + \exp(-\theta^T p_{ah})}$$

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m [-u^{(i)} \ln(h_{\theta}(p_{ah}^{(i)})) - (1 - u^{(i)}) \ln(1 - h_{\theta}(p_{ah}^{(i)}))] + \frac{\lambda}{2m} \sum_{i=1}^n \theta_i^2$$

其中 θ 表示回归参数， λ 表示正则化系数，我们将其设置为 0.6。当成本函数 $J(\theta)$ 最小时，回归效果最佳，此时该回归模型可视为最终模型。

结果与分析 为了评估我们的模型，我们在测试集上测试了这个新模型的准确率。最终的预测结果与实际情况完全吻合。

分析预测结果后，我们发现尽管该事件中存在两处误判，但总体准确率已达到 0.99，这表明我们的模型是可靠的。因此，我们的模型有助于确定阳性报告的可能性，并优先对其进行调查。




图 4.18: 预测输出的分布

4.4 模型的更新

尽管 4.2.1 节中的卷积神经网络（CNN）具有相对较高的准确率（0.8969），但由于有大量新数据，特别是来自新增的报告，其性能仍有进一步提升的空间。通过伪标签技术，我们现在能够利用那些未被开发的数据。

伪标签是利用带标签数据模型为无标签数据预测标签的过程。它常用于半监督学习中，因为在半监督学习中，大多数数据都是无标签的。如今，该技术被用于高光谱图像分类以及胸部 X 光片上新冠肺炎的识别。[11][12] 基于卷积神经网络（CNN）的图像识别结果，我们将使用伪标签来改进我们的模型。其流程如下流程图所示（图 4.9）。

4.4.1 模型 3*: 带有伪标签的改进型卷积神经网络

伪标签是利用带标签数据模型为无标签数据预测标签的过程。它常用于半监督学习中，因为在半监督学习中，大多数数据都是无标签的。如今，这项技术被用于高光谱图像分类以及胸部 X 光片中新冠肺炎的识别 [13][14]。

基于卷积神经网络（CNN）的图像识别结果，我们将使用伪标签来改进模型。步骤如下流程图所示（图 4.19）。

由于问题（c）明确不允许使用华盛顿州提供的、与电子表格中类似的亚洲大黄蜂补充数据，我们将原本不在训练集中的未标记数据（未经核实和处理）作为“新报告数据”添加到该模型中，这有助于我们测试额外的新报告是否会改进我们的模型。我们认为， $P(Pos)$ 的值离 0.5 越远，其精度就越可靠且有说服力。因此，我们只标记以下两种预测结果之一

大于 0.9 或小于 0.1。为了验证这一点,我们在图 4.21 中可视化了一些未经验证图像的预测结果。




图 4.19: 伪标签的流程



图 4.20: 一只真实的雀蜂

$P(Neg)$ 的第 1 个和第 3 个数值均低于 0.1,这表明它们很可能是阳性观测结果。我们可以将其与图 4.20 中的真实雀蜂进行比较。它们与真实黄蜂外观的三个典型特征非常相似。因此,这样的预测相对可靠,可以标记为(伪)阳性。

经过伪标记后,我们将它们纳入原始标记数据集,并重新训练我们之前得到的卷积神经网络(CNN)。在第 7 个 epoch 时,测试准确率达到了 0.9096 的较高峰值,与之前的 0.8968 相比,提升了 1.43%。




图 4.21: 未验证图像的预测结果

与伪标签之前的结果相比,AUC 值提升了 1.08%,达到 0.96。这一结果表明,通过将新报告作为伪标签添加到训练模型中来改进我们的模型是有效的。

4.4.2 主观评估方法

解决模型更新的适当频率的关键在于确定特定时期内的适当报告数量。因此,我们采用主观评估方法,根据与潜在报告案例出现密切相关的不同因素对每个领域进行评分。我们最终选择了五个关键评估指标进行分析:环境

适用性 (1)、季节性因素 (2)、重大外部事件 (3)、经济发展 (4) 以及报告稳定性 (5)。重要性排名结果如下。

$$I_2 > I_3 > I_1 > I_4 > I_5$$

具体的评分规则如下：每个区域的分数由两部分组成（初始分数和附加分数），其中初始分数取决于该区域的环境适宜性，其他四个因素决定附加分数。该区域的分数每天更新，直至达到阈值（例如 100 分），这意味着此时该区域应提交新的报告。之后，该区域的所有分数将被清零，并重新开始评分。根据我们掌握的数据，我们估计该区域几乎将在 6 天后提交一份报告，这也表明在 100 分的评分标准下，平均每天需要增加 17 分。在分配五个因素的权重后，初始分数 (IS) 的计算公式如下。

$$IS_i = 17 \times Weight3 \times \frac{ES_i}{Median ES}, i = 1, 2, \dots, 63$$

其中， $Weight3$ 表示第三个因素（环境适宜性）的权重，63 指的是华盛顿州的区域总数。

关于附加分的确定，还有一些规则。

(a) 季节因素要求同一地区在不同月份有不同的附加分数。我们将模型 2 中的聚类中心数量 (NCC) 视为附加分数的一个决定因素。其公式如下。

$$AS_{ci} = 17 \times Weight1 \times \frac{NCC_j}{Median NCC}, i = 1, 2, \dots, 12$$

(b) 重大外部事件的影响主要体现在，当该地区出现积极情况时，未来六个月该地区的每日附加分数可设定为初始分数的 125%。（此效果可叠加）

(c) 该地区的经济发展水平越高，报告频率就越高。以下方程可以表达这种关系。

$$AS_{ci} = 17 \times Weight4 \times \frac{GDP_i}{Median GDP}, i = 1, 2, \dots, 63$$

(d) 报告稳定性可能与该地区持续负面报告的持续时间呈正相关。具体而言，假设某一地区有超过六个月的连续负面报告记录。在这种情况下，从第六个月开始到该地区出现正面记录为止，其附加价值为初始价值的 - 50%。

让我们来考虑一个具体的例子。假设有一个圆形区域 A，其半径为 $30km$ 。在这个区域

中，存在 $\frac{GDP_A}{Median GDP} = 1.2$ ，预期环境适宜性为 84（全州中位数为 115）。此外，我们假设现在是五月初。还需要注意的是，四月底该地区报告了一例阳性病例。目前的估计是，在那之后的六个月内，该地区不会再出现新的阳性病例。

通过考虑我们评估模型中的各种因素，我们得出结论：A 地区未来八个月的月度可报告数量会随时间变化，7 月和 8 月最高（每月 5.2），11 月和 12 月最低（每月 1.3）。

4.5 华盛顿州根除证据

根除的定义是将某一物种的所有个体从某个不太可能发生重新定殖的区域清除出去 [15]。美国农业部（USDA）推荐了多种根除雀蜂的方法。例如，我们可以在早期（筑巢前和独居阶段）和晚期（繁殖阶段）使用致命陷阱来杀死蜂后，或者在中期（合作和多职阶段）采取积极措施寻找并清除巢穴 [16]。因此，对根除效果的判断将直接决定不同方法在不同地区的适用程度。

4.5.1 纵向数据回归模型

一些相关文献表明，入侵性大黄蜂尤其成问题，因为它们会对当地蜜蜂群落产生不利影响 [4]。因此，在构建评估根除效果的模型时，我们主要关注两个关键因素——特定区域内当地蜜蜂和雀蜂的种群数量随时间的变化。根据我们的假设，在控制过程中，当地蜜蜂种群数量理论上会先增加后减少。相比之下，入侵性大黄蜂种群数量则呈现相反的趋势，即先减少后增加。鉴于此，我们可以建立密度随时间变化的二次回归模型：

$$w_{ij} = b0_i + b1_it_{ij} + b2_it_{ij}^2 + \epsilon_{ij}, i = 1, ..., n, j = 1, ..., n_i(4.5.1)$$

其中， w_{ij} 表示第 i 个地点第 j 次观测到的当地蜜蜂（或雀蜂）的密度， t_{ij} 指的是 z 号地点第 j 次观测的时间点；n 是入侵物种出现的地点数量， n_i 是整个期间内第 i 个地点的观测次数。

基于上述内容，上述二次回归模型通过混合模型进行重写，以突出该区域的整体密度数据。混合效应模型是一种既包含固定效应又包含随机效应的统计模型 [6]。

$$h_{L,i} = h_L + m_{L,i}.k = 0.1.2(4.5.2)$$

其中， h_L 是整个区域的固定效应因子（与观测点无关），

Area code	A	
Time span	May 20xx-Dec 20xx	
Initialized score (per day)	2.48	
Additional score (per day)	AS_a	May: 5.83; Jun: 7.29; Jul: 8.74; Aug: 8.74; Sep: 7.29; Oct: 5.83; Nov: 0; Dec: 0
	AS_b	May-Oct: 3.10; Nov/Dec: 0
	AS_c	3.06
	AS_d	Nov/Dec: -1.24
Report frequency (per month)	May: 3.5; Jun: 3.9; Jul: 4.4; Aug: 4.4; Sep: 3.9; Oct: 3.5; Nov: 1; Dec: 1	

图 4.22：报告频率评估表




图 4.23：A 区域的报告频率

而 n_{ki} 是随观测点变化的随机效应因子。该随机效应因子假定服从均值为零、方差为 d_k^2 的正态分布, 且相互独立。

将式 4.5.2 代入式 4.5.1, 得到一个具有纵向数据的回归模型。

$$y_{i1} = b_0 + b_1 t_{i1} + b_2 t_{i1}^2 + n_0 + n_1 t_{i1} + n_2 t_{i1}^2 + \varepsilon_{i1} \quad (4.5.3)$$

它可以改写为矩阵形式。

$$Y_i = \begin{bmatrix} y_{i1} \\ y_{i2} \\ \vdots \\ y_{in} \end{bmatrix}, X_i = \begin{bmatrix} 1 & t_{i1} & t_{i1}^2 \\ 1 & t_{i2} & t_{i2}^2 \\ \vdots & \vdots & \vdots \\ 1 & t_{in} & t_{in}^2 \end{bmatrix}, b = \begin{bmatrix} b_0 \\ b_1 \\ b_2 \end{bmatrix}, D = \begin{bmatrix} d_1^2 & 0 & 0 \\ 0 & d_2^2 & 0 \\ 0 & 0 & d_3^2 \end{bmatrix};$$

$$V_i = X_i D X_i^T + \sigma^2 I$$

其中, 假设 Y_i 服从正态分布, 其均值向量为 $X_i b$, 方差矩阵为 V_i 。系数的估计需要应用最大似然估计 (MLE), 而非普通最小二乘法 (OLS), 因为普通最小二乘法无法处理模型非线性的情况。 Y_i 的似然函数如下。

$$\mathcal{L}(b, D, \sigma^2) = \prod_{i=1}^n \left\{ (2\pi)^{-\frac{n_i}{2}} |V_i|^{-\frac{1}{2}} \exp \left[-\frac{1}{2} (Y_i - X_i b)^T V_i^{-1} (Y_i - X_i b) \right] \right\}$$

最后, 通过求解似然函数 L 的最大值点, 可以计算出 b 、 D 和 σ^2 的估计值。

该模型的意义在于, 反映该地区整体效应的固定效应系数 b_k 能够从平均意义上预测根除的时间点。相比之下, 随机效应系数 n_{ki} 包含了不同地点之间的变异性 (例如气候、地形、人口), 从而可以在特定水平下评估根除时间点的置信区间。

结果与分析 为了确定当地蜜蜂的数量, 我们使用了 *USAF* 的国家农业统计局的数据, 该数据报告了蜂蜜收获地每个县的蜂群数量。为了在受控条件下获得关于大黄蜂传播的有效数据, 我们使用纵向数据的回归模型对 4.1 节中提到的传播模型进行了修改。控制过程的时间选择为 4 月 (蜂王首次出现) 至 10 月 (即将进入冬眠)。

接下来, 我们随机选择了 20 个区域, 并预测在采取一些控制措施后, 当地蜜蜂和雀蜂的种群数量会随时间发生怎样的变化。图 4.24 展示了其中 3 个区域的当地蜜蜂情况。

数据来源: 美国国家农业统计局 (<https://quickstats.nass.usda.gov/results/98D6C754-2F7A-319C95FE-CR8F673A140F>)




图 4.24: 有人类干预情况下的本地蜜蜂数量

我们可以通过用假设数据测试模型来绘制模型结果（图 4.25）。当 $t = 6.83$ 时，华盛顿 20 个地区的麻雀黄蜂数量将达到最低点，约为 1；当 $t = 7.46$ 时，这些地区的本地蜜蜂数量将达到最高点，约为 241。因此，我们可以得出结论，当时间范围在 6.83 到 7.46 之间时，本地蜜蜂的数量不少于 240 只。黄蜂的数量不超过 1 只，这表明华盛顿州的这 20 个地区的害虫已被根除。该模型还可用于该州其他地区的计算。





图 4.25: 有人类干预和无人干预情况下的种群变化

5 敏感性分析

在我们的模型中，几个数值的变化可能会显著影响模型的结果，因此我们需要逐一分析它们。

5.1 问题（a）中模型的敏感性

为了分析模型 1 和模型 2 权重的敏感性，我们选取不同的 β 值来计算组合预测模型的精度。我们依次选取集合 $\{0.1, 0.3, 0.6, 1, 3, 6, 10\}$ 中的每个元素作为 β 的值。箱线图如下所示。

图 5.1: β 的敏感性分析

从上图可以得出结论， β 对我们模型的预测精度影响很小，这表明我们的模型具有鲁棒性且非常可靠。

5.2 问题（c）中模型的敏感性

为了测试正则化系数 λ 的取值变化所产生的影响，我们选取了不同的 λ 值，并对麻雀蜂出现的概率分布进行了预测。预测结果如图 5.2 所示。




图 5.2: λ 的敏感性分析

当 λ 在特定范围内变化时，我们模型的预测准确率稳定在 90% 以上。当 λ 超过 10 时，模型的预测准确率迅速下降。当 λ 等于 0.6 时，我们的模型能达到最佳预测效果。

6 模型评估

优势：

- 综合考虑：我们从时间和空间两个角度预测了雀蜂的扩散，并选取了 16 个因素来计算环境适宜性。几乎所有有用的因素都已纳入模型 1（见 4.1 节）。
- 信息的充分利用：在评估雀蜂的概率分布时，我们采用了特征映射方法，将 2 个特征扩展为 28 个特征，从而充分利用有限数据的特征。（见 4.3 节）
- 复杂的模型改进方法：通过伪标签，我们能够利用未被开发的数据，这有助于提高原始预测模型的准确性。（参见第 4.4 节）

缺点：

- 数据量不足：阳性报告与阴性报告的比例过于极端。尽管我们已采取一些措施（例如，对图像进行水平和垂直翻转以增加数据量）来减少其对训练集的负面影响，但无法完全消除这种影响；
- 主观误差：在计算更新频率时，我们采用主观评估方法为五个因素分配权重，这在一定程度上是合理的，但不够准确。（见 4.4 节）

备忘录

致：华盛顿州农业部

发件人：2123823 号团队

主题：雀蜂传播预测

日期：2021 年 2 月 9 日

尊敬的先生：

随着全球化背景下贸易、运输和旅游业的发展，雀蜂的引入现已成为华盛顿州生态系统面临的
最大威胁之一。在我们的研究中，我们构建了一系列模型，希望能帮助政府充分利用公众报告
提供的数据，合理调配有限的资源开展调查。

分析预测结果后，我们有许多重要的发现和建议，这些可以帮助您显著提高调查效率。

i) 重点关注那些极有可能出现雀蜂的地区所发生的事件，并优先对这些事件进行调查。通过
比较不同地区的环境适宜性，我们发现有三个地区中心对雀蜂“友好”：第一个是美国
西北沿海地区；第二个是罗萨里奥海峡东海岸的北喀斯喀特国家公园及其周边地区；第三
个是内陆的库特尼国家森林。随着时间的推移，雀蜂将迁移到这三个地区中心。然后，结
合当年的数据，我们就能够准确预测下一年雀蜂的分布情况。上文包含详细数据。鉴于政
府机构的资源有限，你可以据此确定在哪里部署消灭措施以达到最佳效果。

ii) 运用图像识别和文本挖掘方法来减轻工作量，并有效提高调查的准确性。此外，你可以
鼓励人们拍摄雀蜂的照片或视频并上传到网站，以帮助你估算雀蜂的分布情况。在这个过程
中，照片或视频附带的说明会提高估算的准确性。然而，由于公众拍摄的照片质量较低，许
多不适合用于图像识别，且大多数上传的说明也不包含有用信息。因此，你应当适当地向公
众普及相关知识，以改进照片、视频和说明的质量。例如，关于如何拍摄高质量的照片，我
们建议最好在照片中清晰呈现雀蜂的头部、胸部和腹部，这些部位的特征较为明显。另外，
公众的说明应包含有用信息，如颜色、条纹和体型大小等。

iii) 更加关注夏季月份发生的事件，因为此时雀蜂往往更为活跃，并增加调查和数据更新的
频率。

根据预测结果，我们发现雀蜂在 7 月和 8 月最为活跃。在 11 月至次年 3 月期间，雀蜂几乎处于冬眠状态，很少出现，此时你最好适当降低调查和更新数据的频率，以避免人力和物力的浪费。

iv) 根据预测的雀蜂迁徙位置，及时通知养蜂人、农民及其他利益相关者，以避免不必要的经济损失。作为一种外来物种，雀蜂往往会大规模捕食其附近的蜂群，造成经济损失。

关于如何根除雀蜂，查阅相关资料后，我们提供以下几种方法。

i) 针对蚁后。族群中的蚁后通常在 4 月和 10 月外出，这段时间你最好多设置陷阱来捕捉并杀死蚁后。一旦蚁后死亡，这个族群会在短时间内消失。

ii) 瞄准巢穴。你可以追踪雀蜂回到它们的巢穴，找到巢穴并将其摧毁。

iii) 公众宣传。在日常生活中，你需要加强病虫害防治知识的普及。

上述建议将帮助您更好地预测雀蜂的分布，及时更新数据，更有效地抵御外来物种的入侵，保护当地生态系统。我们衷心希望我们的研究能对您有所帮助，更好地保护美国华盛顿州的生态环境。

此致，
敬启！

9193893 号团队

参考文献

- [1] 亚当·M·贝克和丹尼尔·A·波特。入侵性胡蜂将城市传粉者花园变成黑脉金斑蝶幼虫的生态陷阱。《科学报告》，10（1）：1-7，2020。
- [2] 佚名。亚洲巨型大黄蜂。取自<https://extension.psu.edu/asian-giant-hornets> 访问日期未知。
- [3] 穆娜·玛丽亚姆·阿兹米、铁朗·保坂和沼田伸也。日本名古屋市四种黄蜂对城市绿化水平的响应：对城市绿地生态系统负服务的启示。《城市林业与城市绿化》，第 18 卷：117-125 页，2016 年。
- [4] 阿尔韦托·J·阿兰尼斯、马里奥·A·卡瓦哈尔和巴勃罗·M·贝尔加拉。巨头要来了吗？预测亚洲巨型大黄蜂（胡蜂科，大虎头蜂）在美国的潜在传播及影响。《害虫管理科学》，77（1）：104-112，2021。
- [5] MP·罗伯逊、N·凯思尼斯和 MH·维莱特。一种基于主成分分析的建模技术，用于根据存在记录预测生物体的环境适宜性。《多样性与分布》，7（1-2）：15-27，2001。
- [6] 费尔南达·L·舒马赫、克莱西奥·S·费雷拉、马科斯·O·普拉特斯、阿尔贝托·拉乔斯和维克多·H·拉乔斯。一种用于新冠疫情死亡数据的稳健非线性混合效应模型。arXiv 预印本 arXiv:2007.00848. 2020。
- [7] 松浦诚。日本五种胡蜂属（膜翅目，胡蜂科）的比较生物学。1984 年。
- [8] 松浦诚与坂上昌一。《大胡蜂（*Vespa mandarinia*）的生态概述 —— 一种对日本养蜂业构成严重威胁的害虫（含 12 幅文本插图和 5 个表格）》。《北海道大学理学院学报》，1973 年，第 19 卷（第 1 期）：125-162。
- [9] 约翰·M·德雷克和罗伯特·L·理查兹。估算环境适宜性。《生态圈》，9（4）：602-613，2018。
- [10] 安娜·S·贝萨、若昂·卡瓦略、阿尔贝托·戈麦斯和弗雷德里科·桑塔雷姆。入侵的气候和土地利用驱动因素：预测黑胸胡蜂在伊比利亚半岛的扩张。《昆虫保护与多样性》，9（1）：27-37，2016。
- [11] 伊恩·古德费洛、约书亚·本吉奥和亚伦·库维尔。《深度学习》。麻省理工学院出版社，2016 年。
- [12] 阿南德·拉贾拉曼、杰弗里·戴维·厄尔曼。《大规模数据集挖掘》。剑桥大学出版社，2011 年。
- [13] 吴昊和 Saurabh Prasad。基于伪标签的半监督深度学习在高光谱图像分类中的应用。《IEEE 图像处理汇刊》，27（3）：1259-1270，2017。
- [14] 安吉丽卡·I·阿维莱斯 - 里韦罗、菲利普·塞拉斯、卡罗拉 - 比比安娜·舍恩利布和尼古拉斯·帕帕达基斯。GraphxCovid：用于识别胸部 X 光片上新冠肺炎的可解释深度图扩散伪标记。arXiv 预印本 arXiv:2010.00378. 2020 年。
- [15] 朱迪思·H·迈尔斯、安妮·萨瓦、埃德·范·兰登。《根除与害虫管理》。《昆虫学年评》，43（1）：471-491，1998。
- [16] 小条松象甲。新害虫应对指南。Dec. nv.gov，2004 年。