

C

2300348

重振经典游戏：通过数据分析揭示 Wordle 的秘密

摘要

在数字时代，语言通常通过缩写、表情符号和语音消息来传递。然而，《纽约时报》推出的 Wordle 游戏提供了一个回归语言本质的机会。因此，我们对 Wordle 产生的结果进行了数据分析。

首先，我们建立了一个 GRU 预测模型来预测 2023 年 3 月 1 日的报告结果数量。该模型采用了高效的门控循环单元（GRU）算法。因此，通过训练集对测试集进行的预测，其相对误差率为 2.1569%，相对 RESE 为 6.4957%，这表明模型预测具有良好的准确性。2023 年 3 月 1 日报告结果数量的预测区间为 $20367 \pm 2.01569\%$ 。

其次，我们根据分数百分比对单词的属性和分数进行了数据分析。然后，我们定义了单词的四个属性：词频、字母频率之和、字母重复模式（2/3 或无）以及主要词性。对于前两个属性，我们使用“分数”变量进行了回归分析。 f_{word} 与分数的皮尔逊相关系数为 -0.3165 ， f_{letter} 与分数的皮尔逊相关系数为 -0.4005 。rep 和 pos 可用于对单词进行分类。箱线图结果显示，rep 的箱线图中位数差异为 0.13004，而 pos 的仅为 0.05973。因此，我们认为 f_{word} 、 f_{letter} 和 rep 会影响分数百分比，而 pos 则不会。

第三，我们开发了 GSRF 预测模型，用于预测 2023 年 3 月 1 日 EERIE 的 1 到 X 的百分比。网格搜索随机森林（GSRF）算法是一种改进的随机森林算法，它采用了最佳的超参数组合。我们选择了 f_{word} 、 f_{letter} 和 rep 这三个参数作为模型的输入。模型的训练结果显示，均方误差（MSE）为 20.70641，平均绝对误差（MAE）为 3.24388，表明其具有良好的预测性能（表 10）。EERIE 的预测结果为（1, 7, 23, 30, 23, 13, 3）。此外，我们通过分别向 f_{word} 和 f_{letter} 添加高斯噪声进行了敏感性分析，结果表明该模型敏感性较低，因此稳定性较高。

第四，我们使用 K-Means++ 算法构建了难度等级分类模型。首先，我们定义了每个单词的难度值 δ 。通过预测分布，EERIE 的难度值为 0.35916。随后，我们利用 K-Means++ 算法对每个单词的 δ 值进行分析，得到了五个难度等级（表 11）。EERIE 被归类到第三等级。最后，我们将模型的分

类结果与一部分抽样单词的人工难度评级进行了对比，匹配率达到 93.33%，这证实了该模型的准确性。

最后，我们探究了另外两个数据特征。之后，我们依据稳定的模型撰写了一封信，致《纽约时报》的谜题编辑。

关键词：门控循环单元；回归分析；箱线图分析；GSRF；K 均值 ++

目录

1	引言	3
1.1	问题背景.....3	1.2 问题重述.....3
1.3	数据清洗 ...4	
1.4	我们的工作...4	
2	假设	5
3	符号	5
4	GRU 预测模型	5
4.1	GRU 算法描述.....	6
4.2	2023 年 3 月 1 日的预测.....	
5	单词属性与范围百分比的关系	
8		
5.2	回归分析 5.2.1 fn: 词频 .. 5.2.2 fnette: 字母频率	10
5.3	箱线图分析	11
5.3.1	rep: 字母重复率	11
5.3.2	pos: 词性	12
6	GSRF 预测模型	13
6.1	GSRF 算法描述	13
6.2	2023 年 3 月 1 日对 EERIE 的预测.....	14
6.3	预测评估分析.....	15
7	基于 K-Means++ 的难度系数分类模型	16
7.1	8: 难度系数 ...	16

7.2 K-Means++ 聚类分析.....16

7.3 EERIE 的难度分类.....17

7.4 分类模型的准确性讨论.....18

8 数据的有趣特征 19

8.1 特征 1: 词汇属性与困难模式百分比的关系.....19

8.2 特征 2: 为什么 “PARER” 具有最高的 “地狱级” 难度.....20

9 模型敏感性分析 21

9.1 GSRF 预测模型中 fuword 的敏感性分析..... 21

9.2 GSRF 预测模型中 fietter 的敏感性分析..... 21

10 模型评估与进一步讨论 22

10.1 优势.....22

10.2 不足与进一步讨论.....22

11 信函 24

A 样本 25

B 部分词汇的难度率 25

1 引言

1.1 问题背景

在这个数字时代，我们已经习惯了使用缩写、表情符号和语音消息进行交流。然而，有时这些交流方式会剥夺语言本身的美感和深度。但一款猜词游戏——Wordle，让我们能够以一种全新的方式回归语言的本质。通过感受每个字母和单词的韵律与含义，我们可以更深刻地理解语言的魔力，领略其内在的魅力。

Wordle 是《纽约时报》目前提供的一款热门每日谜题，它挑战玩家在六次或更少的尝试中猜出一个秘密的五字母单词。每一轮开始时，系统会随机选择一个单词，玩家必须运用推理和逻辑在规定的猜测次数内猜出答案。每猜一次，系统都会指出哪些字母出现在单词中，以及它们是否处于正确的位置。此外，玩家可以在“困难模式”下进行游戏，该模式要求一旦玩家猜对了答案中的某个字母，就必须在随后的所有猜测中继续使用该字母。

许多用户（尽管并非全部）会在 Twitter 上分享他们的得分。由本杰明·莱斯开发的 Twitter 机器人 Wordle Stats 可用于追踪和分析 Wordle 的每日得分报告。通过追踪和分析来自 Wordle Stats 的每日数据报告，我们或许能够提高自己的猜词技巧，并更好地理解英语的模式和用法。




图 1: Wordle [2]

1.2 问题重述

我们需要分析《纽约时报》提供的关于 Wordle 的数据，并回答以下问题：

1. 开发一个预测模型，用于预测未来某一天的报告结果数量，并提供预测区间。
2. 分析单词属性是否对在困难模式下进行的已报告分数的百分比有影响，以及它们是如何产生影响的。
3. 构建另一个预测模型来预测（1、2、3、4、5、6、X）的百分比，并以 2023 年 3 月 1 日的 EERIE 为例进行具体预测。还需要进行模型评估。

4. 开发一个分类模型来对单词的难度级别进行分类，并获取单词 “EERIE” 的难度级别。还需要进行模型评估。

5. 探索数据中其他可能的相互作用，看看能否发现任何有趣的特征。

1.3 数据清洗

观察所提供的数据，发现了一些问题及相应的处理方法如下。

参考 Wordle 状态，我们发现附件中存在一些错误数据。其中包括单词长度不正确、拼写错误以及“报告结果数量”中的数值错误等。例如，第 314 个单词被误写为 “tash”。此外，第 529 个单词的“报告结果数量”被错误地记录为 2569。为了解决这些问题，我们进行了数据清理以减少错误，提高数据的质量和准确性。以下是我们的数据清理结果。

Original data	marxh(473)	tash(314)	clen(525)	rprobe(545)	2569(529)
Data after cleaning	marsh	trash	clean	probe	25569

表 1：数据清洗

在数据检查过程中，我们发现由于统计误差，某些日期的尝试比例之和不等于 100% 的情况。为了解决此问题，我们重新计算了每天的比例，确保其总和恰好为 100%。通过这种方式，我们旨在减少不同日期同一变量相关的误差，并提高模型的准确性。我们的处理结果是 $\sum_{i=1}^X p_i = 100\%$ 。

1.4 我们的工作




图 2：我们的工作

2 假设

为简化我们的建模，我们做出以下假设：

· 假设 1：所报告的分数中在困难模式下进行的比例可以用 (1, 2, 3, 4, 5, 6, X) 的百分比来表示。由于 Wordle 状态此前已经汇总了 Wordle 207 中整体模式和困难模式下 (1, 2, 3, 4, 5, 6, X) 的值，我们发现这两组值仅相差 1%[1]。这对我们后续的分析很有帮助。

· 假设 2：无论玩家尝试多少次，他们在 Twitter 上分享 Wordle 结果的可能性都是相同的。这一假设有助于进行更准确的数据分析。

· 假设 3：每位玩家在玩《Wordle》之前都不知道答案，且在游戏过程中不作弊。这确保了得分百分比的客观性和准确性。

3 符号说明

Symbol	Description
$score$	the combination of the percentage of scores
f_{word}	the word frequency
f_{letter}	the letter frequency
rep	the repetition of word
pos	the part of speech of word
σ	the difficulty rate
MSE	the Mean Squared Error
MAE	the Mean Absolute Error
d	the Euclidean distance
SSE	the Sum of Squared Errors

表 2：本文中使用的关键符号

4 GRU 预测模型

报告结果的数量每天都在变化，分析这些数据的变化在一定程度上可以反映活跃的 Wordle 用户的趋势。通过研究历史数据和趋势，甚至有可能对未来的报告结果做出有根据的预测。因此在这

在本节中，我们应用了门控循环单元（GRU）算法对所提供的报告结果数量进行机器学习，最终对 2023 年 3 月 1 日的报告结果数量做出了预测。

4.1 GRU 算法描述

GRU（门控循环单元）是一种循环神经网络（RNN），通常用于时间序列分析。它具有与 LSTM（长短期记忆网络）架构相似的特性，但计算速度通常更快。

GRU 架构背后的主要思想是设置两个门，即重置门和更新门，它们控制着信息在网络中的流动。重置门决定应该忘记多少先前的隐藏状态，而更新门则决定应该将多少新输入添加到当前的隐藏状态中。




图 3: GRU 算法流程概述

GRU 的更新公式如下：

$$\begin{aligned} r_t &= \sigma(W_{ir}x_t + b_{ir} + W_{hr}h_{t-1} + b_{hr}) \\ z_t &= \sigma(W_{iz}x_t + b_{iz} + W_{hz}h_{t-1} + b_{hz}) \\ \tilde{h}_t &= \tanh(W_{in}x_t + b_{in} + r_t * (W_{hn}h_{t-1} + b_{hn})) \\ h_t &= (1 - z_t) * \tilde{h}_t + z_t * h_{(t-1)} \end{aligned}$$

(1)

其中：

Symbol	Decription
z_t	the update gate
r_t	the reset gate
h_t	the hidden state at time t

Symbol	Decription
h_{t-1}	the hidden state at time $t - 1$ or at time 0
$\tilde{h}_t$	the new candidate hidden state
σ	the sigmoid function
$*$	the Hadamard product
x_t	the input
$W_{ir}, W_{hr}, W_{iz}, W_{hz}, W_{in}, W_{hn}$	the parameters that need to be trained
$b_{ir}, b_{hr}, b_{iz}, b_{hz}, b_{in}, b_{hn}$	the parameters that need to be trained

表 3: 方程 1 中使用的符号

在这种方法中，时间序列的历史数据被输入到 GRU 模型中，以学习序列中的模式，这些模式随后可用于预测未来的数据点。

4.2 2023 年 3 月 1 日的预测

在 Python 丰富库的支持下，我们选择使用 PyTorch 提供的 GRU 模型。PyTorch 是一个基于 Python 的机器学习库，其显著特点是动态计算图，这与静态计算图不同。动态计算图可以在运行时进行更改，这意味着模型可以根据我们的需求进行修改。这在处理变长序列数据时非常有用，也非常适合我们需要预测的上报结果数量的预测任务。在 PyTorch 中，我们可以利用 torch.nn.GRU [3] 类轻松构建和训练 GRU 模型，并使用该模型进行预测。

我们将 2022 年 1 月 7 日至 2022 年 12 月 31 日期间每日“报告结果数量”时间序列数据的 80% 用作 GRU 模型的训练集，其余 20% 用作测试集。测试集上预测结果的可视化如图 4 所示：




图 4: 测试集上的预测结果。“偏差”表示预测数据与原始数据之间的相对误差率。

从图 3 可以看出，平均偏差约为 0.06，这表明预测数据与原始数据的偏差仅约为 6%。同时，观察到一个有趣的现象：2022 年 12 月 25 日（圣诞节）的偏差接近 50%，这是因为原始数据中该日的报告结果数量大幅下降。这很容易让人联想到当天是重大节日这一事实。这样的结果属于时间序列分析中的异常值，有充分理由剔除该值，并计算剩余数据的均值和均方根误差（RMSE）。RMSE 的计算方法如下：

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (x_t - \hat{x}_t)^2}{n}} \tag{2}$$

如下表 2 所示，预测数据与原始数据之间的相对误差率为 2.1569%，表明这两个值之间的偏差较小。同时，相对均方根误差（RMSE）是通过将 RMSE 除以原始数据计算得出的，在统计学中，当该值小于 10% 时，误差被认为是较小的。因此，可以得出结论：GRU 模型对报告结果的数量具有良好的预测性能，我们选择 2.1569% 的相对误差率作为模型预测的误差区间。

$\bar{x}_t$	$\bar{\hat{x}}_t$	Relative error	Relative error rate	RMSE	Relative RESE
24956.1667	25494.4569	538.29019	2.1569%	1621.0881	6.4957%

表 4：预测数据与原始数据的统计分析。

通过利用预训练的 GRU 模型，我们可以对未来 60 天进行预测，并得到 2023 年 3 月 1 日报告结果数量的预测区间：

$$x_{March1,2023} = 20367 \pm 2.01569\%$$

5 词语属性与百分比得分的关系

在本节中，我们对单词的四个属性以及由得分百分比得出的分数进行了数据分析。通过回归分析，我们发现单词的词频和字母频率与得分呈线性相关。通过箱线图分析，我们发现具有不同字母重复模式的单词的得分存在一定差异，而不同词性的单词的得分则没有表现出显著差异。结果概述如图 5 所示。




图 5: 第 4 节结果概述

5.1 按百分比定义的分

每日尝试率是当天得分的百分比。然而，在研究词汇属性与得分百分比之间的关系时，分析某个词汇属性与由七个数字构成的得分百分比分布之间的关系既困难又不利于分析。因此，我们将这七个百分比值处理为一个单一数字，并将其定义为得分。

分数由两部分组成。一部分是 1 到 6 次尝试的加权平均值，另一部分是 “X” 的百分比。考虑 “X” 的百分比的原因是，Wordle 每天只允许一次尝试，因此 “X” 的百分比实际上代表了当天猜测的失败率，这一点不容忽视。然而，由于 “X” 没有具体的尝试次数，无法参与加权平均值的计算，因此我们将其定义如下：其中：

· p_i 表示 i 尝试次数和 $i \in 1, 2, 3, 4, 5, 6, X$ 的百分比

ω_1 和 ω_2 分别表示分数两部分的权重。我们通过熵权法将 ω_1 设为 0.5，将 ω_2 设为 0.5。

5.2 回归分析

5.2.1 *fword*: 词频

在尝试玩 Wordle 谜题时，日常生活中更常用的单词往往更容易被人们记起，比如 “study”（学习）和 “train”（火车）。因此，当谜底是高频使用的单词时，尝试次数的百分比分布很可能会偏向更少的次数，从而导致得分降低。为了解决这个问题，我们首先使用了

结合网站 [4] 和 Python 来获取每个单词可靠的使用频率 f_{word} 。然后，我们对 f_{word} 和得分都进行了回归分析。

词频与得分的回归分析结果如图 6 (a) 和表 3 所示。皮尔逊相关系数为 -0.3165 ，斯皮尔曼相关系数为 -0.2956 ，这表明词频与得分之间存在一定的线性相关性。此外，通过观察图 6 (a) 中的散点图可以发现，图像的左下角和右上角没有数据分布。这意味着，一个词出现频率高但难以猜测从而导致得分低的情况，以及一个词出现频率低但容易猜测从而导致得分高的情况，都不太可能发生。因此，可以合理地得出结论：词频与得分之间存在一定的线性相关性。




图 6: 单词属性与得分的回归分析

Regression with <i>score</i>	Pearson	Spearman
Word frequency	-0.3165	-0.3256
Letter frequency	-0.4238	-0.4005

表 5: 单词属性与分数的回归分析

5.2.2 f_{Letter} : 字母频率

每个字母都有其自身的使用频率。当 Wordle 玩家使用字母频率较高的单词进行猜测时，他们可能有更高的几率命中答案中的字母，从而获得更多线索，减少尝试次数。

字母频率 (f_{Letter}) 是通过累加每个字母在单词中的使用频率得出的。字母频率的数据来源于谷歌图书 Ngram Viewer [4]，该数据库包含 1500 年至 2008 年的书籍及其他出版物语料库，具有较高的可靠性。例如，

字母 “e” 的出现频率为 11.1607%，而字母“z”的出现频率仅为 0.0772%。 f_{Letter} 的定义如下：

$$f_{Letter} = \sum_{i=1}^5 f_{n,b,c...}(4)$$


我们对 f_{Letter} 与得分之间进行了回归分析，这与词频的分析方式类似。字母频率与得分的回归分析结果如图 6（b）和表 3 所示。皮尔逊相关系数为 - 0.4238，斯皮尔曼相关系数为 - 0.4005，这表明字母频率与得分之间存在一定的线性相关性（甚至比词频的相关性更强）。此外，通过观察图 6（b）中的散点图可以发现，图像的左下和右上角落没有数据分布。这也说明，一个词出现频率高但难以猜测从而导致得分低的情况，以及一个词出现频率低但容易猜测从而导致得分高的情况，都不太可能发生。因此，可以合理地得出结论：字母频率与得分之间存在一定的线性相关性。

资料网


5.3 箱线图分析

5.3.1 rep: 字母重复

在答案词中存在重复字母的情况下，在固定单词长度的前提下，猜测时击中该字母并获得提示的概率可能更高，从而减少尝试次数。通过分析 2022 年 1 月 7 日 1 个字母重复两次或三次（极少数情况）的现象。因此，我们将这些单词分为两类：有重复字母的和没有重复字母的。我们想知道有重复字母的单词和没有重复字母的单词在得分上是否存在显著差异。为此，我们采用了箱线图分析：



(a) 重复的箱线图



(b) 重复的密度

图 7：字母重复率与得分的箱线图分析

Median difference	Box length difference	Number difference of outliers
0.130037	0.00556	2

表 6: 字母重复与得分的箱线图分析

从图 7 (a) 和表 6 可以看出，中位数差异为 0.130037，箱体长度差异为 0.00556。从图 7 (b) 可以看出，这两类数据的分布存在显著差异。因此，我们认为带有重复字母的单词和不带有重复字母的单词在得分情况上存在一定差异。

5.3.2 词性：词性

词性（POS）也是一个单词的重要属性。我们感兴趣的是，不同词性的单词在分数上是否存在差异。

我们使用了广受欢迎的 Python 自然语言处理工具包 Natural Language Toolkit [5]，该工具包包含各种文本处理和语言分析工具，其中包括词性标注。我们利用这个工具，对 2022 年 1 月 7 日至 2022 年 12 月 31 日期间的词汇进行了词性标注。词汇主要分为四类：名词、形容词、副词和动词。随后，我们对这四类词汇的 “得分” 进行了箱线图分析：




图 8: 词性与分数的箱线图分析

Median difference1	Median difference2	Median difference3
0.024991	-0.05973	-0.05972

表 7: 词性与得分的箱线图分析

从图 8（a）和表 7 可以看出，名词与形容词之间的中位数差异为 0.024991，名词与副词之间的中位数差异为 - 0.05973，名词与动词之间的中位数差异为 - 0.05972。从图 8（b）中可以观察到，这四类数据的集中趋势非常相似。因此，我们得出结论：不同词性的词语得分没有表现出显著差异。

6 GSRF 预测模型

在第 4 节中，我们将（1、2、3、4、5、6、X）的百分比处理为一个单一的参数分数。虽然单一参数可以捕捉这七个数字的一些整体特征，但这七个数字的具体含义无法单独表达，重要的细节和意义也可能丢失。

与第 4 节中的时间序列预测不同，报告结果的分布理论上应由当天答案词的属性而非时间序列决定。因此，我们选择了网格搜索随机森林（GSRF）算法，利用单词本身的三个属性来确定预测报告结果分布的最佳策略。借助从现有数据训练的模型中获得的最佳策略，我们预测了 ed 性能。

6.1 GSRF 算法描述

GSRF 算法由随机森林和 GridSearchCV 组成。

GridSearchCV 是一种参数优化算法，常用于微调机器学习模型中的超参数，以优化模型性能。它会遍历指定的参数网格，对每种可能的参数组合进行模型训练和评估，最终输出最佳参数集及相应的模型性能指标。

随机森林是一种机器学习算法，由多个决策树集成而成。随机森林的训练过程基于多个决策树，该算法会为每个决策树随机选择一部分特征子集进行训练。在预测时，随机森林通过平均或投票的方式汇总每个决策树的预测结果，从而得到最终的预测。

与普通的随机森林算法不同，GSRF 算法能够使用最佳超参数组合来训练和预测随机森林模型，这显著提升了模型的性能，并避免了过拟合或欠拟合等问题。GSRF 的算法流程如图 9 所示。




图 9: GSRF 的算法流程

6.2 2023 年 3 月 1 日对 EERIE 的预测

在第 4 节中，我们对单词属性与得分百分比之间的关系进行了数据分析。我们发现，词频 fw 、字母频率 f_{letter} 以及字母重复率 rep 对得分百分比有一定影响。因此，我们将单词本身的这三个属性作为随机森林模型的输入参数，以预测报告结果的分布：

我们以想要预测的单词 “eerie” 为例，其三个输入词属性如表 8 所示。需要注意的是，对于有重复字母的单词，我们将 rep 值设为 1.5，对于没有重复字母的单词，将 rep 值设为 1。这是合理的，因为 GSRF 在计算前会对输入数据进行归一化处理。由于 rep 只有两个可能的值，它会被处理为 0 和 1。

$f_{word},$	$f_{letter},$	ref
0.00023%	0.418799	1.5

表 8: EERIE 的单词属性

接下来，我们使用 2022 年 1 月 7 日至 2022 年 12 月 31 日期间每个单词的词频、字母频率和重复信息训练了 GSRF 模型，以了解其报告结果的分布。为实现这一目标，我们利用了 `scikit-learn` (sklearn) 机器学习库集成模块中的 `RandomForestRegressor` 算法 [6]，以及 `sklearn.model_selection` 模块中的 `GridSearchCV` 算法 [7]。借助训练好的 GSRF 模型，我们利用单词 “eerie” 的三个单词属性对其报告结果的分布进行了预测。结果如表 9 和表 10 所示：

max depth,	max features,	min samples leaf	min samples split	n estimators
10	'sqrt'	2	10	200

表 9：通过 GridSearchCV 得到的最佳超参数组合

1	2	3	4	5	6	X
1.07508%	6.51769%	23.30265%	30.29725%	23.13552%	13.27519%	2.40859%
MSE: 20.70641	MAE: 3.24388					

表 10：2023 年 3 月 1 日对单词 EERIE 的预测

6.3 预测评估分析

在使用机器学习算法进行预测时，两种常用的评估指标是均方误差（MSE）和平均绝对误差（MAE）。MSE 是预测值与原始数据之间平方差的平均值，而 MAE 是预测值与原始数据之间绝对差的平均值。它们的计算方式如下：公众其中：

n 表示样本数量， y_i 表示原始数据， $\hat{y}_i$ 表示预测数据。

根据表 10 中的数据，GSRF 预测模型对 2023 年 3 月 1 日 “EERIE” 的报告结果分布具有非常好的预测性能，其均方误差（MSE）为 20.70641，平均绝对误差（MAE）为 3.24388。这表明该模型能够基于该词的属性准确预测其报告结果，体现了 GSRF 算法在这项任务中的有效性。

考虑到一个词的属性并不局限于我们所应用的这三个，其他未被探索的属性也可能会影响报告结果的分布。将这些额外的属性作为输入纳入模型，或许能提高其预测准确性。此外，一个词出现的时间也可能对分布产生影响，“圣诞节” 这一特殊例子就体现了这一点。

关于单词属性不完整的问题，我们的模型已经尝试全面考虑那些对预测有益的属性。

- 至于时间是否是一个因素，目前尚不确定。

基于上述分析，我们认为我们的预测模型是全面且准确的。

7 基于 K-Means++ 的难度等级分类模型

在本节中，我们利用报告结果的分布来定义单词的难度率 δ ，并计算了“EERIE”以及 2022 年 1 月 7 日至 2022 年 12 月 31 日期间的单词的 δ 值。随后，我们使用 K-Means++ 算法对单词的难度率进行聚类分析，得到了科学的难度率分类。“EERIE”被归为 3 级。最后，我们对单词进行随机抽样，手动标记它们的难度等级，并使用 K-Means++ 模型进行聚类分析。结果表明，我们的分类模型相对准确。

7.1 δ ：难度率

一个单词的难度级别可以直接通过（1、2、3、4、5、6、X）的百分比来确定。可以观察到，当一个单词特别难时，人们不得不去猜测，较大尝试次数（例如 5 或 6）的百分比会增加。

与第 4 节中的得分类似，难度系数仍由两部分组成。一部分是（1、2、3、4、5、6）的百分比的加权平均值，另一部分是 X。然而，与得分中以百分比计算的 X 分量不同，在计算 δ 时，X 与另一部分之间的数值差异相对较大。由于 X 反映了某天未能回答该问题的人数百分比，因此在衡量一个单词的难度时，应该给予它更大的权重。为了平衡这两个参数，我们使用 Sigmoid 函数对这两个数据进行归一化，然后采用熵权法分配权重，从而得到难度系数 δ ：

$$\delta = \sigma\omega_1 * \sum_{i=1}^6 i * p_i + \sigma\omega_2 * p_X$$

(8)

其中：

p_i 表示尝试次数和 $i \in 1, 2, 3, 4, 5, 6, X$ 的百分比

σ 表示 sigmoid 函数

ω_1 和 ω_2 分别表示得分两部分的权重。我们通过熵权法将 ω_1 设为 0.5，将 ω_2 设为 0.5。

7.2 K-Means++ 聚类分析

K-Means 聚类算法是一种常见的无监督机器学习算法，用于将数据划分为多个类别。它预先指定初始聚类数量和初始

聚类中心，并根据样本间距离的大小将样本集划分为不同的簇。欧氏距离被用作数据对象间相似性的度量，相似性与数据对象间的距离成反比。相似性越大，距离越小。基于数据对象与聚类中心之间的相似性，不断更新聚类中心的位置，并持续减小簇的误差平方和（SSE）。当 SSE 不再变化或目标函数收敛时，聚类结束，得到最终结果。

空间中数据对象与聚类中心之间的欧氏距离公式为：

$$d(X,C_i)=\sqrt{\sum_{j=1}^m(X_j-C_{ij})^2}$$

其中：

· X 表示数据对象

资料网

· C_i 表示 i 类聚类中心

· m 表示数据对象的维度

X_j 和 C_{ij} 分别表示 X 和 C_i 的第 j 个属性值。

计算 chire 数据集 SSE 的公式为：

$$\because SSE=\sum_{i=1}^k\sum_{x\in C_i}|d(X,C_i)|^2$$

其中：

· k 表示聚类的数量

在传统的 K-Means 算法中，聚类中心的初始化通常是从 k 个样本点中随机选择的。然而，这种随机选择方法容易陷入局部最优，导致聚类结果不佳。K-Means++ 算法引入的概率选择过程能够使聚类中心更加分散，从而更容易找到全局最优解，进而提高聚类结果的质量。

7.3 EERIE 的难度分类

使用 Python 的 scikit-learn 库中的 K-Means 算法 [8]，并设置 “k-means++” 初始化参数，我们可以对计算出的每个单词的难度率 δ 进行聚类分析。该分析将单词的难度系数分为 5 个等级，从 1 级到 5 级，等级越高表明单词难度越大。单词 “ERRIE” 的计算难度率 δ 为 0.35916，对应难度等级中的 3 级。结果如下列图 10 和表 11 所示：




图 10: 难度等级分类

Level	Number	Percentage	Valuable Percentage
1	131	36.2%	36.2%
2	152	42.4%	42.4%
3	69	19.1%	19.1%
4	7	2%	2%
5	1	0.3%	0.3%
Sum	6.51769%	23.30265%	30.29725%

表 11: 聚类分析结果

7.4 分类模型的准确性讨论

最后，我们随机抽取了 30 个单词，手动标记了它们的难度等级，并使用 K-Means++ 模型进行聚类分析。将样本单词的手动标记难度等级与聚类分析得到的难度等级进行比较，30 个数据点中有 28 个匹配，匹配率为 93.33%。这表明模型得到的难度等级分类与我们对单词难度的主观判断是一致的。因此，我们认为我们的分类模型相对准确。单词样本的数据详见附录 A。

数据的 8 个有趣特征

8.1 特征 1: 单词属性与困难模式百分比的关系

我们感兴趣的是，单词的属性是否与每天选择困难模式的用户比例有关。由于单词的属性在某种程度上与难度相关，如果某天单词太难，会增加用户的挫败感，那么用户第二天可能就不会选择困难模式。因此，我们对单词的四个属性和每天选择困难模式的百分比进行了数据分析，包括回归分析和箱线图分析。结果表明，困难模式的选择百分比与单词频率和字母频率没有线性关系。在具有不同字母重复情况和不同词性的单词中，困难模式的选择百分比也没有显著差异。结果如下：







图 11: 单词属性与困难模式百分比之间的回归分析





(c) 词性的箱线图



(d) 词性密度

图 12: 词性 (POS) 与困难模式百分比之间的箱线图分析

8.2 特征 2: 为何 “PARER” 的难度达到 “地狱级”

在第 8 节中，我们发现 “parer” 一词的难度值高达 0.98，远超排名第二的 “mummy” (0.69 分)。回顾原始数据，我们惊讶地发现，在 “parer” 出现的当天，“X” 百分比高达 48%，这意味着 48% 的玩家未能猜出答案。在浏览 Wordle Stats 上的用户评论时，一些评论提供了可能的解释（图 13）。评论指出，当待猜单词有许多相似词（即字母组成或位置相似）时，这些……





图 13: 用户评论

9 模型敏感性分析

我们对 GSRF 预测模型的输入参数进行了敏感性分析，以测试其在预测报告结果分布时对输入参数变化的敏感性。具体方法是向模型的输入参数添加高斯噪声。然而，对于单词重复程度，只有两种类型的数据，并且在对输入数据进行归一化时，添加到 rep 的噪声会被模型直接消除。因此，我们仅对词频和字母频率进行了敏感性分析。高斯噪声的定义如下：

$$p(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right) \tag{11}$$

其中：

， x 随机信号的振幅， μ 表示均值， σ 表示标准差

9.1 GSRF 预测模型中 f_{word} 的敏感性分析

在向词频添加高斯噪声后，结果如图 14 所示：




图 14：词频敏感性

敏感性分析的可视化结果表明，GSRF 预测模型对词频变化的敏感性较低，这表明其具有较高的稳定性。

9.2 GSRF 预测模型中 f_{letter} 的敏感性分析

在字母频率中加入 1 个高斯噪声后，结果如图 15 所示：





图 15：字母频率的敏感性

敏感性分析的可视化结果表明，GSRF 预测模型对字母频率变化的敏感性相对较低，这表明其具有较高的稳定性。

10 模型评估与进一步讨论

10.1 优势

1. GRU：第 4 节中的 GRU 算法在用于预测任务时具有多个优势。GRU 能够有效处理输入长度可变的序列数据，使其非常适合时间序列预测。而且与其他循环神经网络（如 LSTM）相比，GRU 通常需要更少的参数来训练，这使其计算效率更高，也更易于训练。因此，我们预测结果的相对误差率仅为 2.1569。
2. GSRF：与普通的随机森林算法不同，第 6 节中的 GSRF 算法能够利用最佳超参数组合来训练和预测随机森林模型，这显著提升了模型的性能，并避免了过拟合或欠拟合等问题。
3. K-Means++：在传统的 K-Means 算法中，容易陷入局部最优，导致聚类结果不佳。K-Means++ 算法第 7 节引入的概率选择过程可以使聚类中心更加分散，更易找到全局最优解，从而提高聚类结果的质量。
4. K-Means++ 我们在第 5 节的词属性分析和第 8 节的数据特征挖掘中的分析相对全面且具有建设性。

10.2 局限性及进一步讨论

1. 单词还有更多属性，例如元音和辅音。
2. 时间因素可以纳入报告结果分布的预测中。

3. 我们的模型使用了大量机器学习算法。可以选择更先进的方法和数据训练技术。例如，K-Means 算法有诸如 Mini-Batch K-Means 和遗传 K-Means 算法等变体。可以从每种变体中选择最合适的算法来分析当前数据。

参考文献

[1]<https://twitter.com/WordleStats/status/1481687496241164291>

[2] <https://www.marca.com/tecnologia/2022/02/14/620a2ee522601da7288b4599.html>

[3]<https://pytorch.org/docs/stable/generated/torch.nn.GRU.html>

[4]<https://books.google.com/ngrams/>

[5]<http://www.nltk.org/>

<https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html>

[7] https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html

[8]<https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html>

[9]<https://twitter.com/Wordlestats/status/1571182427007221764>

[10]https://twitter.com/s_harmony_/status/1570624760530477057

11 封信

亲爱的《纽约时报》谜题编辑：

希望您一切安好。我写这封信是为了分享我们对 Wordle 数据的分析结果。

首先，我们建立了一个 GRU 预测模型来预测 2023 年 3 月 1 日的报告结果数量。该模型采用了有效的门控循环单元（GRU）算法。因此，通过训练集对测试集进行的预测，其相对误差率为 2.1569%，相对 RESE 为 6.4957%，这表明模型预测具有良好的准确性。2023 年 3 月 1 日的报告结果数量预测区间为 20367 + 2.01569。

其次，我们对单词的属性以及由困难模式下得分占比所定义的分数进行了数据分析，以探究它们之间的关系。随后，我们定义了单词的四个属性：词频、字母频率总和、字母重复模式（2/3 或无）以及词性：主要词性。对于 f_{word} 和 f_{letter} ，我们以“分数”为变量进行了回归分析。 f_{word} 与分数之间的皮尔逊相关系数为 - 0.3165， f_{letter} 与分数之间的皮尔逊相关系数为 - 0.4005。重复模式（rep）和词性（pos）可用于对单词进行分类。箱线图结果显示，重复模式（rep）箱线图的中位数差异为 0.13004，而词性（pos）的中位数差异仅为 0.05973。因此，我们认为 f_{word} 、 f_{letter} 和重复模式（rep）会影响得分占比，而词性（pos）则不会。

记



第三，我们开发了 GSRF 预测模型，用于预测 2023 年 3 月 1 日 EERIE 的 1 到 X 的百分比。网格搜索随机森林（GSRF）算法是一种改进的随机森林算法，它采用了最佳的超参数组合。我们选择了 f_{word} 、 f_{letter} 和 rep 这三个参数作为模型的输入。模型的训练结果显示，均方误差（MSE）为 20.70641，平均绝对误差（MAE）为 3.24388，表明其具有良好的预测性能（表 10）。EERIE 的预测结果为（1, 7, 23, 30, 23, 13, 3）。此外，我们通过分别向 f_{word} 和 f_{letter} 添加高斯噪声进行了敏感性分析，结果表明该模型敏感性较低，因此稳定性较高。

第四，我们使用 K-Means++ 算法构建了难度等级分类模型。首先，我们定义了每个单词的难度值 δ 。通过预测分布，EERIE 的难度值为 0.35916。然后，我们采用改进的聚类分析算法 K-Means++ 对每个单词的 δ 值进行分析，得到了五个难度等级（表 11）。EERIE 被归类到第三等级。最后，我们将该模型的分

最后，我们发现所分析的四个单词属性并不会影响选择困难模式的用户比例。我们还调查了为什么“parer”是第五难度等级中唯一的单词，其难度系数高达 0.98。事实证明，一个单词的难度可能与其与其他单词的相似度以及这些相似单词的使用频率有关。

如果你想了解更详细的信息，可以阅读我们模型的全文。

此致，
敬礼！

A 样本

Word	Manual	Model	Word	Manual	Model	Word	Manual	Model
atoll	3	3	foyer	5	5	twang	4	4
train	1	1	flock	4	4	bloke	4	4
madam	5	5	hairy	3	3	primo	5	5
peach	2	2	other	3	3	depth	2	2
admit	3	3	knoll	5	5	brine	3	3
trait	4	4	buggy	5	5	class	4	5
recap	3	3	favor	5	5	natal	5	5
carry	3	5	happy	1	1	atone	2	2
found	5	5	aphid	4	4	thyme	2	2
molar	4	4	bough	5	5	wacky	5	5

欢 科网

B 部分单词的难度率

Word	value	group	Word	value	group	Word	value	group
stein	0.139130856	1	treat	0.0894603	1	cloth	0.173900245	1
aloud	0.108252609	1	dream	0.097017869	1	poise	0.139130856	1
today	0.196054096	1	panic	0.151548495	1	glory	0.183128816	1
stair	0.064625023	1	doubt	0.12793931	1	caulk	0.310999245	2
grate	0.174870226	1	solar	0.173476571	1	infer	0.323441505	2
happy	0.203454774	1	choke	0.178493799	1	movie	0.317155672	2
metal	0.17185657	1	tepid	0.117904854	1	donor	0.23639953	2
tiara	0.168933189	1	begin	0.22372847	1	bluff	0.308941723	2
hoard	0.181350828	1	thyme	0.205706341	1	piney	0.349255486	2
avert	0.226157463	1	robin	0.208597166	1	beady	0.285658995	2
Word	value	group	Word	value	group	Word	value	group
cynic	0.246710978	2	showy	0.327805763	2	eject	0.360750519	3
lofty	0.313559582	2	cargo	0.289792582	2	gully	0.475589662	3
unfit	0.258769444	2	blown	0.253373134	2	sever	0.435166278	3
flock	0.263786672	2	glyph	0.233683305	2	vivid	0.407453933	3
carry	0.293076879	2	nasty	0.236784568	2	comma	0.373391992	3
condo	0.339162962	2	creak	0.303318231	2	wedge	0.376850239	3
sweet	0.304997854	2	shard	0.292839653	2	motto	0.355507495	3
soggy	0.308474029	2	elope	0.293112002	2	droll	0.362206003	3
flood	0.271312514	2	howdy	0.38417086	3	mummy	0.685643564	4
story	0.23657413	2	gamer	0.368070525	3	parer	0.978421619	5