

破解 Wordle 谜题：单词属性分析方法

摘要

在过去的 600 天里，一款名为 “Wordle” 的五字母猜谜游戏在推特上掀起了一股热潮。Wordle 玩家的得分报告对管理人员来说至关重要，因为它们为评估游戏难度、预测玩家数量和及时做出调整提供了宝贵的信息。为了更好地分析这些报告并提供游戏改进建议，我们从多个角度和层面对此主题进行了深入细致的研究。

首先，为了解释 Wordle 报告数量的变化并进行预测，我们将玩 Wordle 的行为与传染病的传播进行类比。我们把玩 Wordle 比作感染，玩家比作感染者，长时间未玩 Wordle 的人比作易感者，对游戏感到厌倦的人比作康复者，在 Twitter 上分享比作传播，退出游戏比作康复。基于这些假设，我们使用 SIRS 模型来拟合曲线并解释整体趋势。我们还使用 Prophet 模型插入断点来解释数据波动，并为未来数据提供预测区间。模型评估结果表明，我们的模型具有较高的可解释性和准确性。

接下来，我们从一个包含大量语料库信息的词汇数据库中提取各种词汇属性，并使用多元线性回归来研究词汇属性与困难模式得分之间是否存在关系。然后，我们基于 F 统计量检验该模型的显著性。结果显示这两个因素之间没有显著的相关性。

此外，我们基于之前提取的词语属性构建了一个 BP 神经网络模型，以预测词语猜测次数的分布情况。评估结果表明，该模型具有较高的预测准确率和效率，为下一步的分析奠定了坚实的基础。

此外，我们使用 K-means++ 聚类算法将单词分为三类：简单、中等和困难。我们分析了单词属性与难度之间的关系，以便按难度对答案词进行分类。我们发现，单词的难度与单词中不同字母的数量、字母频率的总和以及单词在不同领域的使用广度密切相关，但没有显著证据表明难度与词频之间存在相关性。结合之前的 BP 神经网络模型，我们可以准确地对单词进行分类。

此外，我们发现像 “妈妈” 和 “手表” 这样的常见单词猜词难度更高，而且单词的首字母与其猜词难度之间也存在一定的相关性。

最后，我们向《纽约时报》的编辑们提供了预测数据和改进建议，以帮助改进 Wordle 并增强该游戏的吸引力。

关键词：Prophet；SIRS；多元线性回归；BP 神经网络；K-Means++

1 引言	
3	
3	
1.2 问题重述.....3	
2 假设与符号 4	
2.1 假设 4	
2.2 符号.....4	
3 模型 1—— 基于 Prophet 和 SIRS 的解释与预测集成模型 5	
3.1 数据预处理与探索性分析.....5	
3.2 Prophet 模型.....3.3 报告数量变化的解释.....9 3.4 词语属性提取.....3.1.1 数据收集与预处理.....5 3.1.2 数据描述与探索性分析.....5.6.....10	
3.3 H 模型报告占比的变量影响.....2	
.....	
3.5.1 模型建立.....	
3.2 gsi 的 Snicc o	
.....	
4.1 BP 模型构建 4.2 BP 模型的不确定性 4.3 BP 模型评估 4.4 BP 模型预测.....14	
5 模型 3—— 基于 K-Means++ 的难度分类 14	
5. 基于的 Csi nsi.....	
5.2 词语属性与难度等级的关系.....15 5.3 关于模型分类准确性的 PCA 讨论.....18 5.4 “EERIE” 难度等级的确定.....19 5.2.1 难度等级与 ND LW 的关系.....15 5.2.2 难度等级与 SLF 的关系.....17 5.2.3 难度等级与 BU 及 Freq 的关系.....17	
6 有趣的发现 6.1 这些词真的那么难吗?20 20	
6.2 哪个首字母对谜底词构成最大挑战?20	
6.3 哪些词能让 Wordle 持续流行?21	
7 敏感性分析 22	
8 模型评估 23	
8.1 优势.....3 8.2 劣势.....23	
参考文献 23	
信函 24	
2525	
附录	
附录 A 回归方程	

1 引言

1.1 背景

最近，推特上掀起了一股分享 Wordle 成绩报告的热潮。过去，益智游戏开发者往往不太清楚自己的游戏对大众而言难度如何。太难的游戏会让人沮丧，太简单的则会令人觉得无聊。随着信息技术的发展，利用大数据分析来控制谜题难度已成为让谜题更具趣味性的关键。《纽约时报》的 Wordle 游戏收集了玩家的尝试次数以及在推特上的报告数量等数据。这些数据可用于评估玩家数量和特定单词的难度，维持玩家的热情，让游戏更具吸引力。

1.2 问题重述

《纽约时报》收集了 359 天的 Wordle 玩家得分报告，包括报告时间、数量、困难模式报告的百分比以及尝试次数。为了控制游戏玩法并估算玩家数量，有必要分析报告数量的趋势、挖掘单词属性中包含的信息，并衡量单词的难度。为了实现这些目标，我们需要：

从大时间尺度（整体趋势）和小时间尺度（数据突变）两方面分析报告数量变化的原因。

收集并挖掘潜在的单词属性。

- Analyze whether the percentage of difficult mode reports is related to word attributes.

分析尝试次数的分布及其与单词属性的潜在关系。

确定单词属性对难度的影响。

挖掘其他有助于改进 Wordle 的信息。




图 1：本文的流程图

2 假设与符号

2.1 假设

为简化模型，我们做出了若干假设。不过，为了优化模型并提高其在复杂现实环境中的适用性，我们可能需要放宽其中一些假设。

Twitter 用户的数量基本保持不变，且每个用户收到与 Wordle 相关信息的概率是相等的。

所有 Wordle 玩家都是 Twitter 用户，且所有 Twitter 用户都是潜在的 Wordle 玩家。

Wordle 中每天的单词是完全随机的，选自所有五个字母的单词。

在 Twitter 上报告游戏结果的玩家是所有玩家中的一个随机样本。

人们可能会厌倦玩 Wordle，但过了很长一段时间后，他们最终可能还是想再玩一次。

2.2 符号说明

: 18 个 Sed Smbas 的参数

Symbols	Definition
<i>NN</i>	Noun, singular or mass
<i>JJ</i>	Adjective
<i>RB</i>	Adverb
<i>VBP</i>	Verb, non-3rd person singular present
<i>VBD</i>	Verb, past tense
<i>NNS</i>	Noun, plural
<i>VBN</i>	Verb, past participle
<i>VB</i>	Verb, base form
<i>IN</i>	Preposition or subordinating conjunction
<i>VBZ</i>	Verb, 3rd person singular present
<i>VBG</i>	Verb, gerund or present participle
<i>MD</i>	Modal
<i>PRP</i>	Possessive pronoun
<i>RBR</i>	Adverb, comparative
<i>CC</i>	Coordinating conjunction
<i>JJR</i>	Adjective, comparative
<i>DT</i>	Determiner
<i>JJS</i>	Adjective, superlative

表 2：本文中使用的词语属性符号

Symbols	Definition
$Freq$	Word Frequency
SLF	the Sum of Letter Frequencies
BU	the Breadth of Usage of a Word
$NDLW$	the Number of Different Letters in a Word
$a-z$	the Number of Letters from a to z in a Word

3 模型 1—— 基于 Prophet 和 SIRS 的解释与预测集成模型

3.1 数据预处理与探索性分析

3.1.1 数据收集与预处理

在解决任务 1 时，有必要分析与该问题相关的词语属性并收集相关数据。可能的因素包括词频、在不同领域的使用广度、词语中不同字母的数量以及词性。在一般的自然语言处理（NLP）中，常用的词性有 36 种 [2]，其中我们选取了与本任务相关的 18 种，如表 1 所示。

为了处理原始数据集中的缺失值、异常值和重复观测值，我们采用了一系列数据处理方法：数据清洗、为离散变量建立虚拟变量、对报告数量进行对数转换以及创建新属性。这四个步骤能够消除无关信息，并有助于从数据集中识别和提取相关信息。

步骤 1：在数据清洗阶段，我们使用 Python 检查缺失值、异常值和重复值。通过测量单词长度，我们检查空值或异常长的值。我们发现没有空值，但有三个异常值：“tash”、“clen”和“rprobe”。经过在线搜索和比对，我们将这些单词纠正为“trash”、“clean”和“probe”。此外，使用“duplicate ()”方法检查重复值，未发现重复值。

步骤 2：为了使词性这一离散变量更易于模型处理，我们构建了 17 个虚拟变量，将该离散变量转换为二元变量。

步骤 3：我们计划使用时间序列模型来预测 2023 年 3 月 1 日的报告数量。在这类模型中，消除数据中的异方差性至关重要。对数据取对数不会改变其性质或相关性，但会压缩变量的尺度。通过缩小数据的绝对值，更容易消除异方差性问题。因此，我们对报告数量进行对数变换。

步骤 4：为了全面探究各种词汇属性对所报告的困难模式得分的影响，我们进一步提取了词汇的属性并建立了几个新变量。这将在 3.4 节中详细阐述。

3.1.2 数据描述与探索性分析

对数据进行可视化处理以挖掘其内在规律，这有助于建模。图

图 2 描述了变量之间的相关性，而图 3 以直方图的形式呈现了尝试次数的分布情况。图 4 展示了报告总数以及困难模式下报告所占比例随时间变化的曲线。




图 2：相关矩阵




图 3：分布直方图

我们可以看出，变量之间的相关性总体较弱，尝试次数的分布呈现出两端低、中间高的状态。数量曲线的趋势与感染曲线有些相似，这将在后续步骤中进行详细分析。

3.2 Prophet 模型

Facebook 提供的 Prophet 算法 [3] 不仅能够处理带有一些异常值的时间序列数据，还能处理部分缺失值。它几乎可以自动预测时间序列的未来趋势。该算法基于时间序列分解和机器学习拟合，使用开源工具 pyStan 来拟合模型，因此能够快速获得预测结果。

在对数据进行对数变换后（详见 3.1.1 节），我们使用 Prophet 建立了一个乘法模型，其参数如表 3 所示，其中 τ 是一个




图 4: 数量曲线

控制线性函数在断点处斜率的参数。对于变化点处的变化率（记为 Δ ），其遵循 $\Delta \sim \text{Laplace}(0, \tau)$ 。随着 τ 减小， Δ 趋近于 0。因此，增大 τ 会拓宽预测值的上下限。趋势项采用默认的分段线性函数。设置更多的变化点并扩大断点范围，会使模型对时间序列数据的变化更敏感，从而改善拟合效果。

表 3: Prophet 模型参数设置

the Number of Changepoints	60	
τ	0.8	
the Range of Changepoints	0.9	
Holidays	Valentine	2022/02/14
	Easter	2022/04/24
	Halloween	2022/10/31
	Thanksgiving	2022/11/24
	Christmas	2022/12/25

Prophet 模型通常由趋势项 $q(t)$ 、季节项 $s(t)$ 、假日效应项 $h(t)$ 和残差项 $\varepsilon(t)$ 组成。 $q(t)$ 是一个分段线性函数，满足：其中 k 表示增长率， Δ 表示增长率的变化， m 表示偏移参数。 $s(t)$ 包含每周的周期性变化：其中 P 是周期时间，且 (a_n, b_n) 、 $(n = 1 \dots N)$ 服从正态分布。 $h(t)$ 说明了假日对结果的潜在影响：

$$h(t) = \sum_{i=1}^L k_i * l_{\{t \in D_i\}}$$

(3)

其中 k_i 、 $i = 1 \dots L$ 服从正态分布。基于上述参数和函数，建立了一个乘法模型：

$$y(t) = g(t) * s(t) * h(t) * \varepsilon(t) \tag{4}$$

我们使用 2022 年 1 月 7 日至 2022 年 11 月 21 日的数据作为训练集，使用 2022 年 11 月 21 日至 2022 年 12 月 31 日的数据作为测试集。拟合结果如图 5 所示，其中红色竖线代表我们设置的断点。




图 5: Prophet 预测

我们使用四个指标来评估该模型的有效性：决定系数（R-squared）、均方误差（MSE）、均方根误差（RMSE）和平均绝对百分比误差（MAPE），具体如下：其中 $\hat{y}_t$ 代表拟合值， y_t 代表实际值。结果如表 4 所示。决定系数接近 1，表明该模型拟合效果极佳。由于我们的最终结果是通过通过对数转换后的数据取指数得到的，因此可以认为较小的均方根误差和均方误差是合理的。4.8% 的平均绝对百分比误差表明平均绝对百分比误差较小。总体而言，所建立的模型适用于预测。

根据上述数据，我们减小 τ 以提高预测区间的精度。随后，我们重新建立模型，并预测 2023 年 3 月 1 日的报告结果数量

表 4: Prophet 的评估

R-squared	MSE	RMSE	MAPE
0.9924	60340502	7767.9149	4.8002

为 14534，预测区间为（13175，16128）（95% 置信水平）。这些预测结果表明，Wordle 的热度随着时间的推移在下降。

3.3 报告数量变化的解释

报告数量的变化可以分解为趋势、季节性和节假日因素，如图 6 所示。我们将从这三个方面来解释报告数量的变化。




图 6: 时间序列分解图

季节性和假日效应:

假期会导致报告数量减少，例如线性趋势图显示情人节前后的报告数量略有下降。在周效应中，报告数量从周日到周三呈上升趋势，从周三到周六呈下降趋势（周五有反弹）。这表明人们倾向于在工作日将《单词大闯关》作为消遣，而在假期则兴趣较低。

整体变化解释：

SIRS 传染病模型能很好地解释趋势成分的变化。我们的假设如下：

假设 1: 所有 Twitter 用户 $A(t)$ 可分为三组：

(1) 普通的 Twitter 用户 $S(t)$ 。他们可能会因为在 Twitter 上看到一些 Wordle 玩家的得分报告而受到影响，并可能产生成为 Wordle 玩家的动力。他们对应的是 “易感个体”；

(2) Wordle 玩家 $I(t)$ 。一些玩家会在 Twitter 上发布报告，这会吸引其他人成为 Wordle 玩家。他们对应 “感染者”；

(3) 疲惫的玩家 $R(t)$ 。他们会有一段时间不玩 Wordle，但过了这段时间可能会重新开始玩。他们对应 “康复者”。

假设 2: 普通玩家 S 有 λ 的概率被感染；在玩家 I 中，他们有 β 的概率对玩 Wordle 感到厌倦并在一段时间内不再玩；在厌倦的玩家 R 中，有 η 的概率受到外部因素的影响而重新开始玩 Wordle。普通玩家 S、玩家 I 和厌倦的玩家 R 都可能有一定 θ 的自然移除概率。




图 7：玩家状态转换

基于上述假设，在设定参数后，可通过求解微分方程拟合玩家数量，再乘以一定比例来计算 Twitter 上的得分报告数量。报告数量的相应拟合曲线如图 8 所示，该曲线与 Prophet 的趋势曲线相符。因此，SIRS 模型可用于解释这种变化的整体趋势。Wordle 于 2022 年 1 月开始流行，玩家数量在 2 月左右达到峰值（报告数量也随之达到峰值）。此后，这款游戏逐渐降温，玩家数量减少，报告数量也随之下降。

3.4 提取词语的属性

为了研究词语属性对挑战性模式报告比例的影响，我们首先需要提取词语的各种有用特性。

1. 一个单词中不同字母的数量（NDLW）

一般来说，一个单词包含的不同字母越少，在尝试中猜对一个字母的概率就越低，谜题也就越难。我们统计了包含不同数量字母的单词的分布情况，以及尝试 5 次及以上的人的平均比例，结果如表 5 所示。从表中可以看出，越少的




图 8: SIRS 模型的拟合曲线

一个单词中不同字母的数量越多，尝试 5 次及以上的人的比例就越高，这表明这个谜题难度更大。因此，单词中不同字母的数量是该单词的一个重要属性。

表 5: 单词中的字母种类及 5 次以上尝试的比例

Different Letters	Number of Words	Proportion of 5+ Tries
3	6	62.50%
4	94	45.10%
5	259	34.90%

2. 单词在日常生活中的使用频率 (Freg)

一般来说，一个词在日常生活中使用得越频繁，人们对它就越熟悉，反之亦然。谜题中不熟悉的词越多，谜题就越难。因此，词在日常生活中的使用频率也是一个重要属性。我们使用来自 Wolfram [4] 的词频数据，该数据是根据谷歌图书数据集计算得出的。

3. 词语在不同领域的使用广度 (BU)

一个单词的使用越广泛，熟悉它的人就越多，反之亦然。人们对谜题中的单词越不熟悉，谜题就越难。一个单词的流行度定义为在 100 个语料库中该单词出现的语料库数量（数据来自《书面和口语英语中的词频》）。

4. 字母使用频率之和 (SLF)

玩 Wordle 游戏时，玩家通常会尝试包含更常见字母的单词以获取更多信息。因此，一个单词中的字母是否常见也是衡量该单词难度的一个重要属性。我们定义 SLF 来描述单词的这一属性：

$$SLF = \sum_{i=1}^5 frequency_i$$

其中，frequency 代表字母 i^{th} 在单词中的出现频率。字母频率数据来自 Algoritmy 网站 [1]。

5. 单词中字母的总和

单词中字母的总和也是该单词的一个属性，因为谜题由五个字母组成，这些字母可以相同也可以不同。

6. 单词的词性

单词的词性是单词最常见的属性之一。

3.5 单词属性对困难模式报告比例的影响

困难模式下报告的比例定义如下：

$$percentage_{hard} = \frac{number_{hard}}{number_{total}}(T)$$

我们基于最小二乘法建立了多元线性回归模型，并使用回归方程的显著性检验，即 F 检验，我们将检验

3.5.1 模型建立

多元线性回归通过以下方程描述因变量 y 与自变量 $x_1,x_2,...,x_m$ 之间的关系：++ 其中， β_0 是常数项。 β_k 是第 k 个自变量的回归系数， ϵ 是随机误差项。我们以 Freq、*SLF*、NDLW、*BU*、单词中字母的总和、单词的词性为自变量，以 $percentage_{hard}$ 为因变量进行多元线性回归。由于所得回归方程较长，其内容包含在附录 A 中。

3.5.2 回归方程的显著性检验

1. 假设构建：

零假设： $H_0:\beta_0=\beta_1=\cdots\beta_m=0$

备择假设： $H_1:\beta_0,\beta_1,\cdots,\beta_m$ 并非都等于 0。

2. 计算 F 统计量：

$$F = \frac{SSR/m}{SSE/(n-m-1)} \sim F(m,n-m-1)$$

其中 $SSR = \sum_{i=1}^n(\hat{y}_i - \bar{y})^2$ 代表回归平方和， $SSE = \sum_{i=1}^n(y_i - \hat{y}_i)^2$ 代表残差平方和。

3. 做出决策 基于给定的显著性水平 $\alpha = 0.05$ ，检验的拒绝域为 $F > F_{\alpha}(m, n - m - 1)$ 。我们建立了一个多元线性回归模型，以词汇属性为自变量，以困难模式下报告的比例为因变量。

回归方程的 F 统计量为 1.058，相应的 P 值为0.379($> \alpha = 0.05$)，表明该回归方程不具有统计显著性。因此，我们得出结论，词汇属性对困难模式下报告的比例没有显著影响。

4 模型 2—— 基于 BP 神经网络的分布预测模型

4.1 BP 模型构建

我们首先对数据进行预处理，将预训练与全局向量模型（GloVe）相结合，并使用主成分分析（PCA）进行降维。词嵌入是一种将词语映射到实值向量的技术，是自然语言处理中的一项基础应用。GloVe 模型是词嵌入模型之一，它采用平方损失，并使词向量与基于整个数据集计算出的全局统计信息相拟合。我们使用来自 GloVe 模型的预训练词向量作为特征。




图 9：实施流程

在处理任务 2 时，我们将从第一个子问题中获得的词属性作为特征的一部分，对其进行标准化处理，并使用主成分分析（PCA）提取主成分。我们将提取出的主成分与通过 GloVe 模型预训练的词向量相结合，将其作为反向传播（BP）神经网络的输入特征。在反向传播神经网络中，我们输入词特征，并将每个词的百分比分布作为标签。我们选取 80% 的数据作为训练集，20% 作为测试集来训练该神经网络并对其进行测试。

性能。由于给定的数据量较小，我们选择建立一个低复杂度网络，该网络包括一个输入层、一个单一隐藏层和一个输出层。隐藏层包含 1024 个隐藏单元，并采用 ReLU 函数作为激活函数。训练过程中使用 Dropout 技术丢弃 50% 的网络单元，以对抗过拟合。选择 L2 范数作为损失函数，反向传播过程中使用 Adam 优化器进行梯度优化，学习率设置为 0.05。采用 Xavier 随机初始化方法。

4.2 BP 的模型不确定性

神经网络具有相当大的随机性，神经网络的 Xavier 方法中的初始化参数是从均匀分布中采样的。此外，dropout 会随机丢弃隐藏层中的神经元。这意味着神经网络的训练结果可能每次都有所不同。为了解决这个问题，我们尝试多次训练模型并选择最佳模型。

模型的输出可能为负值，为解决这一问题，我们选择将负值调整为 0。

由于输出值不能直接用作百分比（因为它们的总和可能超过或低于 100），我们将每个输出除以总和，以获得最终的预测百分比。

4.3 BP 模型评估

测试集上的评估结果如下：

表 6：测试集评估

MAE	MSE	MAPE
3.2302	21.857	32.9194

在测试集上，该神经网络的平均绝对误差（MAE）约为 4，这表明预测值与真实值之间的平均绝对差值为 4，说明该模型具有较高的准确性。其他指标也支持这一结论。

4.4 BP 的模型预测

我们预测了尝试不同时间的人群分布，结果如下。我们有信心误差在 3% 以内。

5 基于 K-Means++ 的难度分类模型

5.1 基于 K-Means++ 的聚类分析。

K-Means 算法是一种无监督学习方法，也是一种基于划分的聚类算法。它通常使用欧氏距离作为度量标准来衡量数据对象之间的相似度，且相似度与数据对象之间的距离成反比。相似度越大，距离越小。该算法需要预先设定初始聚类数量 k 和 k 个初始聚类中心。基于数据对象与聚类中心之间的相似度，算法不断更新聚类中心的位置，并减小聚类的误差平方和（SSE）。当 SSE 没有

Try Times	Percentage(%)
1	0
2	6
3	18
4	29
5	27
6	15
7+	5

表 7：“EERIE” 的预测结果




图 10：“EERIE” 的预测结果

当更长时间的变化发生或目标函数收敛时，聚类结束，并得到最终结果。

“1 次尝试” “2 次尝试” 直至 “7 次及以上尝试” 这些类别很好地反映了谜题的难度。我们将这些变量作为输入，并采用 K-Means++ 算法对词语的难度进行分类。具体过程如下：

步骤 1：确定聚类数量 k 并初始化 k 个聚类中心。

步骤 2：计算数据点与 k 个初始聚类中心之间的欧氏距离，并根据最小距离进行聚类划分，得到 k 个区域。

步骤 3：计算上一步得到的每个聚类的中心位置，并将其用作下一次迭代的聚类中心。

步骤 4：重复上述步骤，直到最后两次聚类结果之间的变化满足精度要求。

图 11 中的肘部法则图结合我们在区分游戏难度方面的经验，用于确定聚类数量。我们选择的聚类数量为 $k = 3$ ，代表三个难度级别：困难、中等和简单。

最后，我们得到了聚类结果，其中聚类 1 包含 135 个单词，聚类 2 包含 156 个单词，聚类 3 包含 68 个单词。各聚类中每个属性的均值和标准差的统计结果如表 8 所示。通过计算每个聚类中尝试次数达到 5 次及以上的尝试所占的平均比例，我们得到了表 9。通过观察表 8 和表 9，我们将聚类 1、聚类 2 和聚类 3 中的单词分别归类为简单、中等和困难。

5.2 单词属性与难度等级的关系

5.2.1 难度级别与 NDLW 之间的关系

图 12 展示了具有不同 NDLW 的单词的难度等级分布，表 10 展示了不同难度等级的 NDLW 所占比例。我们发现，不同字母数量较少的单词所占比例随着难度等级的提高而增加。在本研究提供的数据集中，有 6 个单词仅包含 3 个不同的字母。




图 11: K 值优化

表 8: 不同类别的 K-means 聚类结果及显著性检验

	Cluster Categories (means $\pm$ sd)			F-value	P-value
	1 (n=135)	2 (n=156)	3 (n=68)		
1 try	0.8 $\pm$ 1.057	0.269 $\pm$ 0.459	0.279 $\pm$ 0.452	21.307	0.000***
2 tries	9.459 $\pm$ 4.168	4.013 $\pm$ 1.749	2.868 $\pm$ 1.962	168.146	0.000***
3 tries	30.748 $\pm$ 3.81	20.212 $\pm$ 3.516	12.574 $\pm$ 4.108	594.862	0.000***
4 tries	33.637 $\pm$ 3.824	35.487 $\pm$ 3.819	25.647 $\pm$ 4.485	150.08	0.000***
5 tries	17.807 $\pm$ 3.159	26.436 $\pm$ 3.115	28.794 $\pm$ 5.732	268.933	0.000***
6 tries	6.43 $\pm$ 2.261	11.596 $\pm$ 3.05	21.662 $\pm$ 4.188	565.646	0.000***
7+ tries (X)	1.081 $\pm$ 0.931	1.974 $\pm$ 1.169	8.132 $\pm$ 7.035	119.123	0.000***

表 9: 不同类别的 5 次及以上尝试的平均比例

Cluster categories	Average Proportion of 5+ tries
Cluster 1	25.35%
Cluster 2	39.92%
Cluster 3	58.59%

表 10: 不同难度级别下 NDLW 的比例

Cluster Categories	Proportion of NDLW		
	5	4	3
Easy	90.78%	9.22%	0%
Medium	63.13%	35.63%	1.24%
Hard	52.94%	41.18%	5.88%




图 12: 难度等级与 NDLW 的关系

其中两个被归类为中等难度，即 “motto” 和 “madam”，另外四个被归类为困难，即 “fluff”、“mummy”、“cacao” 和 “vivid”。基于上述分析，我们有充分的证据表明，一个单词包含的不同字母越少，就越难猜测。

料网

5.2.2 难度级别与 SLF 之间的关系




图 13: 难度等级与 NDLW 的关系

不同难度级别单词的 SLF 分布如图 13 和表 11 所示。我们主要关注 SLF 小于 0.2 和大于 0.4 的部分，因为这部分反映了难度级别与大多数字母频率总和之间的关系。可以观察到，随着难度级别的提高，SLF 小于 0.2 的单词所占比例会上升，而 SLF 大于 0.4 的单词所占比例会下降。这意味着，一个单词中常用字母越多，就越容易被猜到，反之亦然。

5.2.3 难度级别与 BU 及 Freq 之间的关系

表 12 显示了不同难度级别下词汇广度的分布情况。词汇广度的定义是一个词汇在 100 个语料库中出现的语料库数量。

表 11: SLF 在不同难度级别中的分布

Cluster Categories	Proportion of SLF		
	< 0.2	0.2-0.4	> 0.4
Easy	2.84%	86.52%	10.64%
Medium	10%	85.63%	4.37%
Hard	13.24%	85.29%	1.47%

语料库，其取值为 0 到 100 之间的整数。该表格表明，一个单词在不同领域中使用得越广泛，相应的谜题就越简单，反之亦然。

同时，我们试图找出一个单词的难度等级与其在日常生活中的使用频率之间的关系。尽管不同难度等级的平均频率存在差异，但平均值对异常值较为敏感。因此，我们首先按频率对单词进行排序，然后用直方图展示它们的分布情况，如图 14 所示。最终，我们发现难度等级与日常生活中的使用频率之间没有显著关系，因为不同难度等级的单词频率分布相当均匀。

表 12: BU 在不同难度级别中的分布

Cluster Categories	BU		
	0-33.33	33.33-66.66	66.66-100
Easy	9.93%	12.77%	77.30%
Medium	19.38%	21.87%	58.75%
Hard	22.06%	26.47%	51.47%




图 14: 难度级别与频率的关系

5.3 关于模型分类准确性的主成分分析讨论

关于模型分类准确率的讨论可以分为两部分。第一部分是每个聚类中的词语之间是否存在显著的难度差异，第二部分是 K-Means 聚类的有效性。如前所述，在第一部分中，

每个聚类的词语中，尝试次数达到 5 次及以上的平均占比分别为 25.35%、39.92% 和 58.59%，这表明不同聚类之间存在显著的难度差异。

关于第二部分，我们对 “1 次尝试”、“2 次尝试” 至 “7 次及以上尝试” 等七个特征进行了主成分分析（PCA）。我们发现前两个主成分解释的方差达到 82.88%(> 80%)。因此，我们采用前两个主成分绘制散点图，如图 15 所示。从该散点图可以明显看出，这些词语区分度良好，K-Means 聚类效果较佳。




图 15：模型分类准确率的主成分分析（PCA）

从评估指标的角度，我们将 K-Means++ 与其他聚类方法（如围绕中心点划分（PAM）和高斯混合模型（GMM））进行了比较，结果如表 13 所示。从比较结果可以看出，K-Means++ 具有更好的聚类效果。

表 13：模型评估

Model	Silhouette Coefficient	CH Score
K-Means++	0.372	309.326
PAM	0.347	303.049
GMM	0.347	291.637

5.4 确定 “EERIE” 的难度等级

根据第二个问题的结果，我们得到了 EERIE 的相关百分比（1、2、3、4、5、6、X）的分布，即 [0, 6, 18, 29, 27, 15, 5]。将该分布输入我们的模型后，我们确定 “EERIE” 的难度等级为 “中等”。

6 有趣的意外发现

6.1 这些单词真的那么难吗？

将单词按难度等级分类后，我们发现 “mummy” 一词的难度等级为 “困难”。当我们计算 “尝试过 5 次或更多次” 的单词所占比例并按降序排列时，惊讶地发现 “mummy” 在难度排名中位居第二，有 82% 的人尝试了 5 次或更多次。由于我们从小就熟悉 “mummy” 这个单词，主观上认为它是一个简单的单词，因此相反的结果更令人惊讶。此外，其他类似的单词还包括 “watch” “catch” “prize” 等。事实上，这证实了我们的观点，即 “单词的出现频率和难度等级之间没有显著的关系”。

6.2 哪个首字母对谜底词构成最大挑战？

我们使用假设检验来确定哪个首字母会构成最难的文字谜题。首先，我们统计所有单词中每个首字母的出现频率。接下来，我们将单词的难度系数定义为 “5 次尝试” “6 次尝试” 和 “7 次或更多尝试 (X)” 这几个类别的总和，并计算所有单词的难度系数。在对难度系数进行排序并选出最困难的前 20% 的单词后，我们统计这些单词的首字母。然后，我们计算每个字母成为进入最困难前 20% 名单的单词首字母的概率。部分结果如表 14 所示。

假设一个以特定字母开头的单词进入前 20% 最难列表的概率为 0.2，即

$$H_0 : p = 0.2$$

(10)

设 n 为该字母作为首字母出现的总次数， k 为该字母作为首字母出现在进入最困难的前 20% 列表的单词中的次数。则我们有

$$k \sim B(n, 0.2)$$

(11)

由于 n 和 k 都是已知的，我们可以计算出这种情况发生的概率 P 。取显著性水平 α 为 0.05，当 $P < \alpha = 0.05$ 时，我们拒绝原假设，认为 p 不等于 0.2。我们已经计算了所有字母的 P 值，并按升序排列。部分结果如表 15 所示。

根据表 15，对于字母 e、s、f、w 和 a，它们相应的 P 值较小。

表 14：首字母与难度的关系

the First Letter	Total	Hard(20%)	Easy(20%)	Hard Rate	Easy Rate
a	28	2	5	0.071	0.179
b	20	4	3	0.200	0.150
c	33	7	10	0.212	0.303
d	12	4	5	0.333	0.418
e	10	6	0	0.600	0.000
f	22	8	2	0.364	0.091
g	17	5	1	0.294	0.059
h	11	4	2	0.364	0.182
...	...	...	...	...	...

表 15：难词首字母统计

the First Letter	Total	Hard(20%)	Hard rate	P value
e	10	6	0.6	0.006
s	51	4	0.078	0.011
f	22	8	0.364	0.036
w	11	5	0.455	0.039
a	28	2	0.071	0.046
r	13	0	0	0.055
t	30	3	0.1	0.079
...	...	...	...	...

小于 0.05，因此 $p \neq 0.2$ 具有显著性。以字母 e、f 和 w 开头的单词的困难率大于 0.2。因此，我们有充分的理由相信，以 e、f 和 w 开头的单词是较难的，其中以 e 开头的单词最难。同样地，我们可以发现，字母 t 作为首字母时对应的单词最容易。具体数据可参见表 16。

表 16：简单词汇首字母统计

The first letter	Total	Easy(20%)	Easy rate	P value
t	30	16	0.533	0
d	12	5	0.417	0.053
c	33	10	0.303	0.056
s	51	13	0.255	0.081
...	...	...	...	...

6.3 哪些单词能让 Wordle 持续受欢迎？

向上突变点表示本应下降的趋势突然上升。这可能意味着与该向上突变点对应的词语更有可能刺激人们之间的交流和传播，从而导致当天的报道数量增加。为了检测向上突变点，我们首先使用孤立森林算法检测所有突变点，然后利用一阶差分的正负性来寻找向上突变点。同时，我们计算了突变率，并选择突变率大于 5% 的突变点作为最终的突变点。结果如下表所示。

Date	Word	Date	Word	Date	Word
2022/2/8	frame	2022/3/18	saute	2022/4/18	flair
2022/2/15	aroma	2022/3/21	their	2022/4/22	plant
2022/2/17	shake	2022/3/24	chest	2022/4/26	heist
2022/2/19	swill	2022/3/27	nymph	2022/4/29	tarsh
2022/2/22	thorn	2022/3/30	stove	2022/5/2	story
2022/3/2	nasty	2022/4/1	snout	2022/5/4	train
2022/3/5	brine	2022/4/2	trope	2022/5/9	shine
2022/3/11	watch	2022/4/8	scare	2022/5/11	farce
2022/3/15	tease	2022/4/13	chunk	2022/12/26	judge




图 16: 敏感性分析

《纽约时报》或许可以从这些热词词汇的特点中汲取灵感，以增强 Wordle 的趣味性。

资料网

7 敏感性分析




图 17: 敏感性分析

在改进 BP 神经网络模型时，我们使用随机森林模型对三次尝试的结果进行回归分析。我们选择参数 $n_{estimators}$ （弱评估器数量）、 $max_{features}$ （最大采样特征数）、 $max_{samples}$ （随机采样的最大样本量）和 max_{depth} （树的最大深度）进行敏感性分析。在每个参数分析中，我们只改变该参数，同时保持其他参

参数采用默认值。我们在数据集上进行了 5 折交叉验证，并将训练集和测试集上的均方根误差（RMSE）的平均值作为每个参数值的结果。如图 17 所示，随着参数值的增加，训练集和测试集上的均方根误差逐渐减小并趋于稳定。不同参数变化情况下的均方根误差稳定在 6.60 左右。这表明该模型对参数变化不敏感，且相对稳定。

8 模型评估

8.1 优势

1. Prophet 模型考虑了节假日对时间序列的影响，且模型参数具有更强的可解释性，这有助于我们理解报告数量的变化。
2. SIRS 模型对 Prophet 模型的趋势项具有出色的解释力。
3. BP 神经网络具有输出多个目标的能力，且不需要为每个目标单独建立模型。
4. K-Means++ 模型具有简单实用的特点，适用于本题的数据集。

8.2 不足之处

1. Prophet 模型在长期预测方面存在一定不足，这在某种程度上与传统的时间序列模型类似。
2. BP 神经网络的参数在初始化时具有随机性，训练后的模型也包含这种随机性，这意味着在某些情况下，模型的输出结果并不总是唯一值。
3. 尽管我们正努力寻找与谜题难度相关的词汇属性，但仍可能存在一些我们忽略的词汇属性。

参考文献

[1] Algoritmy.net. 英语字母频率，获取于 2023 年 2 月 18 日。

[2] 史蒂文·伯德、伊万·克莱因和爱德华·洛珀。《Python 自然语言处理》。奥莱利媒体出版社，2009 年。

[3] 肖恩·J·泰勒和本杰明·莱瑟姆。大规模预测。《美国统计学家》，第 0-0 页，2017 年。

[4] Wolfram.com。单词频率数据，访问日期：2023 年 2 月 18 日。

尊敬的先生或女士：

经过数据分析和建模后，我们很荣幸能呈现关于 Wordle 的报告数量及单词难度的分析。我们相信，我们这些有趣的发现将会对您有所帮助。以下是我们的一些理论分析和数值预测。

1. 报告数量将略有下降，但随后会再次上升。玩游戏的过程就像一种感染，人们在喜欢之后总会感到厌倦，厌倦之后又会再次喜欢。玩家数量就像一条感染曲线，随着时间的推移而增加，达到顶峰后逐渐下降。此外，在节假日和周末期间，报告数量往往会减少，导致曲线出现小幅波动。根据我们的模型，在 2023 年 3 月 1 日，报告数量将降至 (10,452, 21,454) 的范围 (95% 置信水平)。尽管如此，之后它还会上升。

2. 没有任何单词属性会影响在困难模式下进行的游戏所报告的分数比例。通过拟合得到的多元线性回归模型显示，决定系数 (R 平方值) 仅为 0.129。相应地，p 值为 0.379，远大于 0.05。这表明单词属性与困难模式报告的比例之间几乎不存在相关性。这是合理的，因为在开始游戏前，没有人知道会出现什么单词，因此，单词的属性不会影响玩家是否选择在困难模式下进行游戏。

3. 我们可以根据单词的属性更准确地预测答题尝试次数的分布。通过训练 BP 神经网络模型，我们能够基于单词的属性掌握其答对率。例如，对于单词 “EERIE”，尝试答题的人数分布应该如下：0% 的人一次通过，6% 的人两次通过，22% 的人三次通过，32% 的人四次通过，23% 的人五次通过，12% 的人六次通过，4% 的人未能通过。我们有信心将误差范围控制在 3% 以内。

4. 导致猜词难度的属性可能与你想象的不同。通过 K-means++ 聚类，我们根据成功尝试的比例将单词难度分为三个等级，并分析了难度与单词属性之间的关系。结合前面提到的神经网络模型，我们可以根据单词的属性直接判断其难度。人们可能会认为猜词的难度与单词的使用频率有关，但事实上，这是不正确的。在 Wordle 中，猜词的难度与单词中字母的多样性、每个字母的使用频率之和以及其在不同领域的使用广度有关。根据我们的分析，“EERIE” 一词应被归类为中等难度。K-means++ 模型的表现优于其他类似模型，从而提高了我们结果的可信度。

接下来，我们将介绍一些有趣的发现：我们敢打赌，你从未想过 “mummy” 是第二难猜的单词！多达 82% 的玩家需要尝试五次或更多次才能猜中它。其他类似的单词包括 “watch” “catch” “prize” 等等。这是因为猜测一个单词的难度与其首字母有关，例如，以 “e” “s” “f” “w” 和 “a” 开头的单词更难猜，而以 “t” 开头的单词则更容易猜。你可以尝试利用这些有趣的特点来设计游戏。

这些都是我们团队为贵公司提供的建议和策略。感谢您宝贵的时间。希望我们的模型和这些结论能对您有所帮助！

此致，
敬礼！

MCM 团队成员

附录

附录 A 回归方程

以下是 3.5.1 中提到的回归方程

$$\begin{aligned} \hat{y} = & 0.045 - 8.696 \textit{Freq} + 0.007 \textit{SLF} - 0.003 \textit{NDLW} + 0.008 \textit{a} \\ & + 0.007 \textit{b} + 0.006 \textit{c} + 0.009 \textit{d} + 0.010 \textit{e} + 0.010 \textit{f} + 0.008 \textit{g} \\ & + 0.007 \textit{h} + 0.010 \textit{i} + 0.027 \textit{j} + 0.003 \textit{k} + 0.006 \textit{l} + 0.007 \textit{m} \\ & + 0.006 \textit{n} + 0.005 \textit{o} + 0.007 \textit{p} + 0.007 \textit{q} + 0.004 \textit{r} + 0.004 \textit{s} \\ & + 0.008 \textit{t} + 0.009 \textit{u} + 0.010 \textit{v} + 0.005 \textit{w} + 0.011 \textit{x} + 0.010 \textit{y} \\ & + 0.022 \textit{z} + 0.016 \textit{VBG} - 0.020 \textit{VB} - 0.016 \textit{CC} + 0.008 \textit{JJ} \\ & + 0.019 \textit{VBZ} + 0.019 \textit{VBN} + 0.016 \textit{VBD} - 0.010 \textit{MD} \\ & + 0.008 \textit{NN} + 0.010 \textit{NNS} + 0.014 \textit{RBR} + 0.012 \textit{VBP} \\ & - 0.008 \textit{JJS} - 0.007 \textit{JJR} + 0.003 \textit{PRP} - 0.019 \textit{DT} \\ & R^2 = 0.129, N = 359 \end{aligned}$$

(12)