

基于微分方程和 K 近邻的 Wordle 病毒式传播特征及难度决定因素建模

最近，一款名为 Wordle 的益智游戏在全球范围内广泛传播，并在 Twitter 等社交媒体上引发了极高的讨论度。了解 Wordle 热潮的传播机制以及影响该游戏难度的因素，或许能为理解互联网时代的病毒式传播以及人类大脑的词汇联想方式等重要问题提供一些启示。

我们基于 SIR 模型开发了一个类流行病学微分方程模型，用于描述报告总数的变化，并使用遗传算法对模型进行拟合以最小化均方误差（MSE）。随后，我们利用拟合后的模型对 2023 年 3 月 1 日的报告总数进行了点预测。为获得预测的置信区间，我们采用了自助法（Bootstrap）。为提高自助样本的拟合速度，我们使用了计算速度更快的 Nelder-Mead 方法，其初始参数基于遗传算法优化得到。我们将 1000 个自助估计值按从小到大排序，选取第 25 个和第 975 个估计值作为预测区间的下限和上限。

本文构建了两个典型的词汇内部特征。通过假设英语词汇中字符出现概率的一阶马尔可夫性，我们定义了规律性和纯度（负熵）特征。所有迹象都表明，这些特征确实与词汇被猜测的难度有关。本文还使用了诸如重复字符的数量和词汇在日常生活中的使用频率等规律性特征来进行预测和解释。

KNN 回归具有确保预测分布仍总和为零的优良特性，因此我们使用 KNN 回归模型来预测 Wordle 分数的分布。本文中广泛使用协方差矩阵进行变量的初步选择和确定变量之间的关系。在 KNN 回归中，我们利用协方差矩阵选择与分布显著相关的自变量，并通过交叉验证来选择最优的自变量和 K 值。为了预测特定谜题词未来的分数分布，我们再次使用自助法来获取 95% 的置信区间。

我们使用 Wordle 玩家的中位数得分来衡量谜题中单词的难度，将难度分为“简单”、“普通”和“困难”三类。我们首先基于协方差矩阵筛选出与难度显著相关的特征，使用 KNN 分类器对初步筛选出的特征进行分类，并在交叉验证后选择预测准确率最高的 K 值。结果表明，这些特征能够有效预测单词的难度分类。在单词难度预测方面，我们使用 KNN 分类器和我们建立的与难度相关的特征，将单词归入现有的类别中。

在对数据的进一步探索中，我们最重要的发现是，“困难模式”百分比的变化与我们最初构建的类 contagion 模型中假设的忠实玩家的变化高度相似，这在一定程度上证实了我们模型的合理性。

目录

第 2 封信

1 引言 11 背景和问题陈述.....44

2 建模准备 55

. 5

6

3 词特征工程 6

6789

3.2 纯度.....

竞赛资料网

...

...

3.5 特征生成.....9

4 报告结果数量建模 9

4.1 直觉：趋势中有什么.....9

4.2 术语和假设 43 从 SIR 模型到我们的问题模型 4.2.1 术语.....4.2.2 假设.....: ...10

4.3.1 SIR 模型回顾.....11...11

5 词本身是否影响困难模式比例 13

5.1 似乎是真的 5.2 很可能不是真的.....5

6 预测分数分布.....16 15

. .

63 预测和提升.....

7 难度分类

20

.....20

8 其他有趣见解 21

参考文献 24

信函

致：《纽约时报》谜题编辑

发件人：2307166 团队

日期：2023 年 2 月 1 日

主题：回复：关于我们的解谜游戏《沃德乐》

尊敬的编辑：

感谢您来信咨询关于您那款知名的 Wordle 游戏的相关信息。考虑到它是一款在全球广受欢迎的益智游戏，对其流行趋势、传播机制以及单词难度的分析，不仅对贵公司很重要，对了解整体互联网趋势的传播以及人类语言也具有重要意义。

首先，Twitter 上上传的 Wordle 游戏得分数量与传统的疫情传播模型非常契合；不同之处在于，疫情患者最终会失去传播能力，而一部分 Wordle 玩家会成为资深玩家，继续玩 Wordle 并传播相关信息。如果 Twitter 上的结果数量能真实反映 Wordle 的热度，那么我们这类流行病学模型告诉我们，Wordle 已经进入了其生命周期的尾声或平台期；例如，我们预测在 95% 的置信水平下，2023 年 3 月 1 日的报告数量会落在 [11173.04,17069.15] 这个区间内；从该模型中我们得知，要想维持其传播能力，应该扩大用户基础 —— 当然，这并非易事；或者可以尝试提高忠实用户的粘性，以延续游戏的生命周期：比如通过增加特别活动来培养用户习惯，减缓老用户的流失。

关于你提到的困难模式玩家比例问题，我们得出的结论是，单词的属性并不会影响这一比例。因为玩家在每天尝试游戏之前，本不应知晓当日单词的相关信息；而且在我们的模型中，忠实玩家的演变趋势与这一比例的走向相似，这可能意味着该比例的变化仅能通过游戏的生命周期来解释。或许有些团队认为某些特定的难度指标与这一比例相关，但这很可能是因为这些特征随着时间推移存在整体趋势，困难模式玩家的比例也是如此，因此像回归分析这样的统计工具可能会错误地将这种随时间变化的趋势误认为是两者之间的直接关系。

您还要求我们预测特定日期和特定词语的结果分布。根据我们的实验，考虑日期因素的效果并不显著，因此我们仅使用词语信息：我们将若干与您希望预测的词语相似的词语的结果分布取平均值，以此作为预测结果。取平均值的词语的确切数量以及评估相似性的因素如何选择，是由机器通过一些测试方法确定的。假设推文数据具有代表性，我们通过一些特殊的统计方法来确定预测区间。例如，我们对 “EERIE” 这个词的分布估计是 (0.20 4.87 23.55 35.36 23.75 9.94 2.33)。预测区间大约在预测值上下 5% 左右，具体取决于尝试的次数。我们预测中的不确定性主要在于我们没有处理玩家结构的变化 —— 根据我们的类流行病学模型，忠诚玩家的比例可能会上升，这

半个月后可能会对相同单词的尝试次数做出调整。

我们认为，人们猜测单词的次数分布是衡量一个单词难度的重要指标。因此，我们将单词难度相应地分为三类：简单、中等和困难。通过采用与上一段类似的方法，我们可以预测新单词的难度；例如，我们认为 EERIE 属于中等难度。重复字母的数量、加权纯度和加权规律性与难度评级相关，其中前两者呈正相关，后两者呈负相关。后两者是我们设计的用于衡量单词难度属性的统计指标。

除了您之前感兴趣的问题外，还有一些其他见解可能对您有用：

我们发现挑战模式报告的比例呈现出上升的时间趋势，这与我们在上一节中用于预测报告总数的模型中所确立的存在忠实玩家这一假设是一致的。事实上，挑战模式报告比例的时间趋势与我们假设的忠实玩家比例的时间趋势高度相似，我们有理由相信挑战模式报告比例与忠实玩家数量之间存在一定的相关性，这意味着你可以通过观察挑战模式报告比例的趋势来确定 Wordle 忠实玩家比例的变化，从而优化你的商业策略。

我们还发现，Wordle 玩家的得分分布与游戏难度存在一定规律：首次到第三次尝试成功猜对的比例与难度等级呈负相关，而第四次到第七次及以上尝试成功猜对的比例则与难度等级呈正相关。你可以通过观察玩家的得分分布变化来总结 Wordle 难度的变化情况。

选择带有重复字母的单词作为 Wordle 答案，会显著降低玩家在第一次尝试时就猜中答案的可能性，这可能与玩家通常选择使用不含重复字母的策略作为初始猜测有关。如果你想降低游戏难度以吸引更多玩家，可以在游戏时提示单词中重复字母的数量，从而提高玩家猜中谜题的可能性。

顺祝商祺，

像团队 #2307166

1 引言

1.1 背景与问题重述

Wordle 是一款拼图游戏，玩家需在六次或更少的尝试中猜出一个五个字母的单词来解开谜题，每次猜测都会收到反馈。其流程如图 1 所示。

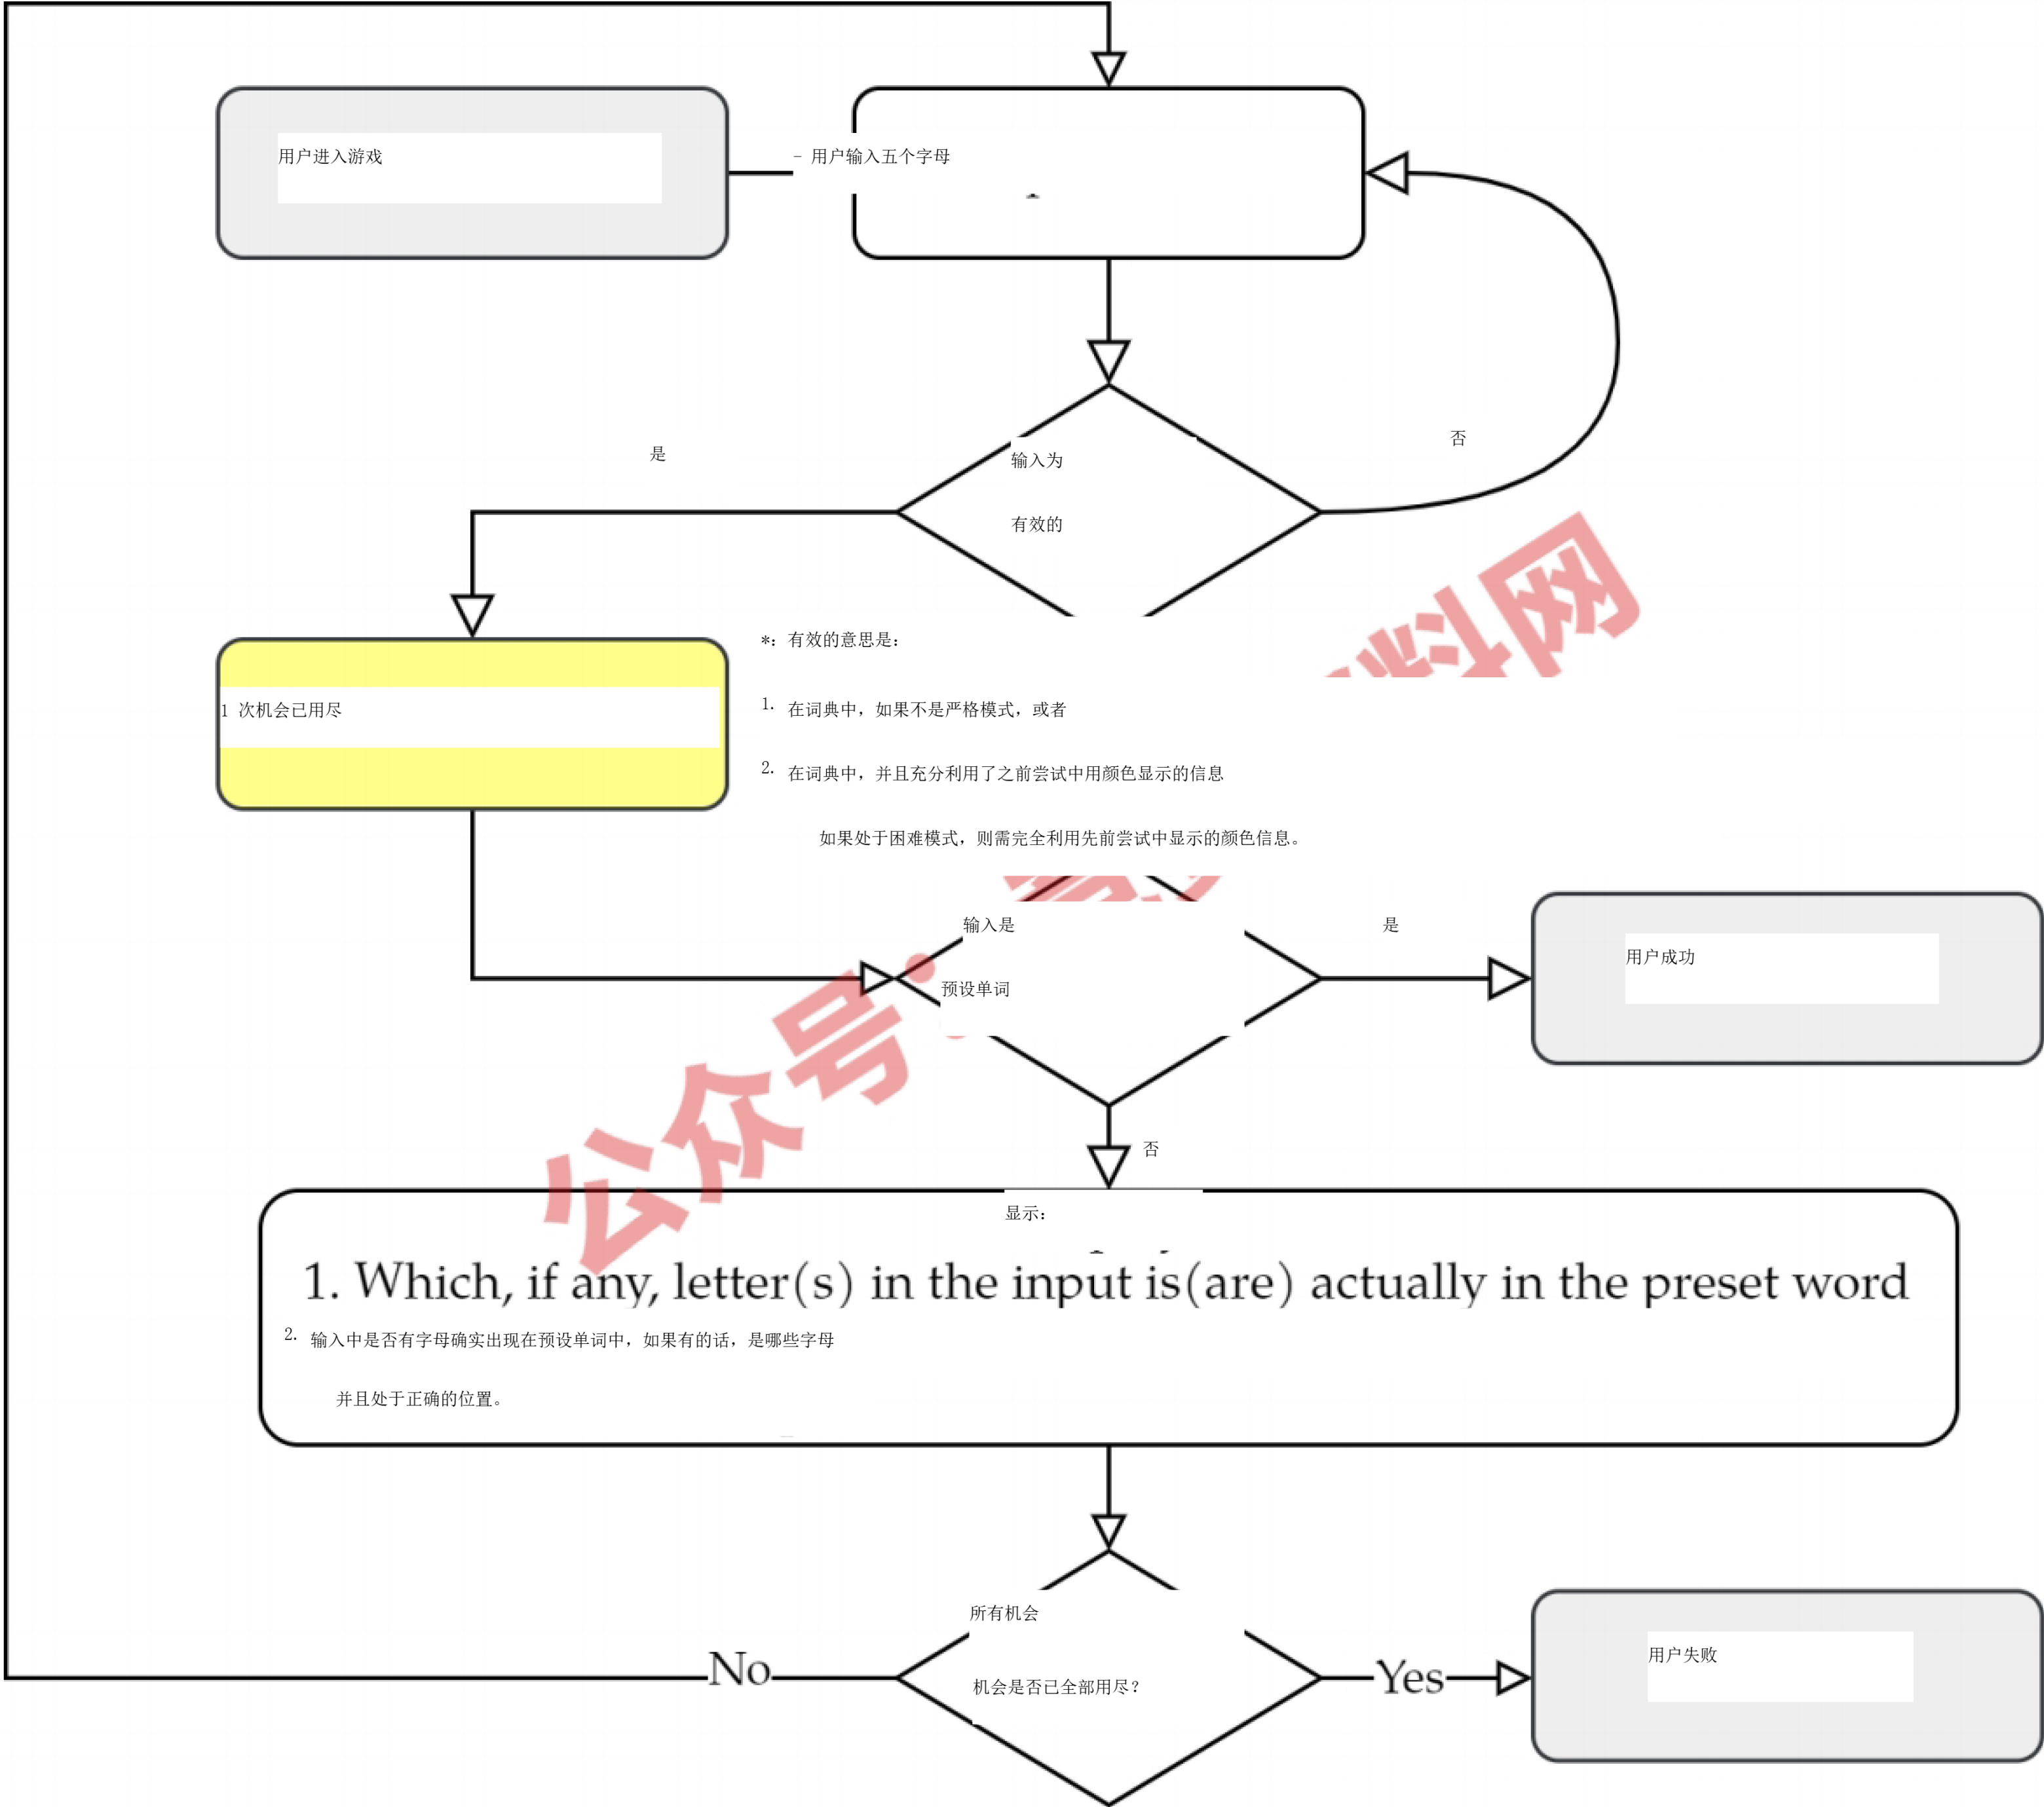


图 1: Wordle 流程图

我们受雇于《纽约时报》，仅使用他们提供的数据来分析和回答以下问题。

问题 1 问题 1 包含两个子问题:

1. 日期和其他因素如何影响报告结果的数量？如果给出特定日期，如何预测报告结果的数量？（需要预测区间）

2. 单词本身的任何属性是否会影响在困难模式下进行的评分报告的百分比？（需要进行机制分析）

问题 2: 如果给定特定日期和谜底词, 如何预测尝试次数的分布? 哪些可能影响结果的因素可能被忽略? (需要预测区间或对预测模型的预测能力进行分析)

问题 3 如何衡量难度? 如何根据难度将答案词分为不同的组别? 每个组别中的词有什么特征? 如何对新的答案词进行分类? (需要分析分类模型的预测能力)

问题 4 找出数据集中有趣的特征!

2 建模准备

2.1 假设

主要假设如下:

给定数据中的英文单词属于英语词汇, 因此与词典中的其他英语单词具有一些共同的概率特征。

玩家更喜欢通用性的词, 那些看起来像有效英语单词的词更容易被记住, 也更优先被尝试使用。

Mode-specific assumptions will be presented in subsequent sections

2.2 符号说明

本文中使用的符号列于表 1 中。

表 1: 符号说明

Symbol	Definition
w_i	word i
c_i	character i
$c_{i,j}$	j-th character in word i
T_i	transition process i
$\text{Reg}(w_i)$	regularity of word i
$\text{Irr}(w_i)$	irregularity of word i
$\text{Pur}(w_i)$	purity of word

2.3 数据清洗

在检查数据集时，我们发现了两种类型的异常值：长度不是 5 的单词，以及总数异常少的报告。异常数据的详情如下。

Date	Contest number	Word	Number of reported results
2022/12/16	545	rprobe	22853
2022/11/26	525	clen	26381
2022/4/29	314	tash	106652
2022/11/30	529	study	2569

为确保数据的准确性，我们选择移除异常数据，而非进行修正和插值。

对于 KNN 回归和分类，为避免量纲对观测值间距离计算的影响，我们根据以下公式对数据进行了标准化。

$$x_{ij}^* = \frac{x_{ij} - \bar{x}}{sd(X_j)},$$

其中， x_{ij} 是准则 j 的第 i 个观测值， X_j 是准则 j 的所有观测值， x_{ij}^* 是归一化数据。归一化数据的均值为 0，方差为 1。

3 词特征工程

3.1 规律性

在英语中，有效的单词通常具有规律的形式模式，人类很难捕捉和形式化这些模式，但这会影响人们玩 Wordle 时的选择，因为那些有规律的单词可能对英语使用者来说更熟悉。

假设每个字符的概率分布仅由其在单词中的前一个字符决定，我们尝试用一种类二元语法 [1] 链来建模这一过程，该模型用于估计在已知单词中前一个字符的情况下，某个字符出现的可能性；为了利用单词首尾的信息，我们在单词的开头和结尾分别设置了两个虚拟字符 BOW 和 EOW，如图 2 所示。

规律性被定义为每个字符向其后继字符转移过程的概率的几何平均值，如公式所述。

$$\text{Reg}(w_i) = \sqrt[n]{\prod_{j=1}^n P(c_{i,j} | c_{i,j-1})},$$




图 2：虚拟角色及转换过程

其中， $P(c_i|c_{i-1})$ （在本文中有时也表示为 $P(T_i)$ ）用于表示从字符 $i-1$ 转换到字符 i 的可能性。

3.2 纯度

如果已知单词中的一个字符，我们能获得多少关于它后一个字符的信息？这在 Wordle 中是一个重要因素，因为游戏的反馈会告诉我们所猜的字母是否真的在当日的单词中，所以如果后一个字符更难预测，解开这个谜题就会更困难。

字符 c_i 的纯度定义如下：

$$\text{Pur}(c_i) = \sum_{j=1}^n P(c_{i+1} | c_i) \log(P(c_{i+1} | c_i)),$$

也就是说， $-\text{Entro}(c_{i+1})$ ，并且基于 3.1 节中的假设，即每个字符的概率分布仅由其在单词中的前一个字符决定。

一个字符的纯度越高，从该字符推断出的下一个字符的数量就越少，某些特定字符出现的概率就越高。换句话说，猜对下一个字符的概率更大，即下一个字符的不确定性更小，如图 3 所示。这些概率和纯度是从bestwordlist.com[6] 的 5 个字母的单词中生成的，没有进行任何频率加权。

单词 i 的纯度定义如下：

$$w_i = \sum_{j=1}^n \text{Pur}(c_{i,j}).$$




图 3: 纯度与后续字符

3.3 重复

单词的重复指数包含两个指标：重复字母的数量和重复字母的最大出现次数。重复字母指的是在一个单词中出现次数大于或等于 2 次的字母。重复字母的数量是指一个单词中重复字母的个数。例如，在“apple”中，除了“p”之外没有其它重复字母，所以“apple”的重复字母数量为 1；而在“cacao”中，“c”和“a”都是重复字母，所以“cacao”的重复字母数量为 2。重复字母的最大出现次数是指一个单词中重复字母的最大出现次数。例如，在“mummy”中，“m”出现了 3 次，所以“mummy”中重复字母的最大出现次数为 3；在“cacao”中，“c”和“a”都出现了 2 次，所以“cacao”中重复字母的最大出现次数为 2；而对于没有重复字母的单词，其重复字母的最大出现次数为 0。

单词重复对 Wordle 难度的影响是显而易见的：Wordle 只会提供关于答案单词是否包含输入的字母以及该字母是否处于正确位置的信息，而不会告知该字母是否重复或重复的次数。如果答案单词包含重复的字母，可能会误导玩家尝试其他字母，从而增加尝试次数，使 Wordle 变得更

这很困难。同时，如果重复的字母重复次数更多，Wordle 提供的关于答案词的信息会进一步减少，从而再次增加 Wordle 的难度。

3.4 频率

一个合理的假设是，人们会优先想到可用词汇空间中他们最熟悉的那些词，无论选择是否受到可用信息的限制，因此日常使用中的词频对于评估词汇难度和预测尝试分布来说都是一个值得考虑的因素。

3.5 特征生成

在词频方面，我们直接使用了戴夫·赫米特的词频列表 [2]，其语料来源是电影字幕。

Regularity 是在bestwordlist.com[6] 的 5 字母单词列表上训练的；生成了一个频率加权版本和一个非加权版本；值得注意的是，在训练加权版本时，使用了对数函数以避免浮点下溢，因此将零频率设置为 1 以避免计算问题。

Purity 是通过与 Regularity 相似的方法，在某个单词列表上训练的。

4 报告结果数量建模

4.1 直觉：趋势中包含什么

为了全面了解报告结果数量的变化情况，我们手动分析了其趋势，并得出了一些简单的结论。

首先，肉眼可见的趋势中不存在周期性。考虑到小游戏的特点，周频率周期性是可能存在的，但我们在使用 F 检验时，并未发现周频率下存在周期性。

整体趋势包括一段相对陡峭的上升部分和一段长尾下降部分，且序列相当平滑。

这些特性太过明显，不容忽视。这一趋势符合疾病流行中受感染人数典型序列的形态。从机制上讲，玩 Wordle 并分享分数这一行为的传播可能具有很强的病毒性，因此我们采用类似流行病学的方法来模拟这一过程。




图 4：报告分数的数量及我们模型的拟合曲线

4.2 术语和假设

4.2.1 术语

s

TP 推特分享游戏：玩《Wordle》并在推特上分享的行为；

TP 者：选择进行 TP 的人。

4.2.2 假设

行为的一致性：TP 者每天都进行 TP，而非 TP 者（包括那些从 TP 者转变而来的人）从不进行 TP。

病毒式营销中，非 TPers 转化为 TPers 的概率取决于他们可能接触到的 TPers 数量。

潜在客户：虽然一些非 TP 用户有可能转变为 TP 用户，但其他非 TP 用户可能无法成为 TP 用户。本节中，初始潜在客户数量用 N 表示。

不回头：由 TP 用户转变而来的非 TP 用户将永远不会再次成为 TP 用户。

4.3 从 SIR 模型到我们的 PCQL 模型

4.3.1 SIR 模型回顾

一个基本的 SIR 模型由一个四阶微分方程组成 [3]：

$$\frac{dK(t)}{dt} = \gamma \times I(t),$$

其中，S 代表易感人群；I 代表感染人群；R 代表康复人群。这与我们的问题非常契合，因为我们可以将 S 视为目标客户，I 视为分数分享者，R 视为那些尝试过这种行为但已经厌倦的人。

然而，这与流行病仍有一些不同之处，尽管大多数分享分数的玩家可能只是在追赶潮流，但并非所有分享分数的人都能很快 “痊愈”；有些分享分数的人会养成习惯，将玩游戏和分享分数视为日常任务。因此，我们打算在 SIR 模型中添加一些新内容。

4.3.2 我们的 PCQL 模型

我们的 PCQL 模型是一个具有 4 个变量和 4 个参数的常微分方程（ODE）模型，具体如下：

变量 P（潜力人群）：可能成为 TP 用户的人群，有机会成为 Crotd。

变量 C（群体）指的是普通的临时参与者，他们很快就会感到厌倦；其中一部分人每天要么会退出，要么会成为忠实参与者。

变量 Q（退出者）：那些对游戏或上传分数感到厌倦的人。

变量 L（oyal，忠诚）：那些不会轻易放弃 TP 的人。

参数 β （参与因子）（参与指参与 TP），表示 TP 对潜在用户的吸引力，在时刻 t 的单位时间内吸引并参与的人数为 $\beta \times P(t) \times (C(t) + L(t))$

参数 r （厌倦系数）表示被吸引参与 TP 的人对 TP 产生厌倦的速率，在时刻 t 的单位时间内，曾经是 TP 参与者的人变成退出者的数量为 $\gamma \times C(t)$ 。

参数 λ （转换因子）表示普通 TPers 转变为忠诚 TPers 的可能性；在时刻 t ，单位时间内转变为忠诚 TPers 的 TPers 数量为 $\lambda \times C(t)$ 。

参数 ϕ （忠诚玩家厌倦系数）表示 Wordle 的忠诚 TP 玩家对 TP 产生厌倦的速率，在时刻 t 的单位时间内将不再进行 TP 的忠诚 T 玩家数量为 $\phi \times L(t)$ 。




图 5: 每时间步的平均转移量

图 5 给人对该模型的直观印象。料

$$\frac{dQ(t)}{dt} = \gamma \times C(t),$$
$$\frac{dL(t)}{dt} = \lambda \times C(t) - \phi \times L(t).$$

4.4 模型拟合与预测

该模型使用均方误差（MSE）作为损失函数来估计模型参数。由于微分方程组的形式解难以计算，因此无法使用传统方法通过最小二乘法进行估计，只能直接计算微分方程的数值解，并使用优化算法最小化均方误差。同时，微分方程无法使用传统算法计算预测区间，因此我们采用自助法（Bootstrap）来获取点预测和预测区间。

Bootstrap 方法需要大量计算，且使用优化算法进行拟合的时间成本较高，因此我们选择计算速度更快的 Nelder-Mead 方法。由于 Nelder-Mead 算法需要为函数指定初始解，我们首先使用遗传算法 [5] 获取一个相对较好的初始解，然后使用 Nelder-Mead 方法选择使均方误差（MSE）最小的参数，遗传算法得到的初始参数如下表所示。由这组参数得到的模型曲线如图 4 所示。

β	γ	λ	ϕ
1.77e-01	1.77e-02	1.04e-03	1.14e-03

生成了 1000 个 Bootstrap 样本，在每个样本中，将使用遗传算法获得的初始参数作为 Nelder-Mead 方法的初始解进行拟合，以最小化均方误差 (MSE) 的参数，并预测 2023 年 3 月 1 日的报告数量，从而得到 1000 个 Bootstrap 预测值。将所得的预测值按升序排列，选取 2.5% 和 97.5% 分位数处的预测值作为 95% 预测区间的上下限。所得的预测区间如下。

Mean	2.5%	97.5%
14689.9	11173.04	17069.15

因此，我们估计在 95% 的置信水平下，2023 年 3 月 1 日的报告数量处于区间 [11173.04,17069.15] 内。

5 单词本身是否会影响困难模式比例

5.1 似乎确实如此

我们使用协方差矩阵来识别影响参与“困难模式”的玩家比例的变量。我们计算了与单词对应的七个属性（词频、加权纯度、未加权纯度、加权规律性、未加权规律性、重复字母数量和最大字母重复次数）与参与“困难模式”的玩家比例之间的相关系数，结果如图 6 所示。

协方差矩阵显示，除了加权规律性和未加权规律性外，单词的其他属性均与参与“困难模式”的玩家比例无显著相关性。由于玩家在玩 Wordle 之前并不了解这些单词，因此单词的大多数属性与参与“困难模式”的玩家比例无显著相关性是合理的。

在困难模式参与者比例方面，加权规律性与非加权规律性之间存在相对显著的相关性，这似乎意味着 Wordle 的属性在一定程度上会影响困难模式的参与者比例。不过，我们分别使用加权规律性和非加权规律性对该模式的参与比例进行了线性回归分析，结果如下表所示。




表 5：困难模式百分比对加权规律性的回归结果

	Estimate	Std.Error	t value	Pr(> t)	
(Intercept)	0.082177	0.00274	29.987	<2e-16	***
Reg_weighted	-0.021913	0.007788	-2.814	0.00517	**
Multiple R-squared: 0.02212					
Adjusted R-squared: 0.01933					

表 6：困难模式百分比对未加权规律性的回归结果

	Estimate	Std.Error	t value	Pr(> t)	
(Intercept)	0.082177	0.00274	29.987	<2e-16	***
Reg_unweighted	-0.148223	0.067780	-2.187	0.0294	**
Multiple R-squared: 0.01348					
Adjusted R-squared: 0.01066					

加权规律性与困难模式百分比回归模型的 R2 和调整 R2 分别仅为 0.022 和 0.019，而未加权规律性与困难模式百分比回归模型的 R2 和调整 R2 分别仅为 0.013 和 0.011，这表明加权规律性仅能解释约 2% 的挑战模式百分比变化，而未加权规律性仅能解释约 1.2% 的困难模式百分比变化，解释力度不够强。此外，加权规律性的回归系数为 -0.022，未加权规律性的回归系数为 -0.01，而数据集中观察样本的加权规律性 95% 集中在 0.081 至 0.612 的范围内，未加权规律性

95% 集中在 0.041 至 0.109 的范围内，这意味着数据集中加权规律性和非加权规律性的极端变化对困难模式占比的平均影响仅为 1%。这表明，加权和非加权规律性的极端变化对数据集中挑战模式占比的平均影响仅为 1%，与挑战模式占比 7.52% 的平均值相比，这一影响并不显著。

5.2 这很可能不是真的

除了解释力的缺乏，这种显著的相关性很可能是由伪回归导致的。下表展示了加权规律性和硬核模式百分比对时间的回归结果。

表 7：困难模式占比对时间的回归结果

	Estimate	Std.Error	t value	Pr(> t)	
(Intercept)	-2.893e-04	1.751e-03	-0.165	0.869	***
Date	1.988e-04	4.453e-06	44.655	<2e-16	***
Multiple R-squared: 0.8507					
Adjusted R-squared: 0.8503					

表 8：加权规律性对时间的回归结果

	Estimate	Std.Error	t value	Pr(> t)	
(Intercept)	0.3814810	0.0305641	12.481	<2e-16	***
Date	-1.668e-04	7.77e-05	-2.146	0.0325	*
Multiple R-squared: 0.01299					
Adjusted R-squared: 0.01017					

回归结果表明，“困难模式”百分比与时间呈正相关，而加权规律性与时间呈负相关，且两者之间的负相关极有可能是由时间趋势导致的，而非它们之间存在因果关系。

总之，我们得出结论，加权规律性和非加权规律性与困难模式百分比之间的显著相关性并不能证明单词属性会影响玩家是否选择困难模式，这一发现也与我们上面的假设一致，即玩家在参与 Wordle 之前并不知道谜题单词。

6 预测得分分布

在预测报告分数的分布时，我们需要确保分数之和等于 100%，而 K 近邻回归方法能很好地满足这一约束条件，因此我们选择 KNN 回归来预测分数分布。




图 7：困难模式报告比例与加权规律性的时间趋势

训练集中观测值之间的距离，选择与该观测值最接近的 K 个观测值，并将它们对应的因变量的平均值作为该模型的拟合值，计算方式如下。

公开


$$\hat{f}(x_0) = \frac{1}{K} \sum_{x_i \in N_0} (f(x_i)),$$

其中， N_0 是与 x_0 最接近的 K 个观测值的集合，而 $\hat{f}(x_0)$ 是模型的拟合值。

由于 KNN 使用因变量的均值作为预测值，这确保了将七个分数拟合到观测值后得到的预测值总和仍为 100%。

6.2 特征选择与参数调优

根据协方差矩阵，我们可以看出猜测得分的分布与困难模式结果数量、词频、重复字母数量、词汇纯净度、词汇加权纯净度、词汇规律性、词汇加权规律性以及重复字母的最大重复次数均存在显著相关性。还可以发现，词汇纯净度与词汇加权纯净度之间、词汇规律性与词汇加权规律性之间存在显著相关性，且重复使用可能会导致预测效果不佳；同时，由于我们在预测中不清楚困难模式的人数数据，若使用困难模式人数的预测值，预测结果将不可靠，因此我们需要进行



进一步对这五个变量进行筛选。此外，从 KNN 方法的思想可知，K 值的选择决定了模型的性能。我们采用交叉验证法来计算使用不同自变量和不同 K 值的 KNN 模型的预测误差，并将使交叉验证误差最小的 K 值用于模型。为了保证计算量适中，我们采用十折交叉验证。

在进行拟合之前，为了消除量级对观测值之间距离的影响，我们使用以下公式对自变量进行标准化，将每个自变量的均值标准化为 0，方差标准化为 1。

$$X_i^* = \frac{X_i - \overline{X}}{sd(X)}$$

交叉验证结果如图 10 所示。




图 10：交叉验证结果

*: ' & ' 表示包含，而 ' ! ' 表示排除；' UnW ' 是非加权词特征；' W ' 是词频加权词特征。

从该图可以看出，使用加权规律性和加权纯度且不包含挑战模式数量的 KNN 模型在 $K = 15$ 上表现最佳。因此，我们选择词频、重复字母数量、单词的加权纯度、单词的加权规律性以及重复字母的最大重复次数作为模型的自变量，并设置模型为 $K = 15$ 。该模型的均方误差（MSE）为 12.35。

6.3 预测与自举法

现在我们确定 EERIE 的每个属性。

Frequency	3264
Weighted Purity	10.86
Weighted Regularity	0.32
Number of Repeated Word	1
Max Times of Repeated	3

将 EERIE 的属性输入到 KNN 模型中，得到了其预测分布，如下表所示。

1 try	2 tries	3 tries	4 tries	5 tries	6 tries	X
0.20	4.87	23.55	35.36	23.75	9.94	2.33

我们使用 Bootstrap 方法计算了 KNN 模型的预测区间，并得到了每个得分预测值的 95% 置信区间，如图 11 所示。




图 11：EERIE 的预测达阵次数分布及 95% 置信区间

可以看出，该模型的误差范围较小。

7 难度分类

7.1 难度评估

Wordle 的难度可以通过玩家猜测 puzzle 单词所尝试的次数来衡量，尝试次数越多，Wordle 就越难。我们可以从数据集中获取最终尝试次数的分布情况，并定义尝试次数的中位数来衡量 Wordle 的难度。尝试次数的中位数指的是在得分分布中处于 50% 位置的玩家猜测该单词所进行的尝试次数。“abbey” 一词的尝试次数中位数为 5。

由于只有 3 个单词的中位数为 6，我们将中位数为 6 的单词与中位数为 5 的单词合并，得到三个难度等级：简单、普通和困难，它们分别对应中位数 3、4 以及 5 或 6。

7.2 难度预测

我们使用协方差矩阵来筛选与难度对应的单词属性，并筛选出重复字母数、加权纯度和加权规律性作为与分类相关的属性。我们使用 KNN 来验证分类的准确性。




图 12: 协方差矩阵

我们使用交叉验证，以准确率（即正确预测的数量占所有预测数量的百分比）作为选择标准，来获取 K 近邻算法（KNN）的最佳 K 值，交叉验证的结果如图 13 所示。

我们选择 $K = 8$ 作为参数，预测准确率为 75.28%。

我们代入了 EERIE 的三个数据，得到了关于 EERIE 的预测结果




图 13：交叉验证结果

属于普通难度。基于模型在 $k = 8$ 的交叉验证误差，我们认为该预测的准确率约为 75.28%，准确率区间为 [63.16%，82.76%]。

8 其他有趣的见解

如图 14 所示，随着时间的推移，困难模式在报告总数中的占比逐渐上升。实际上，这一现象与我们的 PCQL 模型相符，在该模型中，我们假设存在忠实的 TP 玩家（即忠实玩家），并且如图 15 所示，由于忠实玩家比普通玩家退出游戏的可能性低得多，其占比会随着时间的推移而增加。我们可以假设，忠实玩家更倾向于挑战，因此困难模式占比的上升在一定程度上反映了忠实玩家占比的增加。

第四次猜出谜语中单词的比例是词汇难度的临界值。协方差矩阵显示，随着与难度呈正相关的指标上升，在第 4 至 7 次被猜出的谜语比例会增加，而在第 1 至 3 次被猜出的谜语比例会下降。

如下图所示，玩家首次尝试猜对的比例与报告分数的总数呈正相关，这可能是因为随着报告数量的增加，人们从社交媒体上提前知晓谜题的概率也会增加，从而导致首次猜对的比例与报告分数的总数之间存在正相关关系。同时，玩家首次猜测的比例与带有重复字母的谜题单词数量呈显著负相关，这反映出玩家在玩 Wordle 时可能会采用一种策略，即使用没有重复字母的单词作为初始猜测，因为这样可以尽可能多地排除不正确的字母和位置。




图 15: 在具有前述参数的我们的模型中, L_s 在 TP_s 中的占比




图 1 Crarine M

公众号:




图 17: 首次尝试猜对的比例与报告分数总数

参考文献

[1] 马尔可夫·A.A., 《关于 < 叶甫盖尼·奥涅金 > 文本中链中样本关联性的统计研究实例》, 载于《语境中的科学》19 (2007), 第 591-600 页, ISSN: 1474-0664。

[2] Hermit Dave. Github - hermitdave 频率词: 频率词表生成器及处理文件的存储库。Github。网址: <https://github.com/hermitdave/Frequencywords> (访问日期: 2023 年 2 月 18 日)。

[3] W. O. 克马克与 A. G. 麦肯德里克。《对传染病数学理论的一项贡献》。收录于《伦敦皇家学会会报·A 辑 (包含数学与物理领域论文)》115 卷 772 期 (1927 年), 第 700-721 页。国际标准连续出版物编号: 09501207。

[4] R 核心团队。R: 一种用于统计计算的语言和环境。R 统计计算基金会。奥地利维也纳, 2022 年。网址: <https://www.R-project.org/>。

[5] 卢卡·斯克鲁卡。《GA: R 语言中的遗传算法包》。收录于:《统计软件期刊》第 53 卷第 4 期 (2013 年), 第 1-37 页。DOI: 10.18637/jss.v053.i04。

[6] Wond Lis- 5-Ler Words 网址: <https://ws.estoriitcon/1sttersords.htn> (访问时间: 2023 年 2 月 18 日)。

公众号: 竞赛资料