

“势头”作为残余效应存在于网球比赛中 —— 一个双时间贝叶斯网络模型

摘要

本研究通过复杂的统计建模和一种新颖的双时间贝叶斯网络方法，对网球比赛动态进行了调查。通过分析温布尔登的数据，我们解决了五个关键问题：

性能指标（问题 1）：我们引入了一种发球方 / 接发球方重加权策略，以准确评估球员的表现。我们进一步利用滑动窗口和曲线下面积（AUC）方法来确保连续性和局部性，从而更好地捕捉比赛中的波动。

动量存在性（问题 2）：严格的假设检验（Ljung-Box Q 检验和游程检验）无法拒绝完全随机性的原假设。但瞬时胜率可以揭示出与随机性的细微偏差，这表明存在微弱的动量效应，尽管并非具有压倒性的结论性。

动量预测（问题 3）：我们采用两步法。首先，我们将动量效应视为朴素二项式模型的残差，从而将其分离出来。随后，我们开发了双时间贝叶斯网络模型来预测这种残差效应。该网络包含了各种潜在变量，如生理状态、感知和自我效能感。该模型的另一个成果是通过减少信息熵来计算各因素对动量的重要性。

预测分析（问题 4）：我们的模型在 2023 年温布尔登网球锦标赛上进行了测试，成功预测了大多数比赛的波动情况。我们分析了失败案例，并提出了未来可能的改进方案。该模型框架还应用于另一个女子网球比赛数据集，揭示了一些有趣的差异。最重要的是，我们将数据归纳为一个通用框架，用于预测体育比赛中的势头变化。

教练策略（备忘录）：最后，我们为教练草拟了一份备忘录，将我们的研究结果综合为统计发现和有针对性的建议，包括减少失误、战略性进攻、韧性培养等方面。我们的目标是提供竞争优势。

我们的研究结果凸显了网球比赛动态的复杂性，将严谨的统计验证与复杂的预测建模相结合。我们的模型不仅展示出有效的预测能力和显著的稳健性，还广泛适用于各种体育场景。

关键词：网球、势头、贝叶斯网络、统计分析、性能指标。

目录

1 引言	3
1.1 问题背景	3
1.2 说明与重述.....	1.3 我们的工作... 3 3
2 建模准备	4
2.1 模型假设.	
445	
2.2 符号说明.....	
2.3 数据清洗...	
资料网	
5567	
3 问题 1: 概率差异评估策略	
3.1 服务器的重要影响....	3.2 滑动点区间方法.....
i nd ..	
4 问题 2: 动量存在性	
4.1 假设检验准备.....	889
...	
5 问题 3: 动量预测	
5.1 基础模块: 朴素二项模型..	4.3 瞬时胜率 .. 10 11
5.2 作为残余效应的动量.....	12 5.2.1 变量识别 13
5.2.2 模型构建.....	15 5.2.3 数据拟合..... 17 5.2.4 比赛数据推断
.....	19 5.2.5 建议..... 19
6 问题 4: 波动预测与模型泛化	20
7 模型分析	22
7.1 优势与劣势.	
7.2 敏感性分析	2 7.3 结论... 23
2325	
8 备忘录	
参考文献	

1 引言

1.1 问题背景

2023 年温布尔登网球锦标赛上, 卡洛斯·阿尔卡拉斯与诺瓦克·德约科维奇之间的历史性对决, 彰显了 momentum 在网球运动中的深远影响。这场比赛不仅吸引了网球爱好者的目光, 还凸显了竞技体育中一个复杂却未被充分探索的方面: 运动员通过 “momentum” 改变比赛态势的能力。momentum 对决定比赛结果的重要性已成为一个关键的研究热点。排球运动员甚至会将其用于排兵布阵的决策中。这凸显了我们需要一个精密的模型来捕捉 momentum 的本质, 并解释其背后的原理。

1.2 澄清与重述

我们的需求围绕着开发一个可量化的网球 momentum 模型, 该模型旨在识别 momentum 变化的关键指标, 评估它们对比赛结果的影响, 并判断这些变化在多大程度上可归因于技能、策略或纯粹的运气。我们将按以下步骤进行:

1. 创建一个模型来描绘网球比赛的流程, 量化球员在一段时间内的表现。
2. 构建一个假设检验框架, 以评估比赛中的波动是由于势头还是纯粹的偶然。
3. 利用我们的模型预测比赛动态的变化, 识别可能标志着比赛发生转变的潜在指标。
4. 在各种比赛、场地以及可能的其他类似运动中测试我们模型的预测能力, 评估其泛化性。
5. 将我们的研究结果综合为可供教练使用的可执行策略, 帮助他们让球员为比赛动态的变化做好准备, 并在比赛中对势头变化做出有效应对。

1.3 我们的研究

为应对这一挑战, 我们的方法将统计分析、机器学习技术和动态模拟相结合, 构建了一个全面的网球 momentum 模型。通过细致分析精选比赛的数据, 我们力求找出能表明 momentum 变化的模式和相关性。我们的方法包括严格的验证过程, 以确保该模型在实际场景中的可靠性和适用性。通过这一创新视角, 我们旨在阐明利用 momentum 的策略, 从而丰富职业网球这一高风险环境中选手和教练可用的战术库。




图 1: 我们的工作框架

2 建模准备

2.1 模型假设

以下列出一些基本假设。

- 假设 1: 天气、观众支持和轻微伤病等因素不会对比赛结果产生显著影响。
→ 理由: 虽然这些因素可能会影响比赛, 但将它们纳入模型会增加复杂性和不可预测性。对于广泛的分析而言, 关注更具可衡量性和一致性的因素更为实际。
- 假设 2: 选手当前的世界排名是其在即将到来的比赛中潜在表现的可靠指标。
→ 理由: 排名基于球员在滚动周期内的锦标赛表现, 反映其综合能力。

2.2 符号说明

以下列出一些主要符号。

表 1: 符号表

Symbol	Definition
M^1	the probability that player 1 wins a point regardless of the server
AUC	Area Under Curve, a measure of model accuracy
Q	Ljung-Box statistic
Z	Z-score for Runs Test
r_1 or r_2	Expected losing round for player 1 or player 2
B	Intrinsic probability function of winning a point
λ	The parameter determining Duel-Temporal Bayesian Network
L	the likelihood of data from 1 match between players
E	Momentum effect as difference between actual and expected points

2.3 数据清洗

观察了温布尔登特色比赛.csv 数据集后, 我们处理了 `elapsed_time` 列中的异常值 (第 586 至 636 行), 并删除了 `speed_mph` 列的分析。s m

3 问题: 概率差异评估策略

3.1 发球方的重要影响

让我们来看看一场比赛中选手 1 和选手 2 之间的得分差变化, 根据 `Wimbledon_featured_matches.csv` 数据集, 我们用 `p1_points_won` 减去 `p2_points_won` 的数据来得到得分差, 即: 得分差 = 选手 1 赢得的分数 - 选手 2 赢得的分数

$$pointsdifference = p1_{points_{won}} - p2_{points_{won}} - p2_{points_{won}} \quad (1)$$

这个公式有助于我们可视化一场比赛的进程, 正如下方图表所示, 该图表突出显示了随时间变化的分差。




图 2: 2023 年温布尔登网球锦标赛 - 1301 场次的得分差

还添加了两条彩色虚线: 绿色代表从玩家 1 到玩家 2 的发球, 紫色代表从玩家 2 到玩家 1 的发球。

一个关键的观察结果是，当前发球的球员赢得这一分的概率更高，尤其是在 $number = [20, 50]$ 分或 $[180, 220]$ 的情况下。然而，无论谁发球，分差的总体趋势都保持相对稳定，这表明仅靠发球并不会显著改变比赛的势头。因此，当我们试图判断在比赛的特定时间哪个球员表现更好时，不能受发球方是谁的影响。

3.2 滑动分区间方法

为了进一步分析比赛动态，我们重点关注球员赢得一分的概率差异。在一场比赛中，两名球员的表现取决于概率差异 M^1 或 M^2 ， M^1 是球员 1 在不考虑发球方的情况下赢得一分的概率，而 M^2 是球员 2 在不考虑发球方的情况下赢得一分的概率。

接下来，根据给定数据集中的列 `point_no`，我们可以通过选择固定的数据长度 ω 来计算 p_1 和 p_2 。 p_1 是球员 1 在发球时赢得一分的概率， p_2 是球员 2 在发球时赢得一分的概率， w 是分数间隔。如果球员 1 发球 n_1 次，球员 2 发球 n_2 次（其中 $w = n_1 + n_2$ ），球员 1 赢得 x_1 分，球员 2 赢得 x_2 分，那么 $p_1 = \frac{x_1}{n_1}$ 和 $p_2 = \frac{x_2}{n_2}$ 。实际上，我们可以得到性能指标： $(p_1 - p_2)$ 。如果球员 1 和球员 2 拥有相同的发球机会，那么 p_1 和 p_2 的理想值应该相等，那么

$$\begin{pmatrix} M^1 \\ M^2 \end{pmatrix} = \begin{pmatrix} p_1 & 1 - p_2 \\ 1 - p_1 & p_2 \end{pmatrix} \begin{pmatrix} \frac{1}{2} \\ \frac{1}{2} \end{pmatrix} \quad (2)$$

。

当 $M^1 > 0.5$ 时，意味着玩家 1 比玩家 2 表现更好，而 $M^1 < 0.5$ 则相反。此外，数值越高，玩家 1 的表现就越好，因此它可以确定在比赛的特定时间哪个玩家表现更好，以及他们的表现好多少。

为了可视化玩家 1 和玩家 2 的不同表现，我们引入了一个长度为 ω 的滚动窗口。对于每场比赛，我们可以利用这个“滚动窗口”来计算玩家 1 和玩家 2 的表现差异，并结合三次样条插值，绘制出相应的表现程度变化，得到以下曲线 ($\omega = 30$)：




图 3：2023 年温布尔登网球锦标赛第 1301 场比赛的概率差异

其中横坐标是一场比赛的总得分（数量

当两名球员完成一个球时加 1 分（对应给定数据中的 point_no 列），纵坐标表示概率差 M^1 。与图 2 相比，我们发现发球方的变化与概率差无关，这意味着比较概率差比较分数差更有意义。

从图 3 可以看出，红线以上的部分表明选手 1（卡洛斯·阿尔卡拉斯）比选手 2（尼古拉斯·贾里）表现更好，红线以下的部分表明选手 2（尼古拉斯·贾里）比选手 1（卡洛斯·阿尔卡拉斯）表现更好，此外，波峰和波谷的位置表明该选手表现尤为出色。

3.3 滑动时间窗口方法

然而，仅仅根据总分的均匀间隔来选择要绘制的数据点是不够的，我们还应该从比赛时间的角度进行均匀分割。记住， L 代表时间窗口的长度， λ 代表每个时间窗口移动的步长，将点编号替换为 t_i 作为横坐标，分别为 $t_i = \lambda$ 秒、 2λ 秒……例如，如果将 $L = 600$ 秒作为时间窗口的长度，两名球员可能总共打 12 分或 18 分，然后将 $\lambda = 60$ 秒设置为时间窗口移动的步长，这样的结果更能反映球员的表现，也更自然。

通过调整不同的 L 和 λ ，我们绘制了如下变化图：



图 4：2023 年温布尔登网球锦标赛 - 1301 场次在不同窗口下的性能评估

从图表中我们可以观察到，玩家在特定时刻的表现受时间窗口长度 L 的影响显著，而受每个时间窗口移动的步长 λ 的影响较小。一般来说，小窗口会引入噪声，而大窗口则无法描绘游戏中快速变化的动态。为了解决这个问题，一种常见的方法是应用滤波器，例如高斯滤波器，这需要特定的核函数。这需要修改公式 2。但在此我们提出一种更简单但同样有效的方法，称为 AUC（曲线下面积），其定义如下式：

$$A(t) = \frac{1}{L_{max}} \int_{L_{min}}^{L_{max}} M_L(t) dL \quad (3)$$

其中， $M_L(t)$ 表示在考虑窗口长度 L 时，某一玩家在时间 t 的表现。在实际应用中，我们可以简单地将 dL 离散化为 1。这与基于核函数的方法类似。

方法中，AUC 还会根据时间距离对获胜点进行加权（这一点通过将 $M_L(t)$ 表示为指示函数的总和，然后交换求和顺序就可以很容易地看出，这里我们略去细节）。以下是使用这种方法生成的图表。




图 5: 2023 年温布尔登网球锦标赛 - 1301 场次的 AUC - 时间图

从这张图表中，我们可以确定在特定时间哪个球员表现更好。当曲线在 0.5 以上时，球员 1 占据优势，而当曲线在 0.5 以下时，球员 2 表现更好。并且曲线离平衡线越远，球员之间的表现差异就越大。

4 问题 2：动量存在性

鉴于我们的分析揭示了“动量”中可能存在的模式，我们现在通过假设检验来严格检验这些观察结果，以验证动量的存在。

4.1 假设检验准备

我们首先构建了假设检验框架：

零假设(H_0): 对于固定服务器，玩家的得分是独立同分布的 (i. i. d.)，因此遵循二项分布。备择假设 (H_1): H_0 的补集，表明得分并非完全随机，存在某种形式的“动量”或序列依赖性。

为了评估关于“momentum (势头)”不存在的说法，我们指出，在任何给定的比赛中，当选手 1 发球时，选手 1 赢得一分的概率为 p_1 ；当选手 2 发球时，选手 1 赢得一分的概率为 p_2 。这些概率 (p_1 和 p_2) 的计算方法将在第 3 节中说明。

对于每场比赛，我们通过以下方式计算获胜概率：统计球员 1 赢得的分数和总发球数，以计算 n_1 ，以及统计

玩家 1 赢得的分数与玩家 2 的总发球数之比, 用于计算 p_2 。

4.2 Ljung-Box Q 检验和游程检验统计分析

如果得分完全是随机的, 我们预计连续得分之间不会存在显著的自相关性。

我们将球员 1 发球和球员 2 发球的场景分开, 并为每场比赛构建序列。然后计算每个序列的自相关性, 并采用适当的统计检验 (Ljung-Box Q 检验) 来评估该序列的自相关性是否显著。

其中 n 是时间序列的样本量。 h 是为自相关检测考虑的最大滞后数。 $\hat{\rho}_k$ 是滞后 k 处的样本自相关系数。 Q 是 Ljung-Box 统计量, 在原假设下它近似服从卡方分布, 自由度为 $h - m$, 其中 m 是模型中的参数数量 (对于简单的时间序列分析, m 通常取 $m = 0$)。

第一场比赛的 Ljung-Box Q 检验结果显示, 对于多达 10 个观测值的自相关, 相应的 P 值为 0.497, 该 P 值大于常见的显著性水平 (例如 0.05)。其他比赛的结果与此类似。这表明没有足够的证据来拒绝原假设 H_0 。

然后我们进行了游程检验, 以分析数据序列中的 “游程” 数量, 其中 “游程” 被定义为连续出现的相同元素序列。我们计算了期望游程数和方差, 并通过以下方式得到 Z 分数:

$$Z = \frac{(R - E[R])}{\sqrt{Var(R)}} \quad (5)$$

其中: R 代表实际运行次数。 $E[R]$ 是预期运行次数, 计算方式为 $E[R] = 1 + \frac{2n_1n_2}{n_1+n_2}$ 。 $Var(R)$ 是运行次数的方差, 计算方式为 $Var(R) = \frac{2n_1n_2(2n_1n_2 - n_1 - n_2)}{(n_1+n_2)^2}$ 。 n_1 和 n_2 是序列中两种结果 (例如胜利和失败) 的计数。

然后通过 $P = 2(1 - \Phi(|Z|))$ 计算 P 值, 得到 P 为 0.691, 这一数值大于常见的显著性水平 (例如 0.05), 这表明不能否定这些点是独立同分布的假设。其他匹配的结果也类似。

在这里, 我们绘制了两种具有不同匹配情况的方法的结果。除少数情况外, 在各种匹配中, P 值均超过 0.05 的基准, 这表明对于大多数匹配, 我们不能拒绝 H_0 。




图 6 特征重要性

4.3 瞬时胜率

为了检验独立同分布假设，受 Sun, y, 2004 年论文发球方不变的情况下，一名球员在赢下一分后紧接着的瞬时胜率：第一种是球员 1 在发球时赢下一分后紧接着赢下下一分的概率，第二种是球员 1 在接球员 2 发球时赢下一分后紧接着赢下下一分的概率。



表 2：基于发球状态的获胜概率

Player and State	P of winning when serving	P of winning when not serving
Player 2	0.6874	0.3406
Player 1 ^{immediate}	0.6978	0.3498
Player 2	0.6594	0.3126
Player 2 ^{immediate}	0.6683	0.3261

观察到的胜率上升约 1% 可能表明了势头的影响，这对网球比赛中得分序列具有随机性的说法提出了挑战。

深入研究比赛数据的细微之处，揭示出一个有趣的模式：无论是发球还是回球，球员在赢得一分后，拿下下一分的概率都略有提高。虽然这些数据并未极力支持势头这一概念，但它确实含蓄地认可了其存在。

5 问题 3: 动量预测

5.1 构建模块: 朴素二项模型

在识别比赛中的“势头”时, 一个直接的问题是, 我们观察到的所有变量都混合了势头效应和选手技能水平差异带来的效应。为了“分离出”势头的影响, 我们首先开发了一个不考虑任何势头的简单模型。或者说, 这是一个假设得分是同分布随机变量的模型。我们将这个模型称为二项式模型, 记为 $BM^{[5]}$ 。

为了开发这个模型, 我们收集了球员的世界排名作为额外的先验信息……并将其转换为 2023 年温布尔登锦标赛中的相对排名。这里的“相对”是指, 我们根据 32 名球员彼此之间的排名对他们进行重新排名, 得到一个介于 1 到 32 之间的整数数组。然后, BM 只是 $(Rank1, Rank2)$ 的一个函数。

我们的二项式模型会获取两名选手的排名, 然后返回赢得某一分的“内在概率”, 在简单假设下, 这一概率在整场比赛中保持不变。

值得注意的是, 在网球比赛中, 顶尖排名选手之间的实力差距往往比低排名选手之间的差距更明显。例如, 我们可以预期排名第 1 和第 2 的选手之间的差距会大于排名第 31 和第 32 的选手之间的差距。相反, “预期失利轮次”这一概念能够很好地捕捉到这一先验信息。具体来说, 我们定义

因此, 我们可以定义 $BM(Rank1, Rank2) := f_1(r_1, r_2)$ 。设置 $f_2(x, y) = f_1(\frac{x+y}{2}, \frac{x-y}{2})$, 我们得到

$BM = f_2(r_1 - r_2, r_1 + r_2)$ 。我们为 f_2 提供以下近似值:

$$f_2(r_1 - r_2, r_1 + r_2) = \frac{e^{\lambda(r_1 - r_2)}}{1 + e^{\lambda(r_1 - r_2)}} + s \quad (7)$$

其中 $s > 0$ 是服务器优势。或者, 我们可以将右侧设置为带有更多参数的 $\frac{e^{\lambda(r_1 - r_2) + \mu(r_1 + r_2)}}{1 + e^{\lambda(r_1 - r_2) + \mu(r_1 + r_2)}} + s$ 。

但在实验过程中, 我们发现 μ 的值相当小, 因此在此忽略不计。理想情况下, 如果公式 (6) 足够好地捕捉到了排名 - 强度关系, 那么这种简化是合理的。有关进一步的理由, 请参考 [Klaassen 和 Magnus, 2001][2]。

然后, 我们通过最大化似然值, 在 31 场比赛的点对点数据上估计参数 λ 。

步骤 1: 似然函数

假设各分的结果相互独立 (这是我们朴素模型的一个假设), 那么在玩家 1 和玩家 2 的单场比赛中, 玩家 1 赢 n_1 分、玩家 2 赢 n_2 分的观测数据的似然性可以用二项分布表示:

$$L(\lambda, s | n_1, n_2) = \binom{n_1+n_2}{n_1} \left(\frac{e^{\lambda(r_1-r_2)}}{1+e^{\lambda(r_1-r_2)}} + s \right)^{n_1} \left(1 - \left(\frac{e^{\lambda(r_1-r_2)}}{1+e^{\lambda(r_1-r_2)}} + s \right) \right)^{n_2} \quad (8)$$

步骤 2: 对数似然

为了简化计算并处理潜在的数值下溢问题, 通常使用对数似然而非似然本身。

$$\log L(\lambda, s | n_1, n_2) = \log \left(\binom{n_1+n_2}{n_1} \left(\frac{e^{\lambda(r_1-r_2)}}{1+e^{\lambda(r_1-r_2)}} + s \right)^{n_1} \left(1 - \left(\frac{e^{\lambda(r_1-r_2)}}{1+e^{\lambda(r_1-r_2)}} + s \right) \right)^{n_2} \right)$$

λ 的所有匹配:

$$\log L(\lambda, s) = \sum_{\text{matches}} \log L(\lambda, s | n_1, n_2)$$

步骤 4 最大化对数似然 我

由于该函数的平滑性, 我们可以轻松应用牛顿法 (该方法需要计算一阶和二阶导数) 来迭代调整 λ 值以找到最大值。最优值计算为 $\lambda = 0.0624$ 、 $s = 0.1742$ 。

5.2 作为残余效应的动量

我们很容易观察到 “无动量” 说法与 “无记忆” 说法之间的等价性。 “动量不存在” “得分过程与比赛的过去无关, 换句话说, 就是无记忆的”

现在, 通过对两边取反, 我们可以将动量效应测量为:

$$E := S - \hat{S} \quad (11)$$

其中, S 是实际获胜的分数, 而 $\hat{S}$ 是二项式模型预测的获胜分数。由于动量作为一个统计量并没有严格的定义, 我们现在使用公式 (11) 来定义动量的值。这个公式可以直观地理解, 因为以前对动量的批评常常将其描述为 “从随机性中看到某种东西”。

为了设计一个预测残差的模型, 有几个关键事实值得注意:

“势头” 在统计上难以把握的原因在于, 这一概念意味着体育比赛系统中存在某种 “隐藏状态”。因此, 生成模型是更优的选择。直接的一步预测可能会有极大的噪声, 这给有效的模型拟合带来了挑战。我们需要特定的方法来减少噪声的影响。过去比赛状态的影响应该被编码到这个模型中, 而且过去的影响可能会持续很长时间。

综合考虑所有这些因素，我们提出了新颖的双时间贝叶斯网络。作为常规动态贝叶斯网络的一种变体，它不仅为网球比赛构建了一个隐藏模型，还对过去的长短期记忆进行了编码，从而能够全面检测“势头”。

5.2.1 变量识别

在网球运动中，那些看不见的因素可能和记分牌一样具有影响力。例如，一名球员表现的突然飙升或下滑并非总是源于看得见的发球直接得分或双误。这通常是一些隐藏的触发因素——或许是比赛的压力给他们带来的负担——能够扭转局势。一场网球比赛不仅是力量或技术的较量，还涉及复杂的心理和生理动态。

借鉴[泰勒, 1994]的见解，我们可以发现，动量是一个由认知、生理和情感构成的复杂系统，所有这些都由诱发事件引发，并体现在表现变化中。本文提出的“动量链”概念表明，初始事件可能会引发运动员认知、情感和生理方面的改变，进而导致影响表现的行为变化，这与网球运动中发挥作用的无形力量相呼应，引导我们思考潜在变量。

基于这一框架，我们在模型中选取了 3 个潜在变量：“生理状态”“控制感”和“自我效能感”。它们在捕捉那些影响网球比赛中 momentum 波动的复杂、不可观测因素方面起着关键作用。

1. 生理学：球员的身体状况，如疲劳程度、能量水平，甚至是细微的伤病。
2. 控制感知：这代表了球员控制比赛的能力。
3. 自我效能感：自我效能感是玩家对自身能力的信念，它是推动玩家坚持不懈的动力。

根据[泰勒, 1994]的观点，诸如特定投篮、关键分等诱发事件会间接改变球员的心理和生理状态。这些隐藏状态是比赛的暗流，虽不可见但至关重要。将这些纳入我们的模型，能够更准确地理解和预测 momentum 的波动。

然后我们得到下面的图表。下图中的箭头代表了各种因素之间的影响关系。这个复杂的影响网络反映了竞技体育的多面性，其中身体、心理和情境因素相互交织，共同影响着比赛的结果。




图 7：已识别的变量

由于我们的数据存在局限性（仅有 31 场比赛），像这样复杂的模型容易出现过拟合现象，因此不适合用于稳健性预测。为了简化模型构建，我们利用随机森林来寻找对预测而言无关紧要的变量。以下是一些主要特征：

表 3：特征重要性				
Feature	$p_{1_unf_err}$	p_{2_winner}	$p_{2_unf_err}$	p_{1_winner}
Importance	0.120587	0.111018	0.101907	0.094330
Feature	$server$	$rally_count$	$p_{2_net_pt_won}$	$game_victor$
Importance	0.084700	0.081359	0.047800	0.043592
Feature	$p_{1_net_pt_won}$	$p_{2_distance_run}$	$p_{1_distance_run}$	
Importance	0.032918	0.032348	0.032152	

为了简化我们的网络，我们应该使用相关性热力图来可视化特征之间的相关性。这对于特征工程至关重要。排名前 10 的特征的相关性热力图展示了最能预测网球比赛得分获胜者的变量之间的关系。以下是从该热力图中得出的一些见解：

非受迫性失误（ $p_{1_unf_err}$, $p_{2_unf_err}$ ）：这些特征与得分结果呈现显著相关性，这意味着球员的失误会对得分结果产生关键影响。

获胜者（ p_{1_winner} , p_{2_winner} ）：球员因制胜球赢得的分数与比赛结果高度相关。

发球（发球方）：发球方在一分中的角色与之有显著相关性

得分结果。

身体与战略方面 (rally_count, p_1_net_pt_won, p_2_net_pt_won)：这些特征表明了得分过程中涉及的体能消耗和战略性打法，例如更长的回合以及成功的网前球对得分结果的影响。

这揭示了游戏中可能促成势头的多个层面，例如非受迫性失误、制胜球等直接影响，以及发球带来的优势。此外，回合数和网前得分等体能与战略因素也可能影响球员在比赛中的主导地位。





图 8：十大特征的相关性热力图

5.2.2 模型构建

通过这种方法，我们确定并剔除了生理学等无关紧要的特征。剩下的特征构成了我们网络的基础。简化版本如下图所示：



t

以这个更简单的网络作为一个构建块，我们可以将两个块堆叠在一起，形成我们的对偶时间贝叶斯网络：




图 10：双时间贝叶斯网络

我们在这两层的隐藏变量之间添加了绿色箭头，以表示心理和生理状态的连续性。

5.2.3 数据拟合

有效训练该模型的一个障碍是噪声。尽管我们已经考虑了原始实力差异和发球优势, 但必须承认, 在某一分上得分或失分的残余影响在很大程度上仍然是 (并且应该仍然是) 随机的。我们没有让模型预测下一分的状态, 而是让它预测接下来 n 分中影响的总和。由于中心极限定理, 这减少了噪声, 从而使网络训练成为可能。同样, 所有观察到的变量 (如球员的双误) 都在特定时间间隔内进行汇总。具体来说, 假设当前分的索引是 t , 长期层的数据在 $[t-40, t-10]$ 中汇总, 其影响在 $[t-10, t]$ 中; 而短期层的数据在 $[t-10, t]$ 中汇总, 其影响在 $[t, t+10]$ 中。我们仔细区分过去的比赛信息和未来的比赛结果, 以确保我们的模型具有完全的预测性。

从卡洛斯·阿尔卡拉斯的角度看他和德约科维奇之间的对决。




图 11: 去噪残差效应曲线

由于我们的模型中存在潜在变量, 我们利用期望最大化 (EM) 算法在 2023 年温布尔登网球锦标赛的 31 场比赛数据上训练该网络。在统计学中, EM 算法用于寻找概率模型中参数的最大似然估计, 而这类模型依赖于未观测到的潜在变量。

EM 算法由两个步骤组成: 期望步 (E 步) 和最大化步 (M 步)。在 E 步中, 算法会根据模型当前的参数计算潜在变量的期望值。在 M 步中, 算法会最大化似然函数, 基于这些期望值来更新参数。这一过程会重复进行, 直到收敛。

$$Estep: Q(\theta|\theta^{(t)}) = \mathbb{E}_{Z|X, \theta^{(t)}} [\log L(\theta; X, Z)] \quad (12)$$

$$Mstep: \theta^{(t+1)} = \underset{\theta}{\operatorname{argmax}} Q(\theta | \theta^{(t)}) \quad (13)$$

在这些方程中, θ 表示模型的参数, X 表示观测数据, 其中既包括输出残差效应, 也包括输入点对点数据, Z 表示潜变量 (在我们的模型中有 6 个潜变量), L 是似然函数, Q 是一个依赖于潜变量期望值的函数。

在我们的第一次训练中, 我们发现这个数据集中存在一个意想不到的偏差: 1 号球员的整体残余效应优于 2 号球员。因此, 我们的模型预测的 “1 号球员具有更好的残余效应” 与 “2 号球员具有更好的残余效应” 的先验分布 (即当没有提供证据时) 约为 53% 对 47%。我们可以对数据集进行镜像处理 (即交换 1 号球员和 2 号球员的位置), 但这也会使训练成本增加一倍。为了以更通用的方式解决这个问题, 我们将 $Q(\theta | \theta^{(t)})$ 的表达式重新加权为

$$RweightedEstep: Q(\theta | \theta^{(t)}) = \mathbb{E}_{Z|X, \theta^{(t)}} \left[\frac{1}{P(X)} \log L(\theta; X, Z) \right]$$

。

其中, $P(X)$ 是在考虑 X 的某些特征 (在我们的案例中, 即残余效应优势) 时, X 发生的先验概率。

为了有效地训练网络, 我们首先需要将变量离散化。术语 $\text{residual_effect_1}(0)$ 和

$\text{residual_effect_1}(1)$ 分别指的是对手和自身的动量。类似地, unferr1 的范围是 0 到 2, 表示球员之间的相对非受迫性失误水平; '0' 意味着对手的非受迫性失误更多, “1” 表示水平相当, '2' 表明自身的非受迫性失误更多。至于潜在变量, 例如 self_efficacy_1 的值范围是 0 到 1, 表示球员之间的相对自我效能水平; “0” 意味着对手的自我效能更高, “1” 表明自身的自我效能更高。

为了衡量变量的重要性, 我们计算给定每个变量时的信息增益 (或者说 “熵减”)。熵值用于衡量与不同变量对动量影响的预测相关的不确定性或不可预测性。信息增益越大, 表明重要性越高。




图 12: 残余效应和熵的差异

从图表中可以看出，对势头影响最大的积极因素是球员的净胜分，紧随其后的是发球直接得分和保持得分领先。这些结果表明，积极主动且富有攻击性的打法对球员的势头有显著贡献。与之形成鲜明对比的是，非受迫性失误会削弱势头，这强调了在球场上保持心理优势时，稳定性和失误控制的重要性。双误出人意料地对势头有轻微的提升作用。我们推测这与双误和攻击性发球之间的相关性有关。由于在我们的模型中，球员的攻击性并未被确定为变量，因此很难了解其真正的因果效应。

为进一步阐明双误后 momentum 反直觉上升的现象，我们的研究深入探究了发球模式。球员 p_{ace}^{qc} 和 p_{ace}^{gc} 的基准 ace 率分别为 9.70% 和 8.61%。有趣的是，对双误后的分析显示 ace 频率有所上升，球员 1 的 ace 率 p_{ace}^{qc} 在下次双误前呈上升相关性，这可能是模型学到的捷径或数据偏差。

5.2.4 比赛数据推断

在推理过程中，所有观测变量（包括长期残余效应）都会输入到模型中。基于这些已知证据，我们的贝叶斯网络能够确定输出变量和潜在变量的分布，并最终确定比赛中的势头（作为残余效应）。具体而言，鉴于该网络的结构，我们可以利用网络中所描绘的条件依赖关系来描述这些变量分布之间的数学关系。有关计算细节，请参考 [(Ben, 2007)]。

5.2.5 建议号

基于我们贝叶斯网络的统计分析，我们为玩家提出以下可能有助于提升其势头的策略：

1. 减少非受迫性失误：在回合中优先保证连贯性，避免因可避免的失误而丢失 momentum。
2. 利用激进打法：增加上网次数，力求发球直接得分，以充分利用这些动作对比赛势头的强大积极影响。
3. 战略性发球：注重发球的准确性和多样性，减少双误，尽管双误可能不会显著削弱 momentum，但保持发球状态对比赛胜利仍然至关重要。
4. 心理韧性：培养心理韧性以承受面对破发点时的压力，因为克服这些破发点对势头的贡献比预期的要小。
5. 保持领先：努力建立并保持领先优势，因为保持领先能培养积极的势头，并可能给对手带来心理压力。

将这些策略融入训练和比赛中，能帮助球员利用并保持 momentum，这是竞技网球的关键要素。

6 问题 4: 波动预测与模型泛化

我们首先在卡洛斯·阿尔卡拉斯和诺瓦克·德约科维奇的决赛中对我们的模型进行了评估。结果以及另外三场比赛的结果将在后续图表中呈现。值得注意的是，我们的模型准确预测了残余效应最初的几次起伏，但在对应第四盘的第 230 至 280 分出现了失误。在这一阶段，诺瓦克·德约科维奇意外获得了显著优势。这可能是由于我们的模型未考虑到某些因素的影响。




图 3: 预定义的 vsAct

特定球员的打法风格，比如场地偏好、伤病历史。这些只能通过他们的历史表现来建模，而无法通过我们当前的方法（即只考虑球员排名）来推断。基于数据整合球员的个人信息可能会进一步提升我们模型的性能。

此外，除了给定的温布尔登数据集，我们还在 JeffSackmann 的网球比赛记录项目中的女子单打网球比赛数据集上测试了我们的模型，该数据集名为 `charting - w - points - 2020s.csv`。




图 14: 残余效应和熵的差异

与图 12 相比, 一个显著的区别是发球直接得分的影响。在我们的数据集中, 男性球员获得发球直接得分的概率为 9.14%, 而女性球员仅为 4.25%。此外, 双误的出现现在明显具有不利影响, 因为它不再是为了奋力打出发球直接得分而导致的结果。

为了展示我们模型框架的适应性, 我们进一步将其泛化为一种更抽象、更全面的形式, 如下图所示。该框架可以实例化为能够处理各类体育赛事(如乒乓球、篮球、足球等)的模型……




图 15: 通用框架

7 模型分析

7.1 优势与劣势

优势：

1. 通过双层结构同时捕捉短期和长期动量效应。这使得模型能够解释由近期游戏内事件以及长期心理因素引起的动量变化。
2. 纳入了生理状态、控制感和自我效能等潜在变量，这些变量虽无法直接观察，但在动量中发挥着重要作用。这为影响动量的因素提供了更全面的描述。
3. 采用期望最大化等先进的机器学习技术来处理潜在变量，使模型能够在真实比赛数据上进行训练。这使得该模型具有实际应用价值。
4. 在数据集中的不同球员和比赛中实现了良好的泛化能力，展现出稳健性。
5. 提供了关于非受迫性失误、攻击性打法、破发点等不同因素如何影响 momentum 的可解释性见解。

劣势：

1. 若无法获取球员心理状态的实际测量数据，则难以充分验证潜变量表征及其动态的准确性。
2. 需要按时间段聚合数据以减少训练中的噪声，但会损失一些粒度。
3. 未考虑对手的适应性策略及其对势头的影响。假设玩家行为是独立的。

7.2 敏感性分析

为了评估我们所提出模型的稳健性，我们从两个方面进行了敏感性分析。1. 修改模型的预测区间。2. 通过从原始数据集中随机抽取 70% 和 50% 的数据来改变训练数据，这分别对应 22 场和 16 场比赛。

以下是观测变量的信息增益变化。左图的变化表明，更长的预测区间迫使模型优先考虑可能具有更长持续时间的影响，例如“比分优势”。相反，像“赢得网前得分”“发球直接得分”这样的短期事件权重较低。右图中，基于 50% 数据训练的模型出现了显著变化，这可能是由于比赛分布的改变所致。另一方面，使用 70% 数据训练的模型保持稳定，这表明存在一个数据充分性的阈值。




图 16: 残差效应与熵的差异

在本文中，我们首先开发了一个简单的二项式模型，旨在恢复比赛预测的残差用作我们的动量预测器（双时间贝叶斯网络）的标签。可推广性和鲁棒性，使我们能够揭示可观察体育比赛背后的潜在系统。

8 备忘录

致：网球教练们

发件人：2401298 号团队

主题：利用网球中的 momentum——训练的见解与策略

日期：2024 年 2 月 6 日

尊敬的教练们：

我们非常高兴与您分享基于双时间贝叶斯网络模型得出的建议，这些建议旨在通过网球中“momentum（势头）”这一微妙概念来提升球员表现。在竞争激烈的网球界，“势头”这一概念常被认为能改变比赛局势，可能在关键的比赛时刻扭转乾坤。这种难以捉摸的力量被认为会影响比赛结果。我们的研究对这一现象进行了剖析，旨在将这一抽象现象转化为可系统应用的具体策略。



图 17：网球中的 momentum

“动量”不是一个孤立的概念，它代表了网球比赛中复杂的潜在状态的存在，而不是简单的点数所能捕捉到的。我们的研究分析了网球比赛中动量的复杂动态。我们利用统计模型和对决 - 时间贝叶斯网络来量化和预测心理和生理因素对比赛表现的影响。我们的分析表明，虽然每个点的结果在某种程度上似乎是统计独立的，但我们开发的贝叶斯网络讲述了一个更丰富的故事。它揭示了自我效能、策略和生理反应的隐藏线索，这些线索交织在一起形成了动量的结构。

为了让玩家能够利用势头的积极方面，同时减轻其带来的压力，我们建议采取以下战略性转变：

1. 连贯性是关键：鼓励球员减少非受迫性失误；我们的研究发现，连贯的表现与保持势头有关。
2. 主动出击终有回报：建议球员通过网前进攻和发球来确立优势，从而建立积极的势头。
3. 智能发球：强调多样化且精准的发球技巧，以保持 momentum 而不冒双误的风险。
4. 培养韧性：培养球员的心理韧性，这对于应对比赛中的破发点压力和局势变化至关重要。
5. 以领先求胜：力争早早取得领先；我们的模型表明，这会对手带来心理压力，增强领先者的势头。

我们相信这份备忘录为您提供了一个清晰且可执行的策略，帮助您利用势头这一概念为自己带来优势。实施这些建议可能会培养出竞争优势，这对于在现代快节奏的网球比赛中获胜至关重要。

期待看到这些策略在你的球员们提升的表现中得以体现。

您诚挚的，

第 2401298 号团队

参考文献

- [1] 泰勒 (Taylor, J.) 和德米克 (Demick, A.) (1994)。《运动中动量的多维模型》。《应用运动心理学杂志》，6 (1)，51-70。
- [2] 克拉森 (Klaassen, F.) 和马格努斯 (Magnus, J. R.) (2001)。网球比赛中的得分是独立同分布的吗？来自动态二元面板数据模型的证据。《美国统计协会期刊》，96 (454)，500-509。
- [3] 本井伸 (Motoi, S.)、三须贵 (Misu, T.)、中田康 (Nakada, Y.)、矢崎刚 (Yazaki, T.)、小林豪 (Kobayashi, G.)、松本太 (Matsumoto, T.)、八木典 (Yagi, N.) (2012)。基于隐马尔可夫模型的体育赛事贝叶斯事件检测。《模式分析与应用》，15，59-72。
- [4] 孙宇 (2004)。《检测热手效应：一种替代模型》。收录于《认知科学学会年会论文集》(第 26 卷, 第 26 期)。
- [5] 克拉森, F. J., & 马格努斯, J. R. (2003)。预测网球比赛的获胜者。《欧洲运筹学杂志》，148 (2)，257-267。
- [6] 葛晓、林安 (2021)。基于扩展收敛交叉映射的重叠滑动窗口动态因果关系分析。《非线性动力学》，104 期，1753-1765 页。
- [7] 莫伯, J. R. (2008)。《一维纳米线：理解其生长和特性作为迈向生物医学和电子应用的步骤》。佐治亚理工学院。
- [8] 马达范, V. (2016)。使用隐马尔可夫模型预测 NBA 比赛结果。《伯克利大学》。
- [9] 拉布 (Raab)、古拉 (Gula) 和吉仁泽 (Gigerenzer) (2012)。排球运动中存在热手效应，且该效应会用于分配决策。《实验心理学杂志：应用版》，18 (1)，81。
- [10] <https://github.com/JeffSackmann/tennis-MatchChartingProject>。
- [11] 本·加尔 I (2007)。《贝叶斯网络》(PDF)。收录于鲁杰里 F、肯尼特 RS、法尔廷 FW (编)。支持页面。《质量与可靠性统计百科全书》。约翰·威利父子公司。doi:10.1002/9780470061572.eqr089。ISBN 978-0-470-018613。原始版本 (PDF) 存档于 2016 年 11 月 23 日。获取于 2007 年 8 月 27 日。