

奥林匹克多维预测集成器

摘要

为确保对奥运会奖牌预测采用系统化、多维度的方法，本研究构建了一个动态耦合的综合预测框架。该框架整合了多种目标，包括奖牌分布预测、突破性国家识别、赛事表现评估以及教练资源配置的影响分析。通过运用多源异构数据融合和机器学习集成方法，我们实现了对竞技体育发展模式进行深入分析和可靠预测。

首先，我们开发了一个多维度预测模型来分析奥运会奖牌格局。我们利用主成分分析（PCA）对奥运会赛事数据集进行降维和噪声过滤，结合长短期记忆（LSTM）网络挖掘时间特征，并融入主场优势效应。我们建立了双通道 XGBoost-Bootstrap 模型，以生成具有 95% 置信区间的预测结果。结果显示，美国和英国等国家的奖牌数呈上升趋势，而法国和中国等国家则呈下降趋势。该模型的平均绝对误差（MAE）和平均绝对百分比误差（MAPE）较低，具有较高的准确性和较强的稳健性。通过非参数检验，我们识别出了潜在的突破性国家，其中圣马力诺和科威特获得金牌的突破概率分别为 84.7% 和 68.4%。项目分析表明，游泳、田径与奖牌数之间存在强相关性，而 SHapley 可加性解释（SHAP）则将射击量化为核心贡献项目。主成分分析揭示了游泳和摔跤对奖牌增加的积极驱动作用，为优化体育项目配置提供了依据。

随后，我们开发了一个双重差分（DID）模型来量化更换教练带来的竞争优势，并进行了统计显著性检验和平行趋势检验，以确保研究结果的可靠性。研究发现，在 2020-2024 年期间，澳大利亚、韩国和波兰通过对其教练团队进行战略性重组，产生了显著的“优秀教练”政策效应。基于此，我们建议优先投资于高弹性项目。

最后，我们综合所有模型和分析，以呈现新的见解和相应的决策支持。

关键词：预测模型、主成分分析（PCA）、长短期记忆网络（LSTM）、极端梯度提升（XGBoost）、SHAP 值、双重差分法（DID）

目录

1 引言	3
1.1 问题背景	3
1.2 说明与重述	3
1.3 我们的工作	3
2 建模准备	3
2.1 模型假设	3
2.2 符号说明	4
2.3 数据预处理	4
问题 1: 奖牌预测	5
3.3 奥运项目与奖牌数量	13
3.2 突破零 (奖牌)	10
3.1 奖牌排名	5
3.1 主成分分析: 降维	5
3.1.2 长短期记忆网络: 基于时间的趋势	6
3.1.3 极端梯度提升 - 自助法建模	9
3.1.4 结果展示	9
3.3.1 斯皮尔曼: 数学分析	13
3.3.2 SHAP: 揭示相关性与重要性	14
3.3.3 关系与重要性分析	15
4 问题 2: “伟大教练” 效应	18
4.1 双重差分模型	
4.2 假设检验与贡献系数分析	19
问题 3: 新见解	19
6 - 6.2 预测模型评估	21
敏感性分析	21
6.1 主成分数量	21
7 模型分析	22
7.1 优势	22
7.2 不足与进一步讨论	23
8 备忘录	24
参考文献	25

1 引言

1.1 问题背景

2024 年巴黎夏季奥运会的奖牌榜体现了国际体育竞争的多样性：美国以 126 枚奖牌总数领先，而中国在金牌数量上与之持平。东道主法国通过在奖牌总数上位居第四，凸显了主办的优势。阿尔巴尼亚等新兴体育强国获得了首枚金牌，而超过 60 个国家尚未获得任何奖牌，这反映出竞技资源分布的不均衡。目前的预测在很大程度上依赖于赛前数据；然而，历史趋势、项目调整和教练效应等关键变量尚未得到充分量化。通过构建数据驱动模型，我们能够准确识别潜在的奖牌项目、优化教练资源、利用东道主优势，并揭示“隐形冠军”的崛起路径。这种方法提供了动态见解，有助于各国制定战略，并促进奥运格局的再平衡。

1.2 说明与重述

鉴于该问题的背景信息和限制条件，我们必须完成以下任务：

任务 1：开发一个模型来预测每个国家在 2028 年洛杉矶奥运会上的金牌和总奖牌数量，并将预测结果与 2024 年巴黎奥运会进行比较。

任务 2：使用任务 1 中的模型，确定有望在即将到来的奥运会上赢得首枚奖牌的国家，并估算“零突破”的可能性。

任务 3：分析奥林匹克运动项目与奖牌数量之间的关系，同时考虑东道主国家和选定项目的影响。

任务 4：创建一个模型，以识别在特定运动项目中具有“优秀教练”效应的国家，并提供贡献系数。

任务 5：基于所涉主题及已开展的工作，提出额外的原创见解。

1.3 我们的工作

首先，使用主成分分析（PCA）进行降维。接下来，通过长短期记忆网络（LSTM）融入趋势信息，建立极端梯度提升（XGBoost）预测模型。随后，采用威尔科克森符号秩检验来研究哪些国家在获得首枚奖牌方面取得突破，并确定相应的概率。此外，利用斯皮尔曼相关系数和 SHAP 值进行相关性和重要性分析。最后，应用双重差分法（DID）来检验“伟大教练”效应并提供新的见解。为便于描述和可视化，我们绘制了图 1 来展示我们的工作。

2 建模准备

2.1 模型假设

以下列出了一些基本假设。

- 假设 1：运动员在整个比赛期间都处于最佳身体状态




图 1: 我们的工作流程图

并且他们的表现仅受竞争因素影响。

→ 理由：我们假设运动员将以最佳状态参赛，其表现主要由训练和比赛决定，不包括伤病或外部干扰等因素。

• 假设 2：一个国家过去的奥运会表现是未来奖牌数的可靠指标，且东道主国家由于主场优势往往表现更好。

→ 理由：我们假设历史表现反映了国家体育发展的长期趋势，且东道主能从当地观众的支持以及对比赛环境的熟悉中获益。

2.2 符号说明

表 1: 符号列表

Symbol	Definition
α_c	Each country's home advantage coefficient
$\hat{p}_i$	The host advantage coefficient
β_0	Intercept, the baseline medal count for the control group
β_1	The difference between the treatment and control groups
β_2	The overall change in medal counts from 2020 to 2024
β_3	Contribution coefficient
X_{it}	Control variable matrix
γ	Coefficient of X_{it}
ϵ_{it}	Random error term
$Prep_t$	The preparatory period effect
$Threat_i$	Dummy variable indicating coach change, 1 if changed, 0 otherwise
$Post_t$	Time dummy variable, 1 if the Olympic year is 2024, 0 otherwise

2.3 数据预处理

概述本研究中提供的五个附件，“data_dictionary”等，并综合有关奖牌预测、赛事数量和类型的信息，一个

可以发现,信息的规模构成了一个小型数据集。然而,这些数据冗长且复杂,不同数据点之间存在错综复杂的关系,代表了一种与现实世界场景中的决策相关的数据类型。

- 对于附件 2,我们将与 “summerOly_medal_counts” 数据集进行自然连接,以匹配国家名称及其缩写的列,从而增强所提供的信息。

在数据聚合过程中,我们将根据 “团队” “年份” “运动项目” 和 “奖牌” 字段从附件 2 中检索并整合数据,计算每个国家在每届奥运会赛事中的奖牌数量。此外,我们还将合并和计算不同年份各类运动项目的数据,从而得出每届奥运会的赛事类型和数量,为后续的奖牌预测和趋势分析提供重要的数据支持。

对于附件 5,我们将通过插值法以及删除包含缺失值的行或列来处理 “代码” “体育管理机构” 和 “年份” 列中的缺失值。

3 问题 1: 奖牌预测

本研究致力于预测 2028 年洛杉矶奥运会的奖牌数量。通过考虑奖牌排名的区间预测,并认识到奥运会奖牌趋势类似于马尔可夫链的无记忆特性,我们采用了一种创新的 XGBoost5 算法,该算法通过 PCA 3 和 LSTM37 进行增强,以对金牌和总奖牌排名进行建模预测,同时评估模型的不确定性。利用 2024 年经 PCALSTM 增强的数据集,我们得出了 2028 年各国金牌和总奖牌的预测区间,为成绩预测分析提供了便利。

在预测各国 “破零” 获得金牌的概率方面,我们分析了 XGBoost 的区间预测结果。我们对那些点估计值大于或等于 1 的 Bootstrap 样本进行了对称秩和检验,得出结论: P 值小于 0.05 的国家有可能在 2028 年至少获得一枚金牌。

此外,我们研究了不同奥运项目与各国奖牌数之间的相关性及其重要性。我们首先对 2024 年每个国家的金牌数和总奖牌数与重点奥运项目的加权值进行了斯皮尔曼相关性分析。在我们的 PCA-LSTM 增强 XGBoost 模型的基础上,我们利用 SHAP 分析,根据主成分重要性值来评估每项运动的重要性。单变量依赖图进一步探究了单项运动与整体金牌数和总奖牌数之间的关系,而 SHAP 力图则揭示了各国不同运动项目在金牌数和总奖牌数方面的相互关系及其意义。

3.1 奖牌排名

3.1.1 主成分分析: 降维

在预测奥运会金牌数量和排名时,结果与往届奥运会的奖牌数量及构成密切相关。因此,我们将各国在重大体育赛事中获得的金、银、铜牌分别按 50%、30% 和 20% 的权重进行计算,以评估其对未来奖牌排名的潜在影响。

主成分分析 (PCA) 被用于降低 45 个体育项目的加权奖牌计数数据集的维度。这种方法通过利用不相关的主成分有效解决了原始指标之间的多重共线性问题, 从而消除了冗余, 提高了后续算法的收敛速度和准确性。随后, 图 2 (a) - (b) 展示了主成分分析结果的前两个维度。




图 2: 主成分分析双标图

在 5 维主成分中，累积方差贡献率达到 76.4%，有效捕捉了原始数据的大部分特征。这表明可以将数据降维至 5 维进行分析。图 2（b）显示，射击在主成分上的得分最高，表明其在各项赛事中具有显著影响。紧随射击之后，游泳、田径和摔跤的奖牌权重也较为突出。其余赛事聚类明显，这可能是由于它们的奖牌权重具有相关性。总体而言，游泳、田径、摔跤、射击、艺术体操、拳击和跳水对主成分 1（PC1）有显著影响，这表明它代表了主要运动项目的主成分。相反，其他成分（PC2 至 PC5）受较少变量的影响。通过主成分分析降维，本研究得出了 2020 年奥运会各运动项目奖牌权重的五个主成分特征。致模乐园

3.1.2 长短期记忆网络：基于时间的趋势

预测奥运会奖牌榜可以被视为一个时间序列预测问题，因为各国的奖牌数呈现出时间连续性。体育强国往往能保持较高的奖牌数，而新兴国家可能会取得短期突破。因此，该模型必须捕捉不同奥运会中的模式和长期趋势。

LSTM 在处理时间序列数据中的长程依赖关系方面具有优势。例如，如果一个国家在过去三届奥运会上的奖牌数稳步增加，LSTM 可以识别这一趋势，从而预测其会进一步增长。奥运会四年一届的间隔使得传统模型的效果欠佳，而 LSTM 的门控机制有助于保留重要的历史信息，从而提高预测的准确性。

此外，奥运会奖牌数据可能存在噪声，一些国家的表现并不稳定。长短期记忆网络（LSTM）通过学习更广泛的趋势来减轻这种噪声。它还可以纳入主办国指标等额外特征，以提高预测效果。为了解决数据稀疏性问题，特别是针对数据点有限的小国，我们采用了一种正则化技术。

构建 LSTM 模型的过程如下。

特征设计

每个国家的主场优势系数 α_c 是根据历史数据通过回归分析估算的, 并经过标准化处理以作为权重:

$$\alpha_c = \frac{\text{Gold}_c^{\text{host}} - \text{Gold}_c^{\text{avg}}}{\text{Gold}_c^{\text{avg}}} \quad (1)$$

一个二进制变量 $\text{Host}_t \in \{0, 1\}$ 被用来表示该国是否为 t 年的主办国。引入筹备期效应是为了捕捉筹备阶段投资增加所带来的影响:

$$\text{Prep}_t = \begin{cases} 1 & \text{if } t \in [t_{\text{host}} - 8, t_{\text{host}}] \\ 0 & \text{otherwise} \end{cases} \quad (2)$$

其中 t_{host} 表示举办年份, 而 8 相当于两个奥运周期。

• 每个时间步的输入向量被扩展为:

(3)

• 时间序列建模与特征融合

采用双通道 LSTM 结构分别处理奖牌序列和主场优势特征, 最后通过融合进行预测:

$$\mathbf{h}_t^{\text{medal}} = \text{LSTM}_{\text{medal}}([\text{Gold}_{t-k}, \text{Total}_{t-k}]_{k=1}^{n_{\text{steps}}}) \quad (4a)$$

$$\mathbf{h}_t^{\text{host}} = \text{LSTM}_{\text{host}}([\text{Host}_{t-k}, \text{Prep}_{t-k}, \alpha_c]_{k=1}^{n_{\text{steps}}}) \quad (4b)$$

$$\hat{y}_t = \text{FC}(\mathbf{h}_t^{\text{medal}} \oplus \mathbf{h}_t^{\text{host}}) \quad (4c)$$

其中 $n_{\text{steps}} = 3$ 表示使用过去三届奥运会的数据。表示向量拼接, FC 表示全连接层, $\hat{y}_t$ 是预测结果。

• 损失函数与联合优化

设计了一种分层损失函数, 分别对奖牌预测和主场优势识别进行约束:

$$\mathcal{L} = \lambda_1 \mathcal{L}_{\text{medal}} + \lambda_2 \mathcal{L}_{\text{host}} \quad (5a)$$

$$\mathcal{L}_{\text{medal}} = \frac{1}{N} \sum_{i=1}^N ((y_i^{\text{Gold}} - \hat{y}_i^{\text{Gold}})^2 + (y_i^{\text{Total}} - \hat{y}_i^{\text{Total}})^2) \quad (5b)$$

$$\mathcal{L}_{\text{host}} = -\frac{1}{N} \sum_{i=1}^N [\text{Host}_i \log(\hat{p}_i) + (1 - \text{Host}_i) \log(1 - \hat{p}_i)] \quad (5c)$$

$$\lambda_1 = 0.7, \lambda_2 = 0.3, \alpha = 0.1$$

在 LSTM 模型的调优过程中, 我们主要关注两个参数: 隐藏层中的神经元数量 (hidden_size) 和允许早停的轮数 (patience)。我们采用 WMAE_Gold 和 WMAE_Total (公式 6) 作为比较指标, 首先使用固定的 hidden_size 来进行我们的 (研究 / 操作)。

对比结果如下。如图 3 (a) 和 3 (d) 所示 (圆圈代表误差最小值), 最佳配置为 32×6 。图 3 (b) 和 3 (e) 表明, 64×8 和 64×10 这两种配置均能满足目标; 不过, 在图 3 (b) 中, 64×8 的模型相较于其他参数设置, 误差降低更为显著, 因此我们选择了 64×8 。图 3 (c) 和 3 (f) 显示, 128×10 的性能最佳。

随后, 我们对这三个模型进行了直接比较。如图 4 所示, 32×6 和 128×10 配置的性能相当接近; 尽管如此, 128×10 的整体误差更低。因此, 我们最终确定参数为 $\text{hidden_size} = 128$ 和 $\text{patience} = 10$ 。这一选择为后续涉及 XGBoost 的研究提供了关键的趋势指标。

$$\text{WMAE_Gold or Total} = \frac{\sum w_c |y_c - \hat{y}_c|}{\sum w_c} \quad (6)$$

其中 w_c 是国家 c 's 金牌或总奖牌的权重, y 是真实值, $\hat{y}_c$ 是预测值。




图 3: WMAE Gold 和 WMAE Total 的参数调优变化




图 4: 隐藏层大小的比较

3.1.3 XGBoost - 自助法建模

基于上述主成分分析降维和长短期记忆网络趋势测量，我们得到了极端梯度提升模型的输入数据。随后，我们分别基于金牌数和总奖牌数构建了极端梯度提升预测模型。该模型（图 5）的一个关键方面是通过 10 折交叉验证网格参数调优构建相对最优的极端梯度提升模型，并使用自助重采样策略估计奖牌预测值的置信区间。




图 5: XGBoost-Bootstrap 示意图

XGBoost 是一种基于梯度提升树的集成学习算法，其核心是通过构建多个 CART 基分类器对损失函数进行增量式和并行化优化。它对目标函数采用二阶泰勒展开，提高了梯度下降的效率，同时在目标函数中融入正则化项，有效防止模型过拟合。该算法旨在利用这些特性来阐明金牌数、奖牌总数、主场优势、个人项目奖牌权重值和奖牌趋势值之间的非线性关系。目标函数为公式 7，其中 $l(\cdot)$ 是损失函数， $\Omega(\cdot)$ 是正则化项。

Bootstrap 是一种非参数重采样方法。通过采用这种方法，我们独立运行构建的 XGBoost 模型 1000 次，从而能够基于这些迭代计算每个国家的金牌和总奖牌拟合值的 95% 置信区间。

3.1.4 结果展示

预测模型的超参数调优采用均方根误差（RMSE）作为评估标准，旨在选择均方根误差值最小的模型（详见第 6.2 节的详细分析）。在金牌预测模型的训练过程中，

通过超参数调优确定了模型参数的最佳组合, 结果如下: $nrounds = 75$, $max_depth = 2$, $eta = 0.1$, $gamma = 0.5$, $colsample_bytree = 1$, $min_child_weight = 1$, 以及 $subsample = 0.5$ 。值得注意的是, $subsample$ 参数在整个调优过程中保持不变, 设置为 0.5 以确保合理的采样比例。

在奖牌预测模型的训练过程中, 与金牌预测模型相比, 唯一的变化是对 $gamma$ 参数的调整。在该模型中, $gamma$ 值被设置为 0.25, 以优化模型对奖牌数量的预测能力。因此, 我们采用了相对最优的 XGBoost 模型, 对 “2028 年各国金牌和奖牌数量趋势值”、“2024 年各运动项目奖牌权重的五个主成分维度” 以及 “2028 年估计主场效应值” 进行 Bootstrap 重采样和区间估计。2028 年洛杉矶奥运会金牌数和奖牌总数排名前 20 的国家的结果如图 6 (a) – (b) 所示。




图 6: 2028 年奥运会金牌和奖牌数预测前 20 名

根据图 6 (a) – (b) 和表 2 可以看出, 作为东道主, 美国预计在 2028 年奥运会上的金牌数和奖牌数都将大幅增加。此外, 英国、澳大利亚、加拿大和古巴等国家的金牌数和奖牌数也可能有所上升。相比之下, 2024 年奥运会的东道主法国由于主场优势, 有望取得前所未有的成绩, 但模型预测显示, 在接下来的奥运会上, 其金牌数和奖牌数将显著下降。同样, 中国、意大利、韩国、日本和乌兹别克斯坦等国家在下一届奥运会上的表现也可能不佳。

3.2 突破零

基于上述分析以及实现 “零的突破” 的标准, 我们确定了预计在 2028 年至少获得一枚金牌的国家。

表 2：2028 年奥运会前 20 名国家的预测奖牌数及置信区间

Gold				Total			
NOC	Gold_Pred	CI_95%	Trend	NOC	Total_Pred	CI_95%	Trend
USA	51	(32.08,58.34)	↑	USA	133	(79.60,147.35)	↑
CHN	34	(23.33,40.19)	↓	CHN	90	(59.13,103.51)	↓
AUS	19	(10.41,16.13)	↑	GBR	69	(43.12,75.84)	↑
JPN	17	(11.88,18.80)	↓	JPN	55	(38.19,64.94)	↓
GBR	16	(11.92,19.12)	↑	AUS	49	(33.37,63.77)	↑
FRA	12	(9.00,14.86)	↓	FRA	41	(29.86,60.60)	↓
GER	12	(8.41,14.38)	↓	NED	34	(24.58,39.30)	↑
ITA	11	(7.06,13.03)	↓	GER	33	(25.18,48.98)	↓
NED	11	(6.84,13.18)	↓	CAN	29	(21.72,33.68)	↑
NZL	11	(4.82,9.33)	↑	ITA	29	(22.58,34.13)	↓
CAN	10	(5.73,11.70)	↑	KOR	25	(18.08,34.28)	↓
HUN	8	(5.18,10.87)	↑	BRA	21	(14.67,24.32)	↑
KOR	7	(5.69,9.38)	↓	NZL	18	(13.98,23.86)	↓
BRA	6	(3.70,8.06)	↓	HUN	17	(13.00,22.69)	↓
ESP	5	(3.08,6.72)	↓	CUB	15	(10.91,18.57)	↑
UKR	5	(3.39,7.88)	↑	ESP	14	(8.84,19.47)	↓
KEN	5	(2.51,6.01)	↓	SWE	12	(7.06,14.99)	↑
CUB	4	(2.36,5.92)	↑	UZB	11	(8.45,13.61)	↓
UZB	4	(1.96,5.83)	↓	KEN	9	(7.63,14.35)	↓
TPE	4	(2.79,4.53)	↑	UKR	9	(6.96,11.12)	↓

奥运会中的北马其顿（MKD）、博茨瓦纳（BFA）、*TKM*、沙特阿拉伯（KSA）、圣马力诺（SMR）和科威特（KUW）。我们将对从这些国家的 Bootstrap 重抽样得出的点估计进行符号秩检验，以统计评估它们是否能实现这一金牌突破。通过考虑 P 值的大小，这些观察结果的显著性将得到进一步阐明，P 值表明了事件发生的概率。

选择使用符号秩检验，而非采用单样本 t 检验，或定义“获得金牌”这一二元变量以应用逻辑回归或二元分类机器学习算法，是基于以下考虑。

符号秩检验是一种非参数方法，它不需要对潜在总体的分布做任何假设。相比之下，t 检验是一种参数方法，它假设数据来自正态分布的总体，或者样本本身是正态分布的。因此，非参数检验更符合现实场景，从而将出现重大误差的可能性降到最低。

- 为“赢得金牌”设置一个二元变量来设计分类算法，并计算各国实现“零的突破”的估计概率，会用定性变量取代金牌数量这一定量变量。这种方法忽略了特征变量之间的相关性，可能会导致有偏差且不合理的结果。

基于上述分析，我们将采用符号秩检验来从统计学角度确定金牌突破的显著性，并提供概率估计。

1. 假设检验设置

令 d_{ij} 表示第 j 个国家的第 i 个 Bootstrap 预测值, θ_j 表示相应总体的对称中心。当最终预测值为 $\hat{\theta}_j > 1$ 时, 我们建立一个位置参数为 1 的左侧符号秩检验:

$$H_0: \theta_j = 1 \quad \text{vs.} \quad H_1: \theta_j < 1$$

2. 数据转换和统计量构建

我们对原始数据 $d_{ij}^* = d_{ij} - 1$ 执行移位变换。接下来, 我们计算绝对值秩 R_{ij}^+ 和指示变量:

$u_{ij} = I(d_{ij}^* < 0)$ 。在排除 $d_{ij}^* = 0$ 的数据点后, 我们构建符号秩和统计量:

$$w_j^+ = \sum_{i=1}^{n_j} u_{ij} R_{ij}^+$$

其中 n_j 是调整后的有效样本量。

3. 渐近正态性

在大样本条件下, 当原假设为真时, w 服从正态分布:

$$\sigma_j^2 = \frac{n_j(n_j + 1)(2n_j + 1)}{24} - \frac{\sum_{i=1}^k (t_i^3 - t_i)}{48}$$

4. P 值计算

如果 P 值小于或等于 0.05, 即落在拒绝域内, 则可以得出结论: 从统计学角度来看, 该国无法在 2028 年奥运会上实现金牌 “零的突破”。相反, 如果 P 值大于 0.05, 则表明该国很有可能实现金牌 “零的突破”。此外, P 值越大, 犯第二类错误的概率就越小, 从而增加实现金牌 “零的突破” 的可能性。基于上述建立的模型, 图 7 和表 3 展示了针对有望实现金牌 “零的突破” 的国家进行的威尔科克森符号秩检验结果。

根据表 2 和 2024 年参赛国家的金牌数量, 确定有 8 个在 2024 年未获得任何金牌的国家可能在 2028 年实现金牌突破。历史数据显示, 加纳 (GHA) 和格林纳达 (GRD) 分别在 1960 年和 2012 年实现了零金牌的突破。

从表 3 中我们可以看出, 只有两个国家, 即 SMR 和 KWT, 其检验统计量对应的 P 值大于 0.05, 这表明它们没有落在




图 7：小提琴 - 雨云混合图

表 3：符号秩和检验表

NOC	w^+	p	pred
GRD	538231	1	1
GHA	532048	1	1
SMR	498067	0.847	2
KWT	389859	0.684	1
SAU	222158	0.0011	1
TKM	197115	3.01e-09	1
MKD	153243	1.22e-26	1
BFA	153243	1.22e-26	1

拒绝域。这表明，预测的 SMR 和 KWT 在 2028 年奥运会上的金牌数显著大于 1，这意味着这两个国家很可能实现金牌“零的突破”，概率分别为 0.847 和 0.684。

根据表 3，SMR 在 2028 年奥运会上的预测金牌数为 2 枚，95% 近似置信区间为 [1, 3]，表明预测相对稳定。对于 KWT，预测金牌数为 1 枚，95% 近似置信区间为 [0, 2]。图 7 中的小提琴图显示，KWT 的大部分预测数据落在 1 到 2 的范围内。

3.3 奥运会项目与奖牌数量

我们选择使用 SHAP1.10 分析工具来进行奥运会项目与奖牌数量之间的相关性分析和重要性衡量。

3.3.1 斯皮尔曼：数学分析

斯皮尔曼相关系数是一种非参数的秩相关度量。与皮尔逊相关系数不同，后者仅限于描述线性关系且要求数据服从正态分布，而斯皮尔曼相关系数是基于秩次计算的。这种方法使其对异常值的敏感性较低，并能更稳健地反映变量之间的相关程度。

斯皮尔曼相关系数的数学定义如下:

$$\rho = \frac{\frac{1}{n} \sum_{i=1}^n (R(x_i) - \overline{R(x)}) (R(y_i) - \overline{R(y)})}{\sqrt{\frac{1}{n} \sum_{i=1}^n (R(x_i) - \overline{R(x)})^2} \cdot \sqrt{\frac{1}{n} \sum_{i=1}^n (R(y_i) - \overline{R(y)})^2}} \quad (8)$$

其中, $R(\cdot)$ 表示样本中变量的秩。

提出假设:

$$H_0: \rho = 0 \quad \text{vs.} \quad H_1: \rho \neq 0$$

构建 t 检验统计量, 并使用拒绝域做出判断:

$$t = \frac{|\rho|}{\sqrt{\frac{\rho^2}{n-2}}} \stackrel{H_0}{\sim} t(n-2)$$
$$w = \left\{ (x, y) \mid t > t_{\alpha}(n-2) \right\}$$

显著性 t 检验通常在 0.05 的显著性水平下进行。在本研究中, 我们根据 2024 年巴黎奥运会各项目的权重值, 计算了斯皮尔曼相关系数, 并针对各国获得的金牌数和总奖牌数进行了假设检验。该分析旨在从数学角度探究不同项目与其各自的金牌数和奖牌数之间的相互关系。

3.3.2 SHAP: 揭示相关性和重要性

SHAP 是一种基于博弈论的工具, 可增强机器学习模型的可解释性。其核心优势在于能提供一致、精确且公平的解释。选择 SHAP 分析工具来研究每项运动与不同国家之间的相互关系及重要性, 其理由如下:

预测结果的贡献

SHAP 的基本功能是计算每个特征对最终预测结果的贡献, 同时指出这种贡献的方向——正或负。通过结合主成分分析 (PCA) 载荷矩阵, SHAP 利用蜂群图和重要性图, 能够量化每项运动在金牌数和总奖牌数方面的重要性。

非线性处理和特征依赖性

当多个特征相互作用时, SHAP 可以揭示 XGBoost 模型中每个特征的非线性关系。它为每个特征提供准确的贡献分数, 单变量依赖图则展示了不同运动项目的主成分对金牌数和奖牌数的影响。

局部和全局解释

除了上述分析外, SHAP 还为

单个样本，能够对每个特征的贡献程度进行详细检查。这有助于深入分析不同运动项目与各个国家之间的关联。具体而言，通过利用单个样本的 SHAP 力导向图，可以观察到哪些运动项目对特定国家的奖牌数量有主要影响。

3.3.3 关系与重要性分析

根据斯皮尔曼相关系数公式和假设检验，剔除了相关系数不显著的运动项目，如摔跤、沙滩排球、手球、蹦床体操和自行车。图 8 展示了 2024 年巴黎奥运会金牌、奖牌总数与各类运动项目之间的相关性。




图 8：斯皮尔曼相关系数热力图

斯皮尔曼相关性分析揭示了几个关键见解：游泳、田径和射击等运动项目的金牌数与总奖牌数之间存在很强的相关性，这主要是因为这些项目包含多个小项，从而提升了奖牌潜力，而且体育强国在游泳和田径项目上表现尤为突出。相反，篮球、排球等团队运动以及赛艇、皮划艇等一些集体运动的金牌数与总奖牌数之间的相关性较弱，这是因为尽管这些项目的总奖牌数较多（这归因于各国更广泛的参与），但金牌分布较为分散。此外，滑板和空手道等新增项目的金牌相关性较低（0.210），但总奖牌相关性较高（0.496），这表明在总奖牌数增加的同时，金牌分布更为分散。这些运动项目的发展可能源于更多的参与和竞争，这有助于实现更公平的奖牌分配。

此前构建的 2028 年奥运会金牌和总奖牌数 XGBoost 预测模型，基于训练集计算 SHAP 值，得到了图 9 中五个主成分特征的六边形重要性混合图。在金牌预测模型中，两个最重要的主成分是 PC1（0.8345）和 PC2（0.1055）。对于总奖牌数预测模型，主要成分是 PC1（0.6242）和 PC5（0.3024），这与 PC1 的最高方差贡献相符。然后，将各个项目在主成分上的载荷绝对值按主成分的重要性进行加权、求和并归一化，以计算它们的重要性，如图 10 所示。

主成分分析（PCA）和 SHAP 分析揭示了关于体育运动的重要见解。射击和体操在金牌和总奖牌的重要性排名中位列前三，凸显了它们在奥运会中的关键作用。射击项目的多样性以及体操项目有美国和中国等国家的大量参与，促成了它们的排名。游泳在……中排名第三。




图 9：细胞重要性混合图

Sports	Total_importance	Sports	Gold_importance
Shooting	1.0000	Artistic.Gymnastics	1.0000
Table.Tennis	0.9500	Shooting	0.9363
Artistic.Gymnastics	0.9291	Swimming	0.9039
Diving	0.9193	Wrestling	0.8524
Baseball/Softball	0.9185	Basketball	0.8074
Artistic.Swimming	0.8982	Golf	0.7686
Swimming	0.8769	3x3.Basketball	0.7562
Golf	0.8575	Diving	0.7453
Wrestling	0.8502	Baseball/Softball	0.7372
Weightlifting	0.8446	Volleyball	0.7179
Basketball	0.8443	Surfing	0.7150
Surfing	0.8289	Table.Tennis	0.7033
3x3.Basketball	0.8080	Athletics	0.7023
Badminton	0.8049	Artistic.Swimming	0.6873
Skateboarding	0.8015	Boxing	0.6759

图 10：前 15 名体育赛事重要性得分

金牌的重要性（0.9039）源于其多样性和竞争性。乒乓球

的金牌重要性虽较低，但总奖牌数排名第二（0.95），这反映出其全球受欢迎程度以及中国在该项目上的主导地位。跳水和摔跤也具有重要意义，其中跳水彰显了中国的故乐园

接下来，我们将为具有最高 SHAP 重要性的 PC1 创建单变量依赖图。这项分析将阐明 PC1 与奖牌数量之间的非线性关系，突出游泳、田径、摔跤、体操和篮球等运动项目的贡献。

在金牌预测模型（图 11（a））中，主成分 1（PC1）的负值区域与负荷较高的运动项目密切相关，如游泳、田径、摔跤、体操和篮球。当 PC1 为负值时，这些项目表现出色，对金牌数量有显著贡献。依赖图中的上升趋势表明，这些运动项目的优异表现会使金牌数量大幅增加，凸显了它们的关键影响，尤其是在 PC1 负值区域。当 PC1 变为正值时，它们的影响力减弱，这表明它们对金牌数量的影响主要集中在负值区域。同样，在总奖牌预测模型（图 11（b））中，这些相同的运动项目对总奖牌数量有显著影响；当 PC1 为负值时，这些项目的优异表现会同时增加金牌和总奖牌的数量。依赖图中 SHAP 值的上升表明，它们的出色表现不仅对金牌有显著贡献，对银牌和铜牌也同样如此。当 PC1 变为正值时，它们对总奖牌数量的影响力减弱，这进一步证实了它们在 PC1 负值区域的关键作用。




图 11: PC1-SHAP 混合图

最后，本研究纳入了单个样本的 SHAP 值，以分析不同运动项目对美国和法国的金牌及奖牌总数预测的影响，尤其关注游泳和田径等传统强国项目的贡献。此外，研究还探讨了东道主效应，分析 2024 年东道主法国和 2028 年东道主美国如何通过主场优势对金牌和奖牌总数的预测产生积极影响。




图 12: 2028 年美国奖牌和金牌预测 SHAP 图




图 13: 2028 年法国奖牌和金牌预测 SHAP 图

图 12 (a)-(b) 显示，游泳和田径等传统优势项目在主成分分析（PCA）的成分中占很大比重，尤其是在主成分 PC1 和 PC2 中具有较高的载荷，这表明它们对美国金牌数量有显著贡献。金牌预测的 PC1 值为 18，这证实了这些项目的主导作用。相比之下，美国的总奖牌数预测为 133 枚。

其中 PC2 的贡献为 6.08，这揭示了体操和篮球等其他运动项目的影响——尽管这些项目贡献的金牌较少，但在提高总奖牌数方面发挥着至关重要的作用。对于 2024 年奥运会的东道主法国，预测（图 13（a）-（b））明显受到“东道主效应”的影响，其总奖牌数预计为 41 枚，PC5 的显著贡献为 2.89，这凸显了自行车和马拉松等运动项目的重要性。尽管法国的金牌预测相对较低，为 12 枚，但东道主效应积极提升了法国的整体表现，特别是在游泳和田径等项目中，PC3 的载荷为 1.97，证实了这些项目的贡献。虽然法国在这些项目上的传统优势可能不及美国，但主场优势有助于缩小差距。

本分析得出结论，运动项目的选择和传统优势在奥运会表现中起着决定性作用，美国主要在游泳和田径等个人项目中表现出色，而法国则受益于团队项目和东道主效应。总体而言，东道主效应对两国的奥运会表现都有显著影响，法国作为 2024 年东道主有望获得显著提升，而美国在 2028 年将面临新的挑战。

4 问题 2：“伟大教练”效应

从问题 2 的陈述中可以明显看出，教练的流动性大于运动员，这表明他们的转会可能会对一个国家的奖牌表现产生直接影响。*DID*⁴模型适用于通过比较处理组（有教练变动的国家 - 运动项目组合）和对照组（无教练变动的组合）在事件前后的变化，来评估政策或事件的因果效应。该问题还需要估算教练效应对奖牌数量的贡献，这就需要量化因教练变动而增加的奖牌数。此外，还需要选出三个国家，针对它们应在哪些运动项目上投资教练提出建议，同时估算此类投资的潜在影响。

4.1 DID 建模

双重差分模型（DID）的有效性依赖于平行趋势假设，该假设指出，在教练更换之前，处理组和对照组的奖牌数量趋势应保持一致。这一假设需要进行验证，否则结果可能存在偏差。最后，分析结果必须结构清晰，明确每个国家的推荐运动项目、教练效应当前的贡献系数以及预期投资回报。此外，还应讨论估计值的不确定性，如置信区间和 P 值，以提高结论的可信度。因此，我们构建了以下双重差分模型。

$$\min_{\beta, \gamma} \sum_{i,t} (\text{Medals}_{it} - (\beta_0 + \beta_1 \text{Treat}_i + \beta_2 \text{Post}_t + \beta_3 (\text{Treat}_i \cdot \text{Post}_t) + \gamma X_{it}))^2$$

$$\text{s.t.} \begin{cases} \text{Medals}_{it} = \beta_0 + \beta_1 \text{Treat}_i + \beta_2 \text{Post}_t + \beta_3 (\text{Treat}_i \cdot \text{Post}_t) + \gamma X_{it} + \epsilon_{it}, \forall i, t & (9) \\ E[\Delta \text{Medals}_i | \text{Treat} = 1, \text{Post} = 0] = E[\Delta \text{Medals}_i | \text{Treat} = 0, \text{Post} = 0] \\ \epsilon_{it} \perp \text{Treat}_i, \text{Post}_t \end{cases}$$

4.2 假设检验与贡献系数分析

随后, 我们使用普通最小二乘法 (OLS) 拟合模型方程, 以估计系数 β_0 、 β_1 、 β_2 、 β_3 。我们计算 β_3 的 P 值以评估其显著性。此外, 我们进行了平行趋势检验, 以验证在教练变更之前, 处理组和对照组的奖牌趋势是否一致。综合结果如表 4 所示。

表 4: 双重差分模型关于优秀教练效应的结果

NOC	Sport	β_3	P-value	95% confidence interval
JPN	Judo	6.0	0.001	[4.8, 7.2]
ITA	Athletics	5.0	0.010	[3.5, 6.5]
AUS	Swimming	5.0	0.020	[3.0, 7.0]
KOR	Archery	4.0	0.030	[2.0, 6.0]
POL	Athletics	4.0	0.040	[1.5, 6.5]
CUB	Boxing	3.0	0.100	[-0.5, 6.5]
KOR	Fencing	3.0	0.200	[-1.0, 7.0]
CHN	Diving	3.0	0.150	[-0.8, 6.8]
CHN	Shooting	3.0	0.180	[-1.2, 7.2]
BRA	Skateboarding	3.0	0.250	[-2.0, 8.0]

我们选取了 β_3 的前 10 个值展示在图 14 中。从表 4 可以看出, 日本柔道、意大利田径、澳大利亚游泳、韩国射箭和波兰田径的教练变动显著增加了奖牌数量, 因为它们的置信区间均不包含零, 且所有 P 值都小于 0.05。相比之下, 古巴拳击、韩国击剑、中国跳水和射击以及巴西滑板的 β_3 值为正值, 但置信区间包含零, 且 P 值超过 0.05, 这表明这些国家教练变动的因果效应未通过统计显著性检验。接下来, 我们以日本为例进行了平行趋势检验。图 15 显示, 1996 年至 2016 年期间, 奖牌数量呈明显上升趋势, 表明其成功通过了平行趋势检验。

因此, 我们重点关注了通过统计显著性检验和平行趋势检验的前 5 个国家。查阅数据 123 后, 证实澳大利亚、韩国和波兰在 2020-2024 年期间确实发生了教练变动, 具体涉及的分别是 Rennie Taylor、Lee Changhoon 和 Adam Kszczot。这与上述结果一致, 表明我们的模型是有效的。

5 问题 3: 新见解

1. 奖牌数量的时空动态变化

(1) 见解: 该模型通过多次迭代和自助重采样方法分析了奥运会奖牌数量的时空动态。研究表明

¹<https://olympics.com>

²<https://www.insidethegames.biz>

³<https://www.linkedin.com>




图 14：按贡献系数排名的前 10 个国家



图 15：1996 年至 2016 年日本奖牌获得趋势

一些国家在不同的奥运周期中表现相对稳定，而另一些国家的奖牌数则出现显著波动。例如，一些大国的奖牌数波动范围较小，这凸显了它们在多个项目中持续的竞争力。相比之下，一些小国的奖牌数波动更大，这表明它们的表现可能深受特定赛事或突发情况的影响。

(2) 决策支持：研究结果可以帮助奥委会为未来的奥运周期制定更灵活的策略。如果一个国家的奖牌数量出现不稳定情况，奥委会可以通过多样化资源分配来降低不确定性，从而避免过度依赖任何单一项目。例如，增加对不稳定项目的训练投入，以及提高其他有潜力运动项目的竞争力，有助于确保各项目表现的稳定性。此外，对于表现较为稳定的国家，奥委会可以专注于保持现有优势，同时加强研究和技术支持，以确保它们在前沿领域保持竞争力。

2. 奥运会奖牌数量与特定项目之间的相关性

(1) 见解：该模型通过整合主成分分析（PCA）和长短期记忆网络（LSTM），揭示了某些特定项目在预测奖牌数量方面的重要性。研究表明，游泳、田径和射击等项目在许多国家的奖牌贡献中起着关键作用。这些项目不仅在奥运会上广受认可且竞争激烈，也是各国争夺奖牌的重要战场。特别是游泳和田径，由于其比赛场次多、观众参与度高，成为许多国家奖牌数量的主要来源。

(2) 决策支持：奥委会可以利用这些分析结果进行战略规划，特别是在资源分配和赛事发展方面。对于那些展现出强大竞争优势的项目，各国可以通过提供额外的训练设施和资金支持来增加投入。例如，在游泳和田径项目特别强势的国家，奥委会可以与国内外顶尖教练合作，以提升运动员的技能和整体表现，从而加强运动员训练。此外，在数据分析的指导下，各国可以提前确定潜在的夺牌项目，这使它们能够为这些项目制定有效的运动员发展计划和推广策略。

3. 国家战略中的教练投资方向

- (1) 见解：通过模型分析，一些国家在更换教练后表现出强劲的奖牌回报，如澳大利亚。相反，其他国家尽管进行了教练变动，但所受影响微乎其微。
- (2) 决策支持：奥委会应根据不同国家的具体情况制定个性化策略，优先支持那些在更换教练后取得显著进步的项目。对于日本、意大利和澳大利亚等国家，奥委会可以增加在柔道、田径和游泳项目上的投入，以提高奖牌回报率。同时，对于那些成效不太明显的项目，奥委会可以减少在相关教练团队上的过多投入，并重新分配资源，将重点放在更有可能产出奖牌的领域。

6 敏感性分析

6.1 主成分数量

为简化数据结构并提高预测模型的效率，我们使用了主成分分析（PCA）。对奥运会赛事数据集进行了主成分分析，并计算了每个主成分的方差贡献率。选择 5 个主成分的依据是它们解释了 76.4% 的累积方差，有效捕捉了原始数据集中的大部分信息。这一选择得到了图 16 的支持，该图显示前几个主成分之后出现了急剧下降，验证了使用 5 个主成分的合理性。这种方法在保留关键信息、消除冗余特征的同时降低了数据维度。




图 16：主成分选择的碎石图

6.2 预测模型评估

在模型评估中，我们既考察了金牌预测模型和总奖牌预测模型的预测准确性，也考察了它们的稳健性。

1. 预测准确性

通过 10 折交叉验证和 Bootstrap 重采样，我们得到了两个模型的预测区间和置信水平。在金牌预测模型中，测试集的均方误差（MSE）为 6.83，均方根误差（RMSE）为 2.61。尽管这些数值略高于训练集，但平均绝对误差（MAE）为 0.52，平均绝对百分比误差（MAPE）为 14.47%，这表明该模型对新数据的准确性仍然是可接受的。总奖牌预测模型表现更为稳定，其 MSE 和 RMSE 更低，说明预测精度更高。这些结果汇总于表 5 中。

表 5: 模型评估指标

	Gold		Total	
	Training	Test	Training	Test
MSE	1.33	6.83	28.5	6.46
RMSE	1.16	2.61	5.34	2.54
MAE	1.49	0.52	3.68	1.04
MAPE	17.50%	14.47%	18.63%	16.13%

2. 稳健性评估

为了评估模型的稳健性，我们重点关注了 R^2 值以及 10 折交叉验证的 R 平方线图，如图 17

(a) – (b) 所示。结果显示，金牌和总奖牌预测模型的 R^2 值均接近 1，这表明模型对数据的拟合效果良好，在不同数据集上表现稳定，具有较强的泛化能力。




图 17: R^2 在 10 折交叉验证中的值

7 模型分析

7.1 优势

本研究的创新点和优势在于通过整合 PCA-LSTM 增强的 XGBoostBootstrap 算法，开发了一个奥运会奖牌数预测模型。此外，本研究通过多种统计方法对模型的准确性和稳定性进行了全面验证，同时采用 DID 框架评估教练变动对奥运会奖牌数的影响。这具体体现在以下几个方面：

Bootstrap 重抽样方法的引入为预测结果的置信区间估计提供了便利，量化了模型的不确定性并增强了结果的可信度。此外，平行趋势假设检验的应用确保了实验组和对照组在教练变更更前呈现出一致的奖牌趋势模式，进一步提高了模型的稳定性和推断的准确性。

- 本研究通过整合 SHAP 值分析，对不同运动项目对奖牌数量的贡献进行了全面评估，揭示了影响结果的关键因素。值得注意的是，在分析东道主国家时，研究结果表明主场优势对奖牌总数有显著影响，从而提高了模型的可解释性，并为决策提供了更具可操作性的见解。

双重差分模型（DID）的运用能够评估教练变动对奖牌数量的因果效应，精准量化此类变动对奥运表现的影响，并确保因果推断的可靠性。此外，将主成分分析（PCA）用于降维和长短期记忆网络（LSTM）用于趋势建模相结合，提高了奖牌数量的预测准确性，展现出强大的建模能力，尤其在处理复杂的非线性关系和时间序列数据方面表现突出。

7.2 局限性与进一步讨论

我们的模型存在一些局限性和不兼容性。例如，XGBoost 和 Bootstrap 方法的计算成本相对较高，尤其是在处理大型数据集时，这会影响模型的实时适用性。此外，应用 PCA 进行降维可能会导致信息丢失，进而影响模型捕捉复杂关系的性能。虽然 LSTM 能够识别趋势，但在应对突发事件和剧烈波动时，其预测能力有限，这降低了模型的稳健性。再者，DID 模型假设教练变动对奖牌数量的影响是线性的；然而，实际上这些影响可能是非线性的，这导致无法充分捕捉数据中存在的复杂关系，并影响因果推断的准确性。

该模型未来的改进将聚焦于两个关键领域。首先，奥运会奖牌数预测模型将通过先进的集成学习技术，加强对赛事波动、政治因素和运动员表现变化的整合。通过优化加权平均和堆叠建模，该模型将纳入更广泛的变量，并通过强大的实时数据更新机制提高短期预测准确性。强化学习的应用将进一步增强其长期预测能力，提高对突发事件和政策变化的适应性，同时提升计算效率，以实现更及时、更准确的预测。其次，增强型双重差分模型（enhanced-DID）将把差异化影响分析与深度学习技术相结合，以优化奖牌预测。通过纳入随机模拟，该模型将动态调整教练变动对奖牌数的影响，显著提高其在波动环境中的适应性，并提升整体预测效果。

8 备忘录

致：国际奥林匹克委员会

发件人：2500759 号团队

主题：2028 年奥运会奖牌预测及见解

日期：2025 年 1 月 26 日

尊敬的国际奥委会成员：

我们很高兴提交我们针对 2028 年洛杉矶夏季奥运会奖牌预测模型的解决方案。我们团队基于 2024 年巴黎奥运会的数据和额外的背景信息开发了该模型，不仅能提供精准的奖牌预测，还能提升奥运表现提供有价值的见解。

为构建该模型，我们利用历史奖牌数据，并采用主成分分析 - 长短期记忆增强的极端梯度提升 - 自助法进行初步预测。随后，我们通过考虑 2024 年奥运会的赛事设置和竞争结构来调整这些预测，分析这些因素如何影响不同国家的奖牌数量。为估计预测中的不确定性，我们提供了金牌和总奖牌数的置信区间。

我们模型的一个重要组成部分是对“伟大教练”效应的分析，我们通过双重差分模型（DID）将其整合进来。通过比较有教练变动和无教练变动的国家，我们估算了教练更替对奖牌结果的增量影响。我们使用普通最小二乘法（OLS）拟合该模型，并进行统计显著性检验和平行趋势检验，以确保结果的可靠性。

除了简单预测奖牌数量外，我们的模型还能优化奥运表现提供见解。它指出，哪些国家可以通过有策略地增加在特定运动项目上的投入，有望在这些项目中取得突破。此外，我们的模型还对奥运赛事的类型和设置提出了潜在的改进建议，推荐了有助于最大化奖牌成果的调整方案。这些发现可以为各国奥委会在规划 2028 年及以后的奥运会时提供决策指导。

感谢您提供参与这个重要项目的机会。我们期待您的宝贵反馈。

您诚挚的，
第 2500759 号团队

参考文献

- [1] SM Khorshed Alam、李佩月、Mahbubur Rahman、Misbah Fida 和 Vetrimurugan Elumalai。影响中国西北银川地区地下水硝酸盐水平的关键因素：使用极端梯度提升（XGBoost）模型结合 Shapley 加法解释（SHAP）方法的研究。《环境污染》，364: 125336, 2025 年
- [2] 陈若冰、张明鑫、徐晓和刘永峰。用于区分奥运会篮球比赛胜负队伍的赛事相关统计数据：比赛节奏的影响。《体育科学杂志》，第 1-12 页，2025 年。
- [3] 陈跃建、刘雪梅、饶梦、秦勇、王志鹏和纪元进。用于变速条件下非平稳齿轮箱振动表征和故障检测的显式速度积分 Istm 网络。《可靠性工程与系统安全》，254:110596, 2025。
- [4] 安德鲁·古德曼 - 培根。具有治疗时间变化的双重差分法。《计量经济学杂志》，225 (2): 254-277, 2021。
- [5] 李江涛、安兴琴、李清勇、王超、于浩民、周新元、耿杨柳。XGBoost 算法在污染物浓度优化中的应用。《大气研究》，276:106238, 2022。
- [6] 廖文龙、王首翔、杨德昌、杨哲、方建农、克里斯蒂安·雷坦茨、费尔南多·波特 - 阿赫尔。《TimeGPT 在负荷预测中的应用：大型时间序列模型视角》。《应用能源》，第 379 卷: 124973, 2025 年。
- [7] 本杰明·林德曼、本杰明·马施勒、娜达·萨赫拉布和迈克尔·魏里奇。基于 Istm 网络的技术系统异常检测综述。《工业计算机》，131:103498, 2021。
- [8] 图伊·H·诺兰、杰夫·戈德史密斯和大卫·鲁珀特。基于变分消息传递和多层扩展的贝叶斯函数主成分分析。《贝叶斯分析》，20 (1):1459-1485, 2025。
- [9] 杨承宏、李博西、李怡茵、钟玉芳和林育达。一种基于自编码器的算术优化聚类算法，用于增强主成分分析以研究房地产行业市场股票指数之间的关系。《专家系统与应用》，266: 126165, 2025。
- [10] 张君毅、马向龙、张家兰、孙德亮、周新志、米长林和文海佳。基于 SHAP-XGBoost 模型的滑坡易发性地理空间异质性洞察。《环境管理杂志》，332: 117357, 2023。

人工智能使用报告

1. OpenAI ChatGPT (2025 年 1 月 25 日版本, ChatGPT-4)

问题 1: 主成分分析 (PCA) 是如何降维的?

输出: 首先进行数据标准化, 因为这是主成分分析 (PCA) 的前提。接下来, 计算协方差矩阵或相关矩阵, 这一步是为了捕捉变量之间的关系。然后, 进行特征值分解, 而选择主成分的数量是关键步骤。最后, 将数据投影到新的特征空间, 这就是降维后的结果。

2. OpenAI ChatGPT (2025 年 1 月 25 日版本, ChatGPT-4)

查询 2: 如何使用 SHAP?

输出: SHAP 是一种基于博弈论的模型预测解释方法。它通过计算每个特征对模型输出的贡献, 帮助理解模型是如何做出特定预测的。假设你已经安装了 SHAP 库, 接下来需要选择一个要解释的模型。例如, 你可以使用一个训练好的随机森林模型, 然后用 SHAP 来解释其预测结果。步骤可能包括: 加载数据、训练模型、创建 SHAP 解释器、计算 SHAP 值, 最后可视化结果。加载数据时, 需要确保数据经过预处理, 比如标准化或对分类变量进行编码。然后训练模型, 例如使用随机森林分类器。之后, 创建一个 SHAP 的解释器对象, 这可能需要传入模型和数据。计算 SHAP 值时, 可能需要使用解释器的 `shap_values` 方法传入测试样本。

3. OpenAI ChatGPT (2025 年 1 月 25 日版本, ChatGPT-4)

问题 3: 如何量化优秀教练效应的影响?

输出: 将奖牌数量作为因变量, 考虑历史奖牌数、东道主优势、运动员人数、经济指标 (如有) 以及是否引进优秀教练 (作为虚拟变量) 等因素。