

基于 Tobit 和 Hurdle 模型的奖牌预测及优秀教练效应洞察

摘要

在问题 1 中，本文提出了一种 Hurdle-Tobit 融合模型框架，以解决奥运会奖牌数量的离散性、零膨胀特征以及国家间异质性问题。Hurdle 模型通过两阶段建模（logit 分类和截断计数分布）解决零值问题，Tobit 模型则处理右删失数据。这两种模型均引入了显示性比较优势指数（RCA），并纳入了运动员数量规模、东道主效应等异质性因素。通过比较发现，在均方误差和预测覆盖率方面，Hurdle 模型和 Tobit 模型显著优于机器学习方法（随机森林和 XGboost）。其中，Hurdle 模型对体育强国的奖牌数量具有更好的预测效果，而 Tobit 模型对奖牌数量较少的国家预测效果更佳。预测结果显示，美国、中国和印度的奖牌数将有最大增幅，而法国、俄罗斯和德国则会出现显著下降。安哥拉、孟加拉国和柬埔寨赢得首枚奖牌的概率分别为 49.2%、46.7% 和 42.5%。最后，通过模型互补和变量重构，揭示了东道主项目选择对奖牌数量的影响机制。

在问题 2 中，贝叶斯变点检测方法被用于识别特定项目中各国奖牌数量的显著变化（例如在长期低迷后的突然突破），并将这些变化归因于“优秀教练效应”。为解决简单加权奖牌数据中频繁波动的问题，采用了一种具有记忆增强功能的创新数据预处理算法对原始奖牌数据进行预处理，该算法能够有效区分奖牌数据的显著性、动态自我强化机制与由教练效应驱动的真实变化。随后，使用两阶段最小二乘法（2SLS）构建因果回归模型，以量化优秀教练对奖牌数量的贡献，克服了传统普通最小二乘法（OLS）的内生性偏差。模型验证表明，在解释教练效应方面，2SLS 显著优于 OLS。基于此，建议美国、英国和法国应优先在摔跤、赛艇、乒乓球等项目中引进跨国教练，预计这将使奖牌数量增加 1-2 枚。

在问题 3 中，我们延续了问题 1 和问题 2 的分析。基于贝叶斯变点检测方法，我们识别出往届奥运会各项目中潜在的“伟大教练效应”时间节点，并将其作为关键解释变量纳入 hurdle 模型和 Tobit 模型中进行重新分析。同时，为捕捉奖牌数量的动态自我强化机制，我们进一步引入滞后项（如滞后 4 年的东道主效应、历史奖牌数滞后项等），以分析短期效应和长期效应的异质性。最终，我们得出了关于促进赛后资源再分配以及平衡各国奥委会（National Olympic Committees）“深度”与“广度”的政策启示。

关键词：托比特模型、hurdle 模型、两阶段最小二乘法、贝叶斯变点检测、奖牌预测

目录

1	引言	3
1.1	背景	3
3		
3	4	
2	假设与合理性说明	4
3	符号说明	4
4	数据处理	5
4	55	
4.2	数据概述	
5	奥运会奖牌预测的比较建模：包含东道主策略分析的 hurdle-Tobit 框架	6
6		
5.2	模型选择与验证	9
5.2.1	模型选择：Hurdle、Tobit、XGBoost 和随机森林	5.2.2 模型验证：基于 Hurdle 和 Tobit 的
2024	年奥运会预测	9
5.3	2028 年洛杉矶奥运会奖牌数预测	12
5.4	首次奖牌获得者预测与概率估计	12
5.5	项目选择对奖牌数量的影响	13
5.5.1	奥运会项目与奖牌分布的关系	14
5.5.2	重点运动项目及其对不同国家的重要性分析	14
5.5.3	东道主项目选择对比赛成绩的影响	15
6	优秀教练效应：基于贝叶斯变点检测和因果推断模型的策略优化研究	18
6.1	基于贝叶斯变点检测的优秀教练效应发现	18
6.1.1	数据处理	18
6.2		
6.2	优秀教练效应对奖牌数量的定量评估	20
6.1.3	美国的教练效应证据	19
6.2.1	采用 2SLS 的回归模型	20
6.2.2	模型验证	20
6.3	三个国家的针对性教练投资	21
7	见解：奥运会奖牌表现中的战略资源分配与路径依赖	22
7.1	东道主效应的动态衰减与资源再分配	22
7.2	项目和运动数量的“双刃剑效应”	22
8	敏感性分析	23
9	模型评估	23
9.1	优势	23
9.2	劣势	24
	参考文献	24

1 引言

1.1 背景

奥运会奖牌榜反映了各国的体育实力，也是全球竞技水平的基准。在 2024 年巴黎奥运会上，美国和中国各获得 40 枚金牌，并列第一，而东道主法国的金牌数排名第五（16 枚），但总奖牌数排名第四。值得注意的是，阿尔巴尼亚和佛得角获得了各自国家历史上的首枚奖牌，然而仍有 60 多个国家尚未获得过奥运奖牌。

1.2 问题重述

任务 1：利用历史数据开发一个奥运会奖牌预测模型，以预测：（1）2028 年洛杉矶奥运会各国的奖牌数量，包括预测区间和准确性指标，确定相对于 2024 年的排名上升 / 下降情况。（2）各国首次获得奖牌的概率，并结合历史突破模式进行分析。（3）体育赛事结构对奖牌分布的影响，包括识别各国占主导地位的项目。（4）通过项目调整的影响来量化东道主优势。

任务 2 （1）从统计角度验证更换教练对奖牌变化的影响，并量化“优秀教练”的贡献。（2）针对三个国家，找出具有奖牌潜力但表现不佳的运动项目，并评估招募精英教练的可行性和益处。

任务 3 （1）确定影响奖牌分配的非传统因素。（2）为奥委会制定基于证据的政策建议。

1.3 文献综述

对奥运会的实证分析已成为一个重要的研究领域，既包括预测（如 De Bosscher 等人，2006 年），也涵盖更广泛的分析视角（如 Streicher 等人，2020 年）。

自鲍尔（1972）提出基于相关性的评分模型以来，预测方法变得日益复杂。起初，许多研究人员依赖普通最小二乘（OLS）回归，因为其易于解释（例如，贝恩布里奇，1998；康登等人，1999；库珀和斯特肯，2001）。然而，预测奥运会奖牌的一个重大挑战是准确反映大量尚未获得任何奖牌的国家的状况。这些模型中使用的指数函数往往会对较低的预测奖牌数施加惩罚。因此，一些学者转而采用基于泊松分布的模型（例如，刘和孙，2008；利兹和利兹，2012；布莱 - 莫里塞特等人，2017）。

此后，机器学习技术（如随机森林和极端梯度提升）在体育相关领域得到了广泛应用。随机森林方法在预测足球比赛结果（Groll 等人，2019）或赛马结果（Lessmann 等人，2010）等任务中表现出色。然而，作为基于决策树的集成学习方法，随机森林和极端梯度提升在处理非线性关系和特征交互方面表现优异，但它们缺乏对截断数据和零膨胀数据进行显式建模的能力。这意味着这些算法可能无法准确捕捉数据中的截断点或零值生成机制，从而导致预测偏差（Breiman，2001；Chen & Guestrin，2016）。

鉴于因变量（通常为奖牌数量）已被设为零，大多数作者采用了 Tobit 回归来预测奥运会成绩（例如，Tcha 和 Pershin，

2003; Forrest 等人, 2015; Rewilak, 2021)。然而, 最近, 一种两步法变得更为普遍, 即先估计获得任何奖牌的概率, 再在成功的情况下确定奖牌的确切数量。特别是 Scelles 等人 (2020) 和 Rewilak (2021), 他们采用了 Tobit 模型的 Mundlak 变换, 通过各自的 hurdle 模型再次提高了预测准确性。

这一发现与本研究采用的建模方法相符，该方法利用 Tobit 模型和 Herdle 模型来应对奥运会奖牌预测所面临的独特挑战。

1.4 我们的研究工作




图 1 我们的工作

2 假设与合理性说明

- 所有模型均基于奥运会正常举办的情况构建，不会出现奥运会延期等情况。
- 。这些模型的构建不受外部因素（如政治事件和国家禁令）的影响，仅基于现有数据。
- 本文中使用的所有数据均为真实数据，不存在统计误差。

3 符号说明

Notation	Significance
$Mapdisq_{i,t}^*$	Potential medal ability
RCA	National dominance sports index
$Na_{i,t}$	Categories to which the number of players belongs
NAE	The number of events that won medals in a sport for a country
$M_{i,t}$	The expected number of medals won by country
$Medal_PCA$	The number of medals after dimensionality reduction

4 数据处理

4.1 数据清洗

为便于预测，我们剔除了表格数据中的空缺项，统一了国家名称（例如，2024 年的俄罗斯奥委会和联合队被合并为俄罗斯），统一了运动员姓名（例如，由于主办方和参赛规则的不同，马龙和 Long Ma 实际上是同一个人），统一了项目名称（例如，2024 年的 “Tabble Tennis Men’s single” 与 2020 年的 “乒乓球男子单打” 相同）。

4.2 数据概述

下图展示了 1896 年至 2024 年奥运会所有参赛国家奖牌总数的箱线图。同时，我们提取了美国、中国、法国、英国和澳大利亚的奖牌总数绘制了折线图。




图 2 1896 年至 2024 年总奖牌数的箱线图及 5 个国家的奖牌射线图

如图所示，箱线图呈现右偏分布，即最大值远高于中位数，且尾部向右延伸，这反映出少数国家在奖牌榜上占据主导地位。

我们计算了法国巴黎 2024 年奥运会中各国参赛运动员人数、奖牌数量、奖牌总数、是否为主办国、运动项目类型数量以及参赛赛事数量的平均值、标准差、最大值和最小值，如下表所示。

表 1 描述性统计

Variable	Mean	SD	Min	Max
Number of Athletes	73.40	144.9809	2	856
Total Medals	11.42	19.7028	1	126
Gold Medals	1.59	4.97	0	40
Silver Medals	1.59	4.83	0	44
Bronze Medals	1.85	4.83	0	42
Host Country	0.01	0.07	0	1
Number of Events	31.27	46.84	1	234
Number of Sports	10.07	10.30	1	47

根据上述表格可以看出，

运动员人数和奖牌数量的标准差较大，表明离散程度较高。

只有 1% 的观察结果是东道国，这表明东道国的样本量极小，这可能会影响其统计显著性，因此在解读时应谨慎。

运动员的数量与奖牌的数量高度相关，但需要注意的是，模型中主办国变量与运动员数量之间存在协方差，这导致主办国效应可以通过运动员数量来解释。

5 奥运会奖牌预测的比较建模：包含东道主策略分析的 hurdleTobit 框架

5.1 hurdle 模型和 tobit 模型

由于奖牌数量是离散的非负整数（例如 0、1、2 等），处理如此大量的离散数据就变得至关重要，因此我们使用计数模型进行分析。所以我们首先考虑了 Blais-Morissetr 和 Fortin（2017）的建议，即在这种情况下使用泊松模型来处理此类数据。然而，由于各国之间存在显著的异质性，方差大于均值（即过度离散问题），这使得泊松模型的假设不成立。

为了解决过度离散问题，我们转而考虑零膨胀负二项模型（Zinb 模型）。该模型适用于数据中存在大量零值的情况，并假设这些零值来自两个不同的来源，即 “结构性零值”（例如，该国未参加奥运会）和 “抽样零值”（例如，该国参加了奥运会但未获得奖牌）。然而，由于这项研究

其关注的是那些参加过奥运会的国家, 此时结构零并不存在, 零膨胀负二项模型 (Zinb 模型) 的假设也不再适用。

然后, 我们转而使用 Hurdle 模型, 该模型与 Zinb 模型的不同之处在于, 它不区分零值的来源, 而是将模型分为两部分: 第一部分是关于是否至少获得一枚奖牌的决策 (二元分类问题), 第二部分是在至少获得一枚奖牌的情况下, 奖牌数量的分布。这类似于 Tobit 模型 (截断回归模型), 但 Tobit 模型假设低于某个阈值的观测值被截断, 而 Hurdle 模型则明确区分了是否跨越该阈值的两个过程。

因此, 针对从未获得过奖牌的国家和体育强国这两种不同情况, 我们改进了 Tobit 模型、hurdle 模型、随机森林和 XGBoost 这四种方法的使用方式, 并比较了它们的预测效果, 为不同情况选择了最优模型。

步骤 1: 变量定义与处理。

$NA_{i,t}$ 表示 t 年为 i 国参加奥运会的运动员人数, 最初被分析为连续变量。然而, 运动员人数的边际收益可能是非线性的, 并且在预测未来奖牌总数时, 无法提前知道确切的参赛人数。因此, 我们引入 $NA_{i,t}$ 将参赛运动员人数离散为四类:

$-NA_{i,t} = 1 : 0 \text{ to } 9 \text{ athletes};$

$-NA_{i,t} = 2 : 10 \text{ to } 49 \text{ athletes};$

$-NA_{i,t} = 3 : 50 \text{ to } 149 \text{ athletes};$

$-NA_{i,t} = 4 : 150 \text{ athletes and over}$




图 3 奖牌数量之间的相关性

从上述数据可以看出, 值得注意的是, 金牌数、银牌数、铜牌数和奖牌榜之间存在显著的多重共线性。为了简化

在模型中, 我们实际上在使用主成分分析 (PCA) 之前会将其降维到一维, 即 $Medal_PCA$ 。

同时, 每个国家都应该有其主导运动, 为了将其纳入模型, 我们引入 RCA 来量化每个国家的主导运动。 RCA 由以下公式给出:

$$RCA = \frac{M_{ij}/T_j}{M_i/T} (1)$$

这里, M_{ij} 代表国家 i 在运动 j 中的奖牌数量; M_i 代表国家 i 的奖牌总数; T_j 代表运动 j 中的全球奖牌总数; T 代表所有运动项目中的奖牌总数。

$RCA > 1$: 国家在特定运动项目上具有比较优势;

$RCA < 1$: 国家在特定运动项目上具有比较劣势。=

下图展示了 2024 年巴黎奥运会奖牌得主国家的显示性比较优势指数热力图。




图 4 RCA 指数热力图

步骤 2: 定义潜变量 X_t 和潜在奖牌能力 $Mandis_{i,t}$ 。

根据所选的解释变量集, 我们将潜变量 X_t 定义为:

$$X_{i,t}\theta = c + \lambda \ln N_{i,t-4} + \rho Host_{i,t} + \sum_p \gamma RCA_{p,i} + \delta MedalPCA_{i,t-4} + \sum_p \zeta NumEvents_{p,i,t} + \kappa \sum_p NAE_{p,i,t} + \kappa \sum_p NAF_{p,i,t}$$

这里, $X_t = X_{told}$ 、 X_{isiver} 、 $Y_t = \theta_{1,2,\dots,T}$ 。 $Host_{i,t}$ 是主办变量 ($Host_{i,t} = 1$, 国家 i 是第 t 届奥运会的主办国)。 $NumEvents_{i,t}$ 是项目的数量,

i 国参加了 t 届奥运会的 p 项目。 $\alpha, \lambda, \rho, \gamma, \delta, \zeta, \kappa \in \mathbb{R}^3$ 均为系数, 分别代表 $X_{i,t}\Theta$ 在金牌、银牌和铜牌中的数值, 这些系数是基于历史数据通过最大似然估计 (MLE) 计算得出的。

我们通过以下方式定义潜在奖牌能力 $Mapdisq_{i,t}$:

$$Mapdisq_{i,t}^* = X_{i,t}\Theta + \mu_i + \epsilon_{i,t} \quad (3)$$

在此, μ_i 代表特定国家的随机效应 (如文化、培训体系及其他未观测因素), 其服从正态分布 $N(0, \sigma^2)$; $\epsilon_{i,t}$ 是随机误差项。

步骤 3: 构建托比特模型。

对于 Tobit 模型, 其一般设定为:

$$Mapdisq_{i,t} = \begin{cases} Mapdisq_{i,t}^* & , \quad Mapdisq_{i,t}^* > 0 \\ 0 & , \quad Mapdisq_{i,t}^* \leq 0 \end{cases}$$

预测的奖牌数 $Mapolis_{i,t}$ 是潜在奖牌能力 $Mapdisq_{i,t}$ 的简化版本。

步骤 4: 构建 hurdle 模型。

1. 计算赢得 $P(Mapdisq_{i,t}^* > 0)$ 的概率

我们使用 Logit 模型来计算第 i 个国家获得至少一枚奖牌的概率, 如下所示:

$$P(Mapdisq_{i,t}^* > 0) = \frac{1}{1 + \exp(-X_{i,t}\Theta)} \quad (5)$$

2. 计算获胜国家 $M_{i,t}$ 赢得的预期奖牌数。

首先, 我们将 $\mu_{i,t}$ 定义为在 “至少获得一枚奖牌” 条件下, 国家 i 的奖牌数的理论均值, 其公式为:

$$\mu_{i,t} = \exp(X_{i,t}\Theta) \quad (6)$$

然后, 由于只考虑获胜国家 (即排除零值), 为了调整期望值, 我们将截断修正 $E(Mapdisq_{i,t}^* | \cdot)$ 定义为:

$$E(Mapdisq_{i,t}^* | \cdot) = \mu_{i,t} \cdot \frac{1}{1 - (1 - \exp(-r))^{-r}}$$

其中 r 是一个离散参数。

最后, 获胜国家 $M_{i,t}$ 赢得的预期奖牌数由下式给出:

$$M_{i,t} = P(Mapdisq_{i,t}^* > 0) \cdot E(Mapdisq_{i,t}^* | \cdot) \quad (8)$$

5.2 模型选择与验证

5.2.1 模型选择: hurdle 模型、Tobit 模型、极端梯度提升 (XGBoost) 和随机森林 (Random Forest)

在本研究中, 我们采用了四种模型 —— Tobit 模型、Hurdle 模型、随机森林和 XGBoost —— 来预测美国在 2024 年奥运会上获得的奖牌总数。

法国巴黎的奥运会。采用这种方法是为了评估这四个模型预测结果的准确性。下面展示了基于这四种方法的预测结果与真实数据之间的对比。




图 5 四种方法的预测结果与实际数据对比

表 2 模型性能比较 (MSE 和 R^2)

	Hurdle	Tobit	XGBoost	Ramdom Forest
MSE	20.15	23.01	63.67	51.25
R^2	0.8545	0.8026	0.7121	0.758

如图所示，Hurdle 模型表现更优，而随机森林和 XGBoost 的预测结果与真实值拟合效果较差。在随机森林与 XGBoost 的组合模型中，预测值在实际奖牌 $count > 15$ 区域存在偏差，即难以有效处理零膨胀数据的分布特征。同时，奖牌数量较多的国家（实际 $values > 50$ ）的预测点分散且不规则，这反映出该模型捕捉极端值的能力不足。

同时，Hurdle 模型和 Tobit 模型的均方误差 (MSE) 显著低于 XGBoost 模型和随机森林模型，这表明前两种模型的预测准确性更高。

Hurdle 模型和 Tobit 模型的 R^2 显著高于前两个模型。这表明 Hurdle 模型和 Tobit 模型在解释数据变异性方面更有效。

5.2.2 模型验证：基于 Hurdle 模型和 Tobit 模型的 2024 年奥运会预测

我们选择预测性能更优的 hurdle 模型和托比特模型，来呈现 2024 年巴黎奥运会总奖牌数的预测区间和准确性的预测结果。

表 3 2024 年巴黎奥运会奖牌预测

Country	Actual Medals	Hurdle Model			Tobit Model		
		Forecast	Lower CI	Upper CI	Forecast	Lower CI	Upper CI
United States	126	120	103	134	105	95	113
China	91	89	86	93	106	95	117
Great Britain	65	68	63	53	56	51	61
France	64	70	63	77	69	66	71
Australia	53	48	44	52	46	44	58
Japan	45	47	42	51	44	42	46
Italy	40	43	38	48	48	43	53
Rate of right forecasts for 2024 Paris Olympic Games							
All countries (192)							
CI to 95%(+ or -2)		88.6% (93.2%)			83.8% (90.6%)		
Exact forecasts (+ or - 1)		21.9% (77.1%)			43.2% (74.5%)		
Exact forecasts (0 medal)		41.3%			69.1%		
(107 countries)							
Exact forecasts (non-0 medal)		22.4%			10.4%		
(85 countries)							
Countries with at least 3 medals(56)							
CI to 95%(+ or -2)		62.3% (76.8%)			50.2% (69.6%)		
Exact forecasts (+ or - 1)		8.9% (38.5%)			8.9% (31.4%)		

注：CI = 置信区间；粗体为预测值。

首先，在 95% 置信区间预测覆盖率方面，Hurdle 模型覆盖了全部 192 个国家中的 88.6%，高于 Tobit 模型的 83.8%；在至少获得 3 枚奖牌的 56 个国家中，其覆盖率（62.3%）也远高于 Tobit 模型（50.2%）。此外，Hurdle 模型对获得非零奖牌国家的预测准确性（±1 误差率为 22.4%）是 Tobit 模型（10.4%）的两倍多，这凸显了其两阶段建模在适应零膨胀数据方面的优势。

尽管托比特模型在零奖牌国家的完全准确预测率（69.1%）高于 hurdle 模型（41.3%），但这种优势是以牺牲预测非零奖牌的能力为代价的。Hurdle 模型通过分离零值产生机制和正向预测机制，在这两种场景之间更加平衡，尤其在奖牌数较多的国家中表现稳健（±1 误差范围内的比例为 38.5% 对 31.4%）。

总之，得益于其截断回归，托比特模型在零奖牌附近的拟合效果更好。

下界值的假设。然而，随着奖牌数量的增加，离散度显著上升，暴露了单一连续分布假设的局限性。相比之下，赫德尔模型通过两阶段建模，在零值区域和高奖牌区域均展现出更优的预测结果，其点分布集中且离散度低，有效平衡了零值生成机制与正向预测的灵活性。

5.3 2028 年洛杉矶奥运会奖牌数预测

下图显示了所有预计至少能获得一枚奖牌的参赛国家的奖牌排名情况。




图 6 2028 年奥运会奖牌预测：各国金 / 银 / 铜牌分布

根据上述预测结果，我们列出了奖牌总数增减幅度最大的五个国家，如下所示。

表 4 奖牌数增减幅度最大的前 5 个国家

Improve	USA	China	India	Brazil	Japan
Magnitude	15	10	7	5	5
Decline	France	Russia	Germany	Great Britain	Australia
Magnitude	-8	-4	-4	-3	-2

5.4 首次获得奖牌的国家预测及概率估计

预测结果显示，共有三个国家将在 2028 年洛杉矶奥运会上赢得首枚奖牌，即：安哥拉、孟加拉国和柬埔寨。其可能性为

每个国家首次获得奖牌的情况如下表所示。

表 5 预计首次获得奖牌的获奖者及概率

Country	Angola	Bangladesh	Cambodia
Possibility	49.23%	46.67%	42.49%

5.5 项目选择对奖牌数量的影响

下表展示了各国在使用 Tobit 模型和 Hurdle 模型时所获统计结果的平均值。

表 6 两种预测模型的结果

Variables	Hurdle Model		Tobit Model	
	Coef	SD	Coef	SD
Constant				
Host country in 4 years	0.336*	0.1	8.864***	2.02
Host country t	1.566***	0.11	12.520***	2.03
Host country 4 years ago	0.85	0.11	-4.760**	2.08
Athletes [0,10]	0.016*	0	0.897*	0.02
Athletes [10,50]	0.510*	0.23	5.126***	0.67
Athletes [50,150]	0.989*	0.24	7.394***	0.87
150 athletes and more	1.559***	0.27	9.314***	1.15
Medals_PCA(t-4)	3.725***	0.12	3.42***	4.57
RCA	2.538***	0.22	1.828**	1.07
Medals_PCA(t-4)	3.725***	0.12	3.42***	4.57
Num_Events	0.538**	0.22	1.828**	1.07
Num_sports	0.618**	0.21	1.719**	0.97
NAE	2.742***	0.22	2.705***	0.26
$g_{i,t}$	-3.408***	0.25	—	—
σ_u^2	0.115***	0.03	26.68***	1.66
Observations total	529	—	1232	—
Observations noncensored	—	—	529	—

注：*** 表示在 1% 的水平上显著；** 表示在 5% 的水平上显著；* 表示在 10% 的水平上显著

结果表明，事件数量和 NAE 均具有积极且显著的影响，且这种显著性在所有国家都存在。 RCA 的系数较大且方差较大，这可能表明不同体育运动对不同国家的重要性存在显著的异质性。同时，在 Tobit 模型和 Hurdle 模型中，主办国都具有积极影响，且在 Hurdle 模型中，主办国的系数小于 Tobit 模型中的系数。其解释是，主办国与 NAE 、 RCA 等其他变量之间存在明显的多重共线性，这些变量会削弱主办国的显著性，而 Hurdle 模型更有可能捕捉到这种影响。

5.5.1 奥运会项目与奖牌分布的关系

起初，我们尝试构建一个图表，用以展示中国、美国、日本和法国历史数据中平均 N AE、事件数量（Num_Events）与总数（Total）之间的关系。随后，我们计算了这些国家在两个协变量与总数之间的皮尔逊相关系数。总数与平均 N AE 之间的关系图以及相关系数表如下所示。




图 7 各国 RCA、赛事数量（Num_Events）和总数（Total）的比较

表 7 皮尔逊相关系数表

	Mean	SD
num_events	0.238	0.216
NAE	0.952	0.051

研究结果显示，Mean NAE 与 Total 之间存在显著的线性关系，同时标准差较小，这表明其具有普遍性。然而，Num_Event 的显著性可以忽略不计，且这种现象在不同国家之间表现出显著的异质性。

5.5.2 重点运动项目分析及其对不同国家的重要性

RCA 指数是一种定量指标，可用于比较不同国家不同体育运动的相对受欢迎程度。正如热力图所示，现代五项已成为埃及最杰出的运动，这一发现与其作为该国在该项目中唯一的金牌得主和世界纪录保持者的地位相符。审视美国这个同样拥有强大体育声誉的国家时，也能得出类似的观察结果。美国在多项运动中的 RCA 指数超过 1，表明其在各类运动中具有相当程度的优势。这一发现与美国拥有多种实力相近的运动项目这一观点相符。

为了确定对每个国家最为重要的体育运动，本研究以埃及和美国为例。Tobit 模型和 Hurdle 模型

用于预测 2024 年夏季奥运会的奖牌总数，计算相应的显示性比较优势指数（RCA）和系数，以此为基础对各项运动进行排名，并提取这些运动所贡献的奖牌数量。本质上，图中展示的运动项目是美国和埃及总奖牌数的最主要贡献者，这一点从其较高的显示性比较优势指数和相应的系数值中可以得到证明。




图 8 对奖牌数量贡献最大的运动项目：美国和埃及

5.5.3 东道主赛事选择对成绩的影响

根据历史数据观察，东道国的RCA与NAE之间存在显著的协同增长（如下图所示）。




图 9 *NAE*和*RCA* 东道国指数

这种现象可能归因于两种并非相互排斥的机制：

- 战略性项目选择，即主办国利用竞赛规则纳入临时性优势项目（如小众冷门项目），通过 “制度红利” 人为提高显示性比较优势。

系统性的能力提升。举办赛事所带来的长期资源投入（如运动员训练）推动了体育实力的整体提升，进而增强了*NAE*和*RCA*。

为了量化这些机制的独立影响，本研究采用了模型互补性和变量重构的双重策略。虽然 hurdle 模型已被证明能更有效地捕捉东道主效应，但 Tobit 模型在处理弱势国家参与的体育项目（即奖牌数小于或等于 0）方面更为擅长。这是因为 Tobit 模型的截断回归特性更有利于 “零值累积 + 低值连续性” 分布。因此，Tobit 模型能够更敏锐地通过*RCA_{add}*和*NAE*检测东道主国家突破零奖牌阈值的边际效应。因此，必须通过变量细化构建基于 Tobit 和 Hurdle 的两个模型。

- 将连续的*NAE*转换为三分类变量（低 / 中 / 高），以识别凭经验积累的非线性阈值效应，并计算在以往事件中稳定存在的传统事件的平均*RCA*，以反映国家的长期竞争力。

- 分离永久赛事和新赛事的*RCA*。对于新赛事 *RC A_{add}*：提取东道主新增临时赛事的*RCA*的历史最大(*max(RCA)*)，以捕捉其战略性选择赛事的峰值效应。最大值(*max(RCA)*)，以捕捉其战略性选择赛事的峰值效应。

随后的结果将在接下来的表格中呈现。

表 8 四个解释模型的结果

Variables	Model (1)–Hurdle		Model (1)–Tobit		Model (2)–Hurdle		Model (2)–Tobit	
	Coef	SD	Coef	SD	Coef	SD	Coef	SD
Host country in 4 years	0.136*	0.21	5.864***	0.12	0.236*	0.12	5.864***	0.22
Host country t	1.354***	0.41	5.520***	0.23	1.546***	0.21	5.520***	0.03
Host country 4 years ago	1.085***	0.21	4.145**	0.18	0.879**	0.11	4.547**	0.12
Athletes [0,10]	0.016*	0	0.745*	0.22	0.016*	0	0.789*	0.22
Athletes [10,50]	0.241*	0.34	0.826***	0.88	0.510*	0.12	0.726***	0.57
Athletes [50,150]	0.789**	0.54	0.924***	0.65	0.989**	0.23	0.954***	0.65
150 athletes and more	0.978***	0.25	9.314***	1.15	0.834***	0.12	0.614***	1.15
Medals_PCA(4)	-3.725***	0.28	3.42***	4.57	3.702***	0.23	3.42***	4.47
RCA	1.548***	0.32	1.828**	1.42	2.538***	0.24	1.828**	1.17
RCA_usual					0.538*	0.22	0.778**	0.92
RCA_add					2.618***	0.41	1.994**	0.93
NAE					2.911***	0.122	2.414***	0.48
NAE [0,20]	1.745***	0.24	2.948**	1.15				
NAE [20,50]	1.857***	1.71	1.011**	0.75				
NAE 50 and more	1.912***	0.92	1.112***	0.36				
Num_Events	0.575**	0.24	1.148**	1.72	0.538*	0.22	1.178**	0.92
Num_sports	0.487**	1.69	1.572**	1.07	0.618**	0.41	0.994**	0.93
$g_{i,t}$	-3.408***	0.75	—	—	-3.408***	0.235	—	—
σ_u^2	0.350***	0.05	26.68***	23.67	0.334***	0.03	51.907***	8.36
Observations total	554	—	1289	—	554	—	1289	—
Observations noncensored	554				554			

注：*** 表示在 1% 的水平上显著；** 表示在 5% 的水平上显著；* 表示在 10% 的水平上显著。

根据表格中的结果，战略性地增加临时优势项目(RCA_{add})是主办国奖牌增长的核心驱动力。在模型 2 中， RCA_{add} 的系数显著为正 (2.618, 1.994)，这表明主办国可以通过增加具有最佳历史表现的新项目（如东京奥运会的空手道）并将资源集中在这些项目上，在短期内显著提高奖牌收益。相比之下，长期竞争力(RCA_{usual})的影响相对有限，且在模型 1 和模型 2 中显著性并不突出。其次，对于 Tobit 模型而言，其数量和类型

赛事数量（赛事数量，运动项目数量）显著为正（模型 1 中运动项目数量的系数为 1.572），这表明增加分项赛事或新的运动项目类型能够为竞技实力较弱的国家创造更多获得奖牌的机会。此外，模型 1 显示，对于竞技实力较弱的国家而言，通过增加赛事，经验积累（NAE 分类变量）和作为东道主突破零奖牌门槛尤为关键（NAE 低分组系数为 2.948*）；而在 Tobit 模型中，东道主效应（东道主 t 系数为 5.520**）更强，这证实了其对弱国突破奖牌数的边际效应。总之，东道主通过 “短期聚焦优势项目 + 扩大赛事规模 + 优先利用本土资源” 这一三管齐下的赛事选择策略，实现了奖牌数量的结构性增长。这一机制对竞争力较低的国家而言，具有更为决定性的意义。

6 伟大教练效应：基于贝叶斯变点检测和因果推理模型的策略优化研究

6.1 基于贝叶斯变点检测的伟大教练效应发现

当一个国家在某届奥运会的某个项目中获得的奖牌数量出现显著变化时，例如在某一届获得至少一枚奖牌，但在连续几届奥运会中都未能获得奖牌，或者获得的奖牌数量大幅增加，且在之前的几届中也获得过金牌，我们认为这种显著变化是 “伟大教练效应” 的结果。这种观点的原因是，在长期低迷后突然取得突破，或者在某一届奥运会中实力大幅提升，可能与一位杰出的教练有关，即使该国此前已具备一定的体育实力。可以使用贝叶斯变点检测来识别这种明显的转折点。都模乐园




图 10 两种类型的变点

6.1.1 数据处理

贝叶斯变点检测在医学等领域有着广泛的应用，例如实时检测患者心率的突然变化，或者检测历史数据中发生显著变化的时间点。然而，对于奖牌数据，如果将铜牌、金牌和银牌分别设为 1、2、3，那么单位时间内的波动就过于

数值较大，导致模型识别出大量变化点。因此，我们对奖牌数据进行处理，使其在一个时间单位内更加稳定。计算采用滑动窗口法，公式如下：

$$S_t = \left(1 + \frac{1}{N_{Total}}\right) \cdot \begin{bmatrix} a \\ b \\ c \end{bmatrix} \cdot \begin{bmatrix} N_{Gold} & N_{Silver} & N_{Bronze} \end{bmatrix}$$
$$Score_t = \sum_{i=0}^K S_{t-4,i} e^{-i} \quad (10)$$




图 11 两种类型的变点

6.1.2 贝叶斯变点检测

贝叶斯变点检测的基本原理包括将数据分割为不同的部分，假设每个部分遵循特定的概率分布（例如正态分布）。这种方法需要通过应用贝叶斯推断来估计变点的位置和数量。该方法通过联合后验分布整合观测数据、参数先验和变点先验，并利用边际似然简化计算。这有助于推断出最可能的变点配置。

6.1.3 美国教练效应的证据

通过引入美国排球队和体操队的数据，并运用贝叶斯变点检测法，我们发现该方法检测到了变点，即显著的教练效应，如下表所示。

表 9 美国优秀教练效应的证据

Sports	Change-point	Posterior Probability	Data Segment	Variance	Confidence Interval (95%)
Volleyball	2008	0.95	2004-2008	1.3	[4.8, 5.6]
Gymnastics	1984	0.87	1980-1984	2.1	[7.3, 8.3]

6.2 优秀教练对奖牌数量影响的定量评估

回归模型是统计学中用于估计变量间关系的重要工具。在可解释性方面，它们明显优于 XGBoost 和随机森林等机器学习模型（引用文献）。然而，当使用回归模型分析优秀教练对奖牌数量的贡献时，无法避免由内生性导致的估计偏差（即变量间相互关系、遗漏变量等的影响），这使得无法准确识别教练的真实影响。因此，我们必须放弃一般的参数估计方法（如 OLS、DID 和 IV），开发一种能消除内生性并专注于教练与奖牌之间强因果效应的参数估计方法，即两阶段最小二乘法（2SLS）。

6.2.1 使用工具变量法估计优秀教练影响的回归模型

步骤 1：使用工具变量 S 对内生变量 D 进行回归

内生变量 D 表示教练是否优秀。如果 $D = 1$ ，则表明该教练有显著效果；否则， $D = 0$ 。定义 D 的表达式为：

$$D = \alpha_0 + \theta_1 \text{Score} + \alpha_2 \text{RCA} + \alpha_3 \text{NumEvents} + \alpha_4 \text{NumAthlete} + \alpha_5 \text{NAE} + m(11)$$

其中，Score 是具有强相关性且满足外生性（不直接影响优秀教练的存在）的工具变量。其余解释变量为外生变量。

步骤 2：使用预测值 $\hat{D}$ 对奖牌数量 N 进行回归

奖牌数量 N 可以表示为

$$N = \beta_0 + \beta_1 \hat{D} + \beta_2 \text{RCA} + \beta_3 \text{NumEvents} + \beta_4 \text{NumAthlete} + \beta_5 \text{NAE} + n(12)$$

其中 $N = [N_{\text{gold}}, N_{\text{silver}}, N_{\text{bronze}}]^T$ 为 3×1 向量。 $\beta_0, \beta_1, \beta_2, \beta_3, \beta_4, \beta_5 \in \mathbb{R}^3$ 是系数。

如果 β_1 为正值，那么 β_1 的三个分量分别代表卓越教练效应对金牌、银牌和铜牌的贡献。

6.2.2 模型验证

我们以美国为例，使用 1960 年至 2024 年的历史数据。首先，对每一项运动采用贝叶斯变点检测法，从统计上确定可能存在伟大教练效应的事件。然后，依次使用两阶段最小二乘法（2SLS）和普通最小二乘法（OLS）对每一项运动进行最大似然估计（MLE）回归，从统计上确定 2SLS 和 OLS 对伟大教练在各赛事中所获奖牌数量的影响，并将结果与实际值进行比较，如图所示。




图 12 两阶段最小二乘法、普通最小二乘法模型与实际数据的比较

两阶段最小二乘法（2SLS）和普通最小二乘法（OLS）都能解释优秀教练对奖牌数量的影响，但就解释效果而言，两阶段最小二乘法（2SLS）明显优于普通最小二乘法（OLS），且内生性问题也得到了更好的解决。

6.3 三个国家的定向教练投资

统计结果显示，美国、英国和法国可以通过对教练的战略投资获得边际收益。各国引进教练后预计增加的奖牌数量如下表所示。

表 10 美国、英国和法国的定向辅导投入及预期改进幅度

The United States	Magnitude	Great Britain	Magnitude	France	Magnitude
Wrestling	2	Wrestling	1	Table tennis	1
Rowing	1	Canoeing	2	Badminton	1
Judo	1	Judo	1	Athletics	1
Archery	1	Shooting	1	Gymnastics	2
Triathlon	2	Weightlifting	1	Rowing	1

上述策略基于两个核心逻辑：第一，在现有教练的介入下，选择边际效益突出的项目，以最低成本实现奖牌增长；第二，瞄准国际竞争格局中的薄弱环节（例如，乒乓球由亚洲主导），通过跨境教练合作填补技术空白。从长远来看，此类投入既能提升短期成绩，又能构建可持续的竞争力，尤其是在奖牌分布高度集中的奥运项目中。

7 大见解：奥运会奖牌表现中的战略资源分配与路径依赖

对于问题 3，我们延续问题 1 和问题 2 的分析，采用贝叶斯变点检测来标记各国在以往奥运会中各项运动可能存在的显著教练效应，并将其作为解释变量加入 hurdle 模型和 Tobit 模型中。同时，由于奖牌动态存在自我强化机制，我们对解释变量进行了相同处理（即进一步解释滞后项），然后进行回归。结果如下表所示。

表 11 解释模型的结果

Variables	Hurdle Model		Tobit Model	
	Coef	SD	Coef	SD
Host country t	1.354***	0.41	5.520***	0.23
Host country 4 years ago	1.085***	0.21	4.145***	0.18
Athletes [150+]	0.978***	0.25	2.314***	1.15
Medals_PCA	1.548***	0.32	1.828***	1.42
Num_Events vs. Num_Sports	0.575** vs. 0.487**	0.19	1.148*** vs. 1.572***	1.03

注：仅显示待分析的变量以解释系数；：*** 在 1% 的水平上显著；** 在 5% 的水平上显著；* 在 10% 的水平上显著。

7.1 东道主效应的动态衰减与资源再分配

从时间角度来看，短期内，东道主 t 的系数为 1.354*（hurdle 模型），这表明在当前奥运会期间，东道主的优势最为显著。长期来看，4 年前东道主的系数为 1.085*（hurdle 模型），这表明 4 年后东道主效应仍然存在，但强度下降了约 20%。

政策启示：

- 主办国需要在赛事结束后的 2-4 年内将基础设施改造为长期训练基地，以避免资源闲置。
- 非主办国可以瞄准往届主办国的 “后奥运低谷期”，通过合作获取其剩余资源（如场馆租赁和教练交流）。

7.2 赛事和运动项目数量的 “双刃剑效应”

事件数量（Num_Events）的系数为 0.575*（hurdle 模型），这表明增加赛事数量有助于提升获得奖牌的机会。然而，运动项目数量（Num_Sports）的系数仅为 0.487*（hurdle 模型），这说明过度多样化可能会分散资源。

政策启示：各国奥委会需要平衡 “广度与深度”。

小国：选择 3-5 项潜力大的运动项目，以避免多条战线作战。

· 大国：利用多项运动的优势，但需要建立“核心 - 外围”梯队（例如，以田径为核心，现代五项为补充）。

8 敏感性分析

使用 hurdle 模型时，第一阶段需要一个二元分类器来对哪些国家至少能获得一枚奖牌进行分类。我们使用了逻辑特回归分类器。因此，我们将对二元分类器的选择进行敏感性分析，以探究二元分类器的选择是否会影响 hurdle 模型对奖牌数量的可解释性，进而影响其预测性能。我们使用随机森林分类器、决策树和逻辑回归来替代 hurdle 模型中的逻辑特回归分类器，将输出概率作为 hurdle 模型第一阶段的结果，对其进行回归，并以逻辑特回归分类器为基准，比较原始模型中各协变量系数的变化。

Variables	Random Forest Classifier	Decision Tree	Logistic Regression
Host country in 4 years	0.052	0.022	-0.057
Host country t	-0.011	0.025	-0.088
Host country 4 years ago	0.062	-0.013	0.565
Athletes [0,10]	-0.122	0.051	-0.041
Athletes [10,50]	0.011	0.052	0.251
Athletes [50,150]	0.062	-0.045	0.051
150 athletes and more	0.032	0.000	0.152
Medals_PCA(t-4)	-0.052	0.052	0.142
RCA	0.012	0.069	-0.098
Medals_PCA(t-4)	0.012	-0.052	-0.095
Num_Events	0.012	0.021	0.054
Num_sports	0.041	0.065	0.013
NAE	-0.032	0.054	-0.064
$g_{i,t}$	0.055	-0.048	0.052
σ_u^2	-0.011	0.054	-0.098
Observations total	0.072	-0.067	-0.052
Observations noncensored	-0.065	0.002	0.082
	0.025	0.051	-0.054

从表中可以看出，所有协变量系数与解释变量之间的误差均小于 10%，这表明我们所选的分类器模型对 hurdle 模型的性能没有显著影响，且我们的模型具有较强的稳健性。

9 模型评估

9.1 优势

· Hurdle 模型和 Topit 模型的可解释性与性能都很出色，而非简单的机器学习算法。

在使用贝叶斯变点检测之前，首先对数据进行预处理，以反映奖牌的重要性和动态自我强化机制。

在解释显著的辅导效果时, 使用两阶段最小二乘法 (2SLS) 可以消除变量之间的内生性。

9.2 局限性

由于研究对象的局限性, 该模型未纳入经济和人文等因素的影响, 这可能会导致误差。

参考文献

- [1] 德博舍 (De Bosscher)、德克诺普 (de Knop)、范博滕堡 (van Bottenburg)、希布利 (Shibli) (2006)。《分析促成国际体育成功的体育政策因素的概念框架》。《欧洲体育管理季刊》, 6 (2), 185-215。
- [2] 施特赖歇尔, T., 施密特, S. L., 施赖尔, D., & 托格勒, B. (2020)。预期情感与对大型公共项目的支持: 举办奥运会。《技术预测与社会变革》, 158, 120158。
- [3] 巴尔, D. W. (1972)。奥运会比赛: 国家成功的结构性关联。《国际比较社会学杂志》, 13 (2), 186-200。
- [4] 班布里奇, M. (1998)。体育竞赛中的结果不确定性: 1896-1996 年奥运会。《应用经济学通讯》, 5 (3), 161-164。
- [5] 康登, E. M.、戈尔登, B. L. 和瓦西尔, E. A. (1999)。利用神经网络预测各国在夏季奥运会上的成功。《计算机与运筹学》, 26 (13), 1243-1265。
- [6] 库珀, G. H., & 斯特肯, E. (2001)。1896 年以来的奥运会参与情况与表现。SSRN 电子期刊。<https://doi.org/10.2139/ssrn.274295>
- [7] 吕汉 - 克 (Lui, H.-K.) 和孙伟 (Suen, W.) (2008)。《男性、金钱与奖牌: 奥运会的计量经济学分析》。《太平洋经济评论》, 13 (1), 1-16。
- [8] 利兹, E. M., & 利兹, M. A. (2012)。金、银、铜牌: 确定各国在夏季奥运会男女项目中的成功。《国民经济与统计年鉴》, 232 (3), 279-292。
- [9] 布莱 - 莫里塞特, P., 布歇, N., 及福廷, B. (2017)。公共体育投资对奥运奖牌的影响。《经济评论》, 68 (4), 623-642。
- [10] 格罗尔 (A. Groll)、莱伊 (C. Ley)、绍贝格尔 (G. Schauburger) 和范·埃特费尔德 (H. van Eetvelde) (2019)。一种混合随机森林模型用于预测国际赛事中的足球比赛结果。《体育定量分析期刊》, 15 (4), 271-287。
- [11] 莱斯曼、S.、宋、M.C. 和约翰逊、J.E. (2010)。预测竞争性事件的替代方法: 在赛马 betting 市场中的应用。《国际预测期刊》, 26 (3), 518-536。
- [12] 布莱曼, L. (2001)。随机森林。《机器学习》, 45 (1), 5-32。

[13] 陈天奇、Guestrin, C. (2016). XGBoost: 一个可扩展的树提升系统。见《第 22 届 ACM SIGKDD 国际知识发现与数据挖掘会议论文集》(第 785-794 页)。ACM。

<https://doi.org/10.1145/2939672.2939785>

[14] 查 (Tcha)、珀欣 (Pershin) (2003)。《重新审视夏季奥运会表现与显性比较优势》。《体育经济学杂志》，4 (3)，216-239。

[15] 福雷斯特 (D. Forrest)、麦克海尔 (I. G. McHale)、桑斯 (I. Sanz) 和特娜 (I. D. Tena) (2015 年)。《夏季奥运会各国奖牌总数的决定因素：按运动项目分类的分析》。收录于《竞技体育经济学》。爱德华·埃尔加出版社。

[16] 雷维拉客, J. (2021)。奥运会成功的 (非) 决定因素。《体育经济学杂志》，22 (7)，152700252199283。

[17] 塞莱斯 (Scelles)、安德烈夫 (Andreff)、博纳尔 (Bonnal)、安德烈夫 (Andreff) 和法瓦尔 (Favard) (2020)。重新思考夏季奥运会各国奖牌总数预测。《社会科学季刊》，101 (2)，697-711。

[18] 施特赖歇尔, T., 施密特, S. L., 施赖尔, D. 及托格勒, B. (2020)。预期情感与对大型公共项目的支持：举办奥运会。《技术预测与社会变革》，158，120158。

[19] 塞莱斯 (N. Scelles)、安德烈夫 (W. Andreff)、博纳尔 (L. Bonnal)、安德烈夫 (M. Andreff)、法瓦尔 (P. Favard) (2020)。重新思考夏季奥运会各国奖牌总数预测。《社会科学季刊》，101 (2)。