

基于回归和机器学习的奥运奖牌预测模型

摘要

在奥林匹克运动中，准确预测奖牌结果并了解推动国家表现的因素，对于有效的战略规划至关重要。基于给定的数据集，我们开发了多个数学模型来预测奖牌数量，确定了可能赢得首枚奖牌的国家，评估了特定运动项目的战略重要性，量化了金牌教练的影响力，并分析了主办国的溢出效应。研究结果包括：

奖牌预测：我们开发了一种多元线性回归 - 前馈神经网络 Bootstrap 集成区间模型，该模型纳入了主场优势、运动员储备、历史势头和竞争指数等特征。模型预测，美国将在 2028 年洛杉矶奥运会上占据主导地位，预计总共获得 143 枚奖牌，其次是中国，获得 76 枚。此外，模型显示美国和德国的奖牌数可能会有所提升，而中国和英国的奖牌数可能会下降。

首次获得奖牌者：我们开发了一种混合逻辑回归 - 随机森林模型来预测首次获得奖牌者。分析的关键特征包括参加的项目数量、运动员参赛经验和项目竞争强度。有三个国家 —— 安哥拉、萨尔瓦多和巴布亚新几内亚 —— 被确定为最有可能赢得首枚奥运奖牌的国家，其概率分别为 88.09%（逻辑回归）和 94.12%（随机森林）。蒙特卡洛模拟进一步验证了这一预测，95% 置信区间为 1.00-8.00。

战略性体育项目优先级排序：奥林匹克运动战略重要性评估模型（SIAMOS）用于评估赛事特征（数量、多样性）与国家奖牌潜力之间的关系。通过主成分分析法对关键指标 —— 国家奖牌占比、全球竞争影响力、长期成绩稳定性和运动员项目分布进行了加权。结果显示，游泳（美国， $IS = 39.8$ ）和跳水（中国， $IS = 33.1$ ）是影响力最高的项目。东道主可以通过聚焦那些具有良好历史表现和竞争优势的运动项目，来优化奖牌成果。

教练影响力分析：断点回归量化了杰出教练的影响力，包括景山惠子（中国，花样游泳）、戴夫·布雷斯福德（英国，自行车）以及贝拉·卡罗伊和玛尔塔·卡罗伊（美国，体操），他们执教后与执教前的奖牌数比率中位数为 1.7。

优秀教练效应应用：波兰（田径、皮划艇静水、帆船）、尼日利亚（足球）和印度（羽毛球、举重、摔跤）被确定为精英教练潜力巨大的国家。调整后的回归系数和奖牌权重 —— 金牌（0.9）、银牌（0.6）、铜牌（0.4）、无奖牌（0.1）—— 凸显了精英教练如何能提升奖牌前景和加权分数。

宿主溢出效应：对数据的进一步探索表明，“宿主助推”显著提高了邻国的奖牌率。

关键词：奥运奖牌预测；奥运项目战略重要性评估模型；逻辑回归 - 随机森林；多元线性回归 - 前馈神经网络

目录

1 引言

12 Rtnn fh r. . . 333

1.1 背景... ..

1.3 我们的工作... .. 4

2 假设与合理性说明 4

3 符号 5

4 数据预处理 5

55

4.2 数据探索

5 具有东道主效应的多元线性回归 - 前馈神经网络 Bootstrap 集成区间预测模型 6

5. 模型选择原因 6

下

... 6

9

5.4 不确定性与评估分析 10

6 首次获得奖牌国家的逻辑回归和随机森林预测模型 11

6.2 特征工程.....

6.3 首次获得奖牌国家的条件分析 12 rion n iio 6.5 赔率估计..... ...14

7 奥林匹克运动项目战略重要性评估模型 (SIAMOS) 15

7.1 模型开发与评估框架.....15 7.2 结果 1: 赛事与奖牌数量的关系.....16 7.3

结果 2: 各国特定运动项目的重要性.....16 7.4 结果 3: 东道主赛事选择对奖牌结果的影响

.17

8 优秀教练的贡献 18

&. Dinin o Gira Coch..

8.2 数据处理框架..... ..18

9 “优秀教练” 效应的实际应用 8.3 基于断点回归模型的系数计算 18 84 案例研究分析 (聚

焦三项关键运动)1 22

22

9.2 结果 22

10 其他见解: 东道主国家对邻国奖牌率的溢出效应

222223

国家

10.1 分析与结果..... ..

10.2 各国奥委会的战略建议.....

232425

11 敏感性分析

12 优势与劣势

参考文献

1 引言

1.1 背景

2024 年巴黎奥运会落下帷幕, 亮点颇多, 其中美国以 126 枚奖牌位居奖牌榜榜首, 且与中国并列金牌榜第一, 两国各获 40 枚金牌。

随着全球目光转向 2028 年洛杉矶奥运会, 这座城市充满活力的能量和文化多样性为这场历史性的盛会奠定了基础。

通过分析历史数据和设计预测模型, 我们旨在预测 2028 年奥运会的奖牌榜。东道主美国有可能巩固其主导地位。与此同时, 那些尚未获得过奥运奖牌的国家将努力取得首胜, 创下历史性的里程碑。

此外, 优秀教练的影响和战略性投资可能会显著改变结果, 为世界各国的奖牌前景和成绩优化提供宝贵的见解。

1.2 问题重述

基于背景分析, 核心任务如下:

问题 1. 开发一个各国奥运奖牌数预测模型。该模型应包含不确定性估计, 评估预测准确性, 并提供全面的性能指标。

任务 1.1: 使用该模型预测 2028 年洛杉矶夏季奥运会的奖牌榜。为所有结果提供预测区间。此外, 找出与 2024 年的成绩相比, 最有可能取得进步以及存在表现不佳风险的国家。

任务 1.2 确定尚未获得过奥运奖牌的国家, 并预测其中有多少国家可能在即将到来的奥运会上获得首枚奖牌。估算各国赢得首枚奥运奖牌的概率。

任务 1.3 将赛事编号和类型整合到模型中, 以分析它们与各国奖牌数量的关系。确定特定国家有影响力的运动项目、其重要性以及东道主赛事选择对结果的影响。


问题 2. 与运动员不同, 教练可以自由地在各国之间流动, 这可能产生显著的 “金牌教练” 效应。

任务 2.1 分析数据, 寻找可能归因于杰出教练影响的变化证据。量化这种 “伟大教练” 效应对奖牌数量的贡献。

任务 2.2 选择三个国家, 并确定它们应该投资招募 “优秀教练” 的体育项目。评估此类战略性教练投资对奖牌表现的潜在影响。

问题 3. 确定该模型揭示的有关奥运会奖牌数量的其他原创见解。根据这些发现, 向各国奥委会提供可采取的建议。

1.3 我们的工作



2 假设与合理性说明

为简化这一问题，我们做出以下基本假设，每一项假设都有充分的理由。

- 分析和模型完全基于 2016 年、2020 年和 2024 年奥运会提供的数据集。这三届最新的奥运会提供了关于表现趋势的最新且相关的数据，确保分析基于具有代表性和适用性的信息。
- 新参赛者在首次参加奥运会时的表现与那些未来不会再参加奥运会的运动员相当。奥运会首秀和退役有相似之处，两者都涉及缺乏经验或职业生涯结束等挑战，这确保了运动员参赛的稳定性。
- 俄罗斯和白俄罗斯被排除在 2028 年的奖牌榜之外。俄罗斯和白俄罗斯的运动员在 2024 年奥运会上没有持本国国旗参赛，这表明他们在 2028 年可能会面临同样的限制。
- 多元回归模型和回归断点模型中的扰动项均服从独立正态分布。误差服从均值为零、方差恒定的正态分布，这确保了统计检验的有效性和模型估计的可靠性。
- 假设 2028 年奥运会将在没有重大全球干扰的情况下举行。“这一假设预计不会出现重大全球干扰，确保 2028 年奥运会按计划进行，且分析与历史趋势一致。”

• 奖牌数量在运动项目层面进行分析，以此推断赛事层面的数据。我们汇总每个运动项目中各单项赛事的数据，以减少因赛事数量波动而产生的变异性。

3 符号说明

Symbols	Description	Unit
Y_1, Y_2	Predicted medal count (total medals or gold medals)	Medals
X_{Comp}	Competitiveness index	Dimensionless
X_{Ath}	Athlete pool	Dimensionless
X_{Host}	Host boost indicator	Binary
X_{Hist}	Historical momentum	Dimensionless
AWR	Award-winning rate	Percentage (%)
$\beta_0, \beta_1, \beta_2, \beta_3, \beta_4$	Regression coefficients	-
$\hat{P}_i$	Combined prediction for i -th instance	Medals
w_{MLR}, w_{NN}	Weights for MLR and NN models	-
PE_{MLR}^2, PE_{NN}^2	Mean squared prediction errors for MLR and NN	-

其中我们定义了主要参数，而这些参数的具体值将在后续给出。

4 数据预处理

4.1 数据清洗与调整

4.1.1 替换示例

表 1: 标准化奥运数据调整表

Category	Original Name	Standardized Name
Country Name Changes	Great Britain	United Kingdom
	Macedonia	North Macedonia
Language Substitutions	Cote d'Ivoire	Ivory Coast
	Cape Verde	Cabo Verde
Synonym Replacements	Independent Olympic Athletes	Individual Olympic Athletes ^{IOC2025}
	Refugee Olympic Team	Refugee Athletes ^{IOC2025}
NOC Consistency	ROC (Russia, 2020)	Russia
	RUS (Russia, pre-2020)	Russia
Sports Merging (2016)	Cycling (as a single Sport)	Split into Events
	Canoeing (as a single Sport)	Split into Events

4.2 数据探索

4.2.1 各国奖牌流向分析

图 1 展示了一个桑基图，突出显示了 2024 年奥运会期间的主要奖牌流动模式：

- 主导运动项目和国家：游泳和田径对美国、中国等国家的奖牌总数贡献显著。
- 战略重点：意大利和澳大利亚在小众运动方面表现出色，展现了量身定制的投资策略。




图 1: 展示各国与各项目奖牌流向的桑基图 (2024 年奥运会)

具有宿主效应的 5 重多元线性回归 - 前馈神经网络 Bootstrap 集成区间预测模型

5.1 模型选择原因 草乐园

预测奥运会奖牌分布是一项复杂的回归任务。多元线性回归（MLR）模型简单且可解释，对于线性关系有效，但在捕捉如东道主效应等非线性动态方面存在局限。为解决这一问题，前馈神经网络（FNN）模型在捕捉非线性模式和处理多样化数据集方面表现出色，且准确率较高。结合 MLR 的简单性与 FNN 的适应性，我们提出了一种混合方法以提高奖牌预测的效果。

5.2 模型构建与融合

5.2.1 多元线性回归模型构建

多元线性回归公式

该模型的公式如下:

$$Y_i = \beta_0 + \beta_1 X_{Comm} + \beta_2 X_{4th} + \beta_3 X_{Hset} + \beta_4 X_{Hiset} + \epsilon, (i = 1, 2)$$

特征选择

表 2: 关键预测特征及其数学定义

Feature		Interpretation	Mathematical Formula
Host (X_{Host})	Boost	Boost from hosting the Olympics, quantified as an additional medal improvement rate.	$X_{\text{Host}} = \begin{cases} 1 + \Delta_R, & \text{if Host Nation} \\ 0, & \text{Otherwise} \end{cases}, \quad \Delta_R = \text{median}\left(\frac{R_h - \bar{R}_n}{\bar{R}_n}\right)$ R_h : Host medal rate, $\bar{R}_n$: Non-host avg. rate.
Athlete (X_{Ath})	Pool	Reflects athlete participation trends, adjusted for Olympic debutants.	$X_{\text{Ath}} = \sum_{t=0}^2 N_{T-t}$ N_{T-t} : Number of athletes in the $(T - t)$ -th Olympic cycle.
Competitiveness Index (X_{Comp})		Captures nation-specific strength across sports, adjusted for temporal decay.	$X_{\text{Comp}} = \sum_{k=1}^K \left(\frac{m_k}{M_{\text{total}}} \cdot \sum_{t=1}^3 p_{k,t} \cdot e^{-0.2t} \right)$ m_k : Medals in sport k , $p_{k,t}$: Medals at $T - t$, M_{total} : Total medals.
Historical Momentum (X_{Hist})	Mo-	Weighted sum of past medals, with higher weights for recent performances.	$X_{\text{Hist}} = \sum_{t=1}^3 M_{T-t} \cdot e^{-0.2t}$ M_{T-t} : Total medals at $T - t$.

相关性分析

为了探究特征与目标变量之间的关系，我们计算了皮尔逊相关系数。




图 2: 相关矩阵 (X_{Comp} , X_{Ath} 和 X_{Hist})

如图 2 所示，获奖率与预测特征 X_{Comm} 、 X_{Ath} 和 X_{Hist} 存在显著相关性，相关系数分别为 0.92、0.86 和 1.00。这些数值凸显了竞争力、运动员储备规模和历史势头在预测一个国家的获奖表现方面的密切关系。




图 3：东道主优势

由于东道主效应是一个离散变量，而其他特征是连续变化的，因此东道主效应与其他三个指标的线性相关性较弱。因此，有必要单独分析东道主效应。如图 3 所示，一个国家在其主办年份的奖牌总数显著增加，这凸显了 “东道主效应” 是一个关键特征。

5.2.2 前馈神经网络 – 模型构建



图 4：前馈神经网络模型构建

从图 4 可以看出，该模型采用典型的前馈神经网络（FNN）结构，包括一个输入层、两个带有 ReLU 激活函数的隐藏层以及一个带有线性激活函数的输出层。原始数据集被划分为训练集和测试集，其中训练集又进一步分为训练数据和验证数据（占训练集的 20%）。模型使用 Adam 优化器进行训练，学习率为 0.01。训练过程中会跟踪验证损失，以评估模型的性能。

5.2.3 预测的加权融合



图 5：加权融合构建

为提高奖牌数量预测的准确性和稳健性，我们采用加权融合方法来结合多元线性回归（MLR）和前馈神经网络（FNN）模型的输出结果。

首先，计算两个模型的均方预测误差（MSE）：

$$PE_{MLR}^2 = \frac{1}{N} \sum_{i=1}^N (R_i - P_{MLR,i})^2, PE_{NN}^2 = \frac{1}{N} \sum_{i=1}^N (R_i - P_{NN,i})^2$$

每个模型的权重是根据其相对误差得出的：

$$w_{MLR} = \frac{PE_{NN}^2}{PE_{MLR}^2 + PE_{NN}^2} \approx 0.6, \quad w_{NN} = \frac{PE_{MLR}^2}{PE_{MLR}^2 + PE_{NN}^2} \approx 0.4$$

最后，观测值 i 的组合预测计算如下：

$$\hat{P}_i = w_{MLR} \cdot P_{MLR,i} + w_{NN} \cdot P_{NN,i}$$

通过分析预测误差可以清楚地看出，MLP 模型的误差较大，而 FNN 模型存在过拟合风险。组合的 MLP-NN 模型解决了这些问题，提高了准确性和稳健性，从而实现可靠的预测。

5.3 预测结果与见解


NOC	Total Medals				Gold Medals				Confidence Intervals (95%)			
	Pred.	Δ	Rank	Δ	Pred.	Δ	Rank	Δ	Total Lower	Total Upper	Gold Lower	Gold Upper
United States	143	↑17	1	-	59	↑19	1	-	110	192	50	68
China	76	↓15	2	-	32	↓8	2	↓1	61	94	27	37
United Kingdom	62	↓3	3	-	21	↑7	3	↑4	56	85	17	25
France	60	↓4	4	-	16	-	5	-	50	73	13	19
Australia	54	↑1	5	-	21	↑3	3	↑1	49	70	17	25
Japan	43	↓2	6	-	16	↓4	5	↓2	35	51	13	19
Italy	40	-	7	-	12	-	8	↑1	34	48	10	14
Germany	36	↑3	8	↑1	12	-	8	↑2	31	44	10	14
Netherlands	35	↑1	9	↓1	15	-	7	↓1	31	43	12	18
Canada	30	↑3	10	↑1	10	↑1	10	↑2	27	37	8	12

表 3：2024 年奥运会奖牌预测（含排名、变化及置信区间）


有望进步的国家：美国（+17 枚奖牌）和加拿大（+3 枚奖牌）呈现上升趋势，这可能得益于对运动员培养的投入增加以及执教策略的优化。

可能奖牌数下降的国家：法国（60 枚奖牌，而 2024 年为 64 枚）在举办奥运会后可能会出现奖牌数下降，而中国（76 枚奖牌，2024 年为 91 枚）则面临挑战，因为其优势项目“举重”将不再举办。

主要不确定性：美国的奖牌区间凸显了团队运动中的可变性，而像斯洛文尼亚这样的小国（1 枚金牌，置信区间：0-2 枚）由于依赖个体运动员，表现出更大的波动性。



(a) 奖牌比例 (对数)



(h) 奖牌数量 (绝对值)

图 6: 奥运会奖牌表现对比可视化

如图 6 所示, 热力图利用我们的预测结果描绘了 2016 年至 2028 年间排名前十的国家的奖牌数变化情况。颜色深浅表示奖牌总数, 深蓝色代表更高的奖牌数。

主要趋势包括美国和中国始终在奖牌榜上占据主导地位, 这反映出两国强大的体育项目实力。东道主往往能大幅提升奖牌数量。日本和荷兰等新兴国家呈现上升趋势, 这表明它们在体育方面进行了战略性投资。相比之下, 意大利、俄罗斯和韩国等国家的表现则时好时坏。英国、意大利和德国等西方国家保持着稳定的奖牌数量。

5.4.1 不确定性评估分析

采用自举法 (500 次迭代) 来量化总奖牌数和金牌数预测的不确定性。该过程包括: 最终的 95% 预测区间是从汇总结果中得出的:

$$\text{Lower Bound} = \text{Percentile}(2.5), \text{Upper Bound} = \text{Percentile}(97.5)$$

例如, 美国的总奖牌区间 [116, 193] 反映出较高的不确定性, 这是由于团队项目表现的波动性所致, 而中国更窄的金牌区间 [27, 37] (预测为 32 枚) 则表明其在跳水和乒乓球项目上的优势更为稳定。

5.4.2 预测评估分析

从表 4 可以看出, 所选的模型变量既具有显著性, 又具有解释力:

- Host Boost (X_{Host}): 系数 13.10 ($p < 0.001$)表明, 主办奥运会对奖牌数量有强烈的积极影响, 尽管由于国家间的差异, 标准误差较高 (2.88)。

表 4: 多元线性模型的回归系数

Variable	Coefficient	Standard Error	t-Statistic	P-Value(P> t)
Host Boost (X_{Host})	13.10	2.88	4.55	<0.001
Athlete Pool (X_{Ath})	0.004	0.003	1.33	0.188
Competitiveness Index (X_{Comp})	2.18	0.71	3.06	0.003
Historical Momentum (X_{Hist})	0.59	0.09	6.42	<0.001

- 竞争力指数(X_{Comp})和历史势头(X_{Hist}): 两者都有显著的积极影响, 系数分别为 2.18 和 0.59 ($p < 0.01$)。历史势头的 t 值最高 (6.42), 标准误差最低 (0.09), 凸显了其对奖牌表现的强大影响。
- 运动员库(X_{Ath}): 系数 (0.004) 不具有统计学显著性($p = 0.188$), 这表明仅靠运动员库规模无法充分解释奖牌结果。

总体而言, 该模型有效地捕捉到了奖牌分布的主要驱动因素, 其中主办国地位、竞争力和历史势头做出了显著贡献。

表 5: 回归分析的关键指标和结果

Metric	Formula	Result
Mean Squared Error (MSE)	$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$	7.115
Root Mean Squared Error (RMSE)	$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$	2.667
Mean Absolute Percentage Error (MAPE)	$MAPE = \frac{100}{N} \sum_{i=1}^N \left \frac{y_i - \hat{y}_i}{y_i} \right $	51.099%

表 5 中的指标表明, 该模型对绝对误差的控制较好, 均方根误差 (RMSE) 为 2.667 (平均偏差为 2.7 枚奖牌)。然而, 51.1% 的高平均绝对百分比误差 (MAPE) 显示, 在准确预测奖牌数较少的国家时存在挑战, 这表明仍有改进空间。

6 首次获得奖牌国家的逻辑回归和随机森林预测模型

6.1 模型选择的原因

预测各国赢得首枚奥运奖牌的概率是一项复杂的分类任务。逻辑回归 (LR) 是一种广泛使用的模型, 其优势在于简单性和

可解释性，在预测变量和结果之间的关系为线性时，能有效地估计概率。然而，它在处理非线性模式和复杂特征交互时存在困难，而这些在奥运数据中经常出现，例如历史变异性或区域效应。

为了克服这些局限性，随机森林（RF）提供了一种可靠的替代方案。作为一种集成学习方法，随机森林能够捕捉非线性关系和复杂的相互作用，同时对特征重要性进行排序，使其适用于各种数据集。然而，随机森林可能会过拟合，且缺乏逻辑回归（LR）的透明度。

为了充分利用这两种模型的优势，我们采用了一种混合方法，将逻辑回归（LR）的可解释性与随机森林（RF）的灵活性相结合。这在简单性和稳健性之间取得了平衡，能够更准确、更全面地预测哪些国家将赢得首枚奥运奖牌。

6.2 特征工程

为了确定从未获得过奖牌的国家，我们处理了 `summerOly_athletes.csv` 表格，以识别获得过奖牌的运动员，然后筛选出他们在比赛中所代表的国家。从所有国家的列表中，我们排除了那些至少获得过一枚奖牌的国家。

这里的核心原则是通过只计算独特的国家来简化流程，因此重复项只被计算一次。

这会生成一份从未获得过奖牌的国家名单，以及相关特征：

- 参与的项目数量。统计这些国家参与的项目总数。
- 运动员参与体验。计算运动员参与的平均场次。

项目竞争强度。计算公式： $\frac{m}{i + m}$ ，其中数值越接近 1，表示竞争越激烈。

6.3 首次获得奖牌国家的条件分析

我们计算了每届奥运会中首次获得奖牌的国家数量（例如，2020 年东京奥运会有 5 个国家，2016 年里约奥运会有 3 个国家），并根据各项特征分析了这些国家的分布情况，包括均值、方差和趋势等统计数据。




图 7：均值和方差

图 8：首次获得奖牌的国家数量

如图 7 和图 8 所示，不同奥运年份中首次获得奖牌的国家数量存在显著波动。例如，在 2020 年东京奥运会上，有 5 个国家赢得了其历史上的首枚奖牌，而 2016 年仅有 3 个这样的国家。

6.4 模型构建与预测结果

我们使用了两种预测模型——逻辑回归和随机森林——来估计各国在下次奥运会上获得首枚奖牌的可能性。

6.4.1 逻辑回归模型

逻辑回归模型根据关键特征预测一个国家首次获得奖牌的概率。该模型如下：

$$P(Target = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 \cdot Experience + \beta_2 \cdot Programs\ Attended + \beta_3 \cdot Competition\ Intensity)}}$$

其中， $P(Target = 1|X)$ 是首次获得奖牌的概率， β_0 、 β_1 、 β_2 、 β_3 是每个特征（经验、参加的项目和比赛强度）的模型系数。

6.4.2 随机森林模型

随机森林模型会聚合多个决策树的预测结果。最终预测是所有树预测结果的平均值：

$$\hat{y} = \frac{1}{N} \sum_{i=1}^N \hat{y}_i$$

其中， $\hat{y}$ 是预测概率，N 是树的数量， $\hat{y}_i$ 是第 i 棵树的预测结果。

6.4.3 预测结果

两个模型的预测结果如下：

• 逻辑回归预测：安哥拉、萨尔瓦多、巴布亚新几内亚

随机森林预测：安哥拉

然后，我们利用泊松二项分布结合蒙特卡洛模拟，来估计可能首次获得奥运奖牌的国家的预期数量及其置信区间。图 9 所示的模拟结果表明，当首次获得奖牌的国家数量恰好为 3 个时，这一概率最高。




图 9：首次获得奖牌的国家蒙特卡洛模拟

基于这些发现，我们得出结论：有 3 个国家最有可能在下次奥运会上赢得首枚奥运奖牌。模拟结果与我们的预测非常吻合，证实了该模型估计的稳健性。蒙特卡洛模拟不仅验证了预期结果，还为可能在下次奥运会上赢得首枚奖牌的国家数量提供了一个概率范围元

这些预测反映了模型的输出概率，安哥拉在两个模型中都是常见的预测结果，这表明该国很有可能获得首枚奖牌。

6.5 估计赔率

预测哪些国家将在下次奥运会上获得首枚奖牌的概率，是根据它们各自的交叉验证准确率来估算的。下表总结了每个模型的估算概率：

Model	Cross-Validation Accuracy	Estimated Odds (Correctness)
Logistic Regression	88.09%	4:1 (80% chance)
Random Forest	94.12%	16:1 (94% chance)

表 6：预测首次获得奖牌国家的估计概率

7 奥林匹克运动项目战略重要性评估模型（SIAMOS）

为了衡量特定运动项目 s 对特定国家 ce 的战略重要性，我们基于四个关键指标建立了一个全面的评估框架。

7.1 模型开发与评估框架

7.1.1 体育项目重要性评价指标说明

在奥运会表现背景下，用于评估一项运动重要性的四个关键指标是：

- NMP（国家奖牌占比）：一项运动为一个国家的总奖牌数贡献的奖牌比例。
- GCP（全球竞争存在感）：一个国家在某项运动中的竞争力相对于全球表现而言 Bernard2004。
- LAS（长期成绩稳定性）：过去五届奥运会中某项运动表现的稳定性。
- ASD（运动员运动项目分布）：分配到特定运动项目的运动员数量占运动员总数的比例。

每个指标都采用 Min-Max 标准化方法进行标准化，以确保国家间的可比性。一种结合主成分分析（PCA）和专家验证的混合加权方案，分别赋予 40%、30%、20% 和 10% 的权重。这反映了每个指标在评估一项运动的战略意义时的相对重要性。

表 7：评估指标、权重及公式

Indicator (Weight)	Formula	Standardization
NMP (40%)	$\frac{Medals_{c,s}}{Total\ Medals_c} \times 100\%$	Min-Max normalization
GCP (30%)	$\frac{Medals_{c,s}}{Global\ Medals_s} \times 100\%$	Min-Max normalization
LAS (20%)	$1 - \frac{\sigma}{\mu}$	Min-Max normalization
ASD (10%)	$\frac{Athletes_{c,s}}{Total\ Athletes_c} \times 100\%$	Min-Max normalization

7.1.2 模型构建

SIAMOS 模型整合了这四个指标，以计算每个国家 C' 中每项运动 s 的重要性得分 ($IS_{c,s}$)

$$IS_{c,s} = \alpha \cdot NMP_{norm} + \beta \cdot GCP_{norm} + \gamma \cdot LAS_{norm} + \delta \cdot ASD_{norm}$$

其中 $\alpha:\beta:\gamma:\delta=4:3:2:1$ （40%、30%、20%、10%）。

7.2 结果 1：赛事与奖牌数量的关系




图 10：相关性分析：（a）显示了赛事数量的影响，（b）强调了运动项目对奖牌数量的影响。

结论：如图 10 所示，赛事数量与参赛国家的奖牌数呈正相关。同样，赛事的多样性也与奖牌数呈正相关。这些发现表明，赛事的数量和种类都对一个国家的奖牌获取潜力有积极影响。

7.3 结果 2：各国特定运动项目的重要性

7.3.1 计算得分

以下表格展示了选定国家和运动项目的计算得出的重要性得分：

表 8：部分国家和运动项目的重要性得分

Country	Sport	Importance Score (<i>IS</i>)	Ranking
China	Diving	33.1	1
China	Table Tennis	29.6	2
USA	Swimming	39.8	1
USA	Basketball	27.8	2
Korea	Archery	37.4	1
Korea	Badminton	31.8	2
Japan	Judo	36.5	1
Japan	Gymnastics	30.2	2
Australia	Swimming	38.6	1
Australia	Cycling	29.7	2

7.3.2 见解与建议

- 中国：跳水项目($IS = 33.1$)和乒乓球项目($IS = 29.6$)占据主导地位，这体现了其历史优势。
- 美国：游泳($IS = 39.8$)和篮球($IS = 27.8$)仍然是优先项目。

• 韩国：射箭 ($IS = 37.4$) 和羽毛球 ($IS = 31.8$) 凸显了重点投资。

其他：日本：柔道 ($IS = 36.5$)、体操 ($IS = 30.2$)；澳大利亚：游泳 ($IS = 38.6$)、自行车 ($IS = 29.7$)

这些见解有助于制定战略规划，以最大限度地提高未来奥运会的奖牌潜力。

7.4 结果 3：东道主赛事选择对奖牌结果的影响

为了评估东道主的项目选择对奖牌结果的影响，我们使用了全球竞争比例 (GCP) 指标，该指标量化了一个国家在某项运动中的竞争力相对于全球表现的情况 Bernard2004。表 9 提供了选定国家和运动项目的 GCP 得分。

表 9：部分国家和运动项目的全球竞争比例 (GCP) 得分

Country	Swimming	Track and Field	Shooting	Taekwondo	Cycling
USA	0.3214	0.2841	0.0962	0.0523	0.1085
CHN	0.1263	0.1435	0.2782	0.2648	0.0712
JPN	0.0823	0.1274	0.0896	0.2167	0.1354
AUS	0.3645	0.0912	0.0438	0.0417	0.1824
KOR	0.0512	0.0374	0.0856	0.3084	0.0685

7.4.1 东道主赛事选择的影响

通过研究东道主对赛事的选择，我们发现了两个关键影响：

1. 优势项目的强化：东道主往往会加入其最擅长的项目，以最大化奖牌数量。例如：

美国在 1996 年亚特兰大奥运会期间增加了游泳和田径项目，获得了多枚金牌。

中国在 2008 年北京奥运会上增设了更多射击项目，这大大提高了他们在此项目上的奖牌总数。

2. 特定赛事竞争力的提升：主办赛事在筹备、场地熟悉度和公众支持方面具有优势，这使得主办国在传统上较弱的赛事中更具竞争力。例如：

澳大利亚利用其 2000 年的东道主身份，在自行车和田径项目中取得了出人意料的奖牌。

韩国利用 1988 年汉城奥运会确立了在跆拳道项目上的主导地位，而跆拳道在当时是一项新引入的运动。

这些研究结果强调了东道主国家赛事选择在塑造奖牌结果方面的战略作用，并凸显了未来东道主国家优化其策略的机会。

8 伟大教练的贡献

8.1 优秀教练的定义

伟大教练 (GC) 被定义为这样一种教练专业人士：其受聘会使目标奥运项目的奖牌获得量出现统计上显著的增长 ($p < 0.05$)，这一增长通过其受聘前后的表现来衡量。伟大教练的标准包括：

直接影响：在第一个奥运周期内， $\geq 15\%$ 奖牌数量增长，较历史表现有所提升。

持续改进：至少在接下来的两届奥运会中保持 $Maintaining \geq 80\%$ 的最佳表现。

运动层面的考量：

当一名教练入职时，无论是作为体育总教练还是专项教练，他们都会通过协作和与运动员的互动，对同一运动项目中的其他赛事产生影响。

· 每届奥运会中，每项运动的赛事数量可能有所不同，因此考虑运动项目层面有助于减轻这一因素带来的不稳定性。

仅关注单个事件数据可能会导致样本量过小，从而增加随机性的可能性，并可能使结论产生偏差。

8.2 数据处理框架

8.2.1 奖牌权重体系

勋章权重分配：已定义权重（不含 $Medal = 0.1$ 、 $Bronze = 0.4$ 、 $Silver = 0.6$ 、 $Gold = 0.9$ ）用于量化性能质量

国家表现指标：按国家 - 运动 - 年份三元组计算加权分数：

$$\Phi_{c,s,y} = \sum_{i=1}^4 w_i \cdot N_i, w \in \{0.1, 0.4, 0.6, 0.9\}$$

其中 N_i 统计奖牌类型 i 的出现次数

8.2.2 奖牌数据标准化

- 二元奖牌编码：将奖牌结果转换为布尔指标（1 = 获得奖牌，0 = 其他情况），用于跨项目汇总
- 体育分类统一：使用国际奥委会 (IOC) 命名法，统一等效项目（如花样游泳 / 同步游泳）的历史记录

8.3 基于断点回归模型的系数计算

为了分析优秀教练对奖牌数量的影响，我们使用以下模型：

$$MedalCounts = \beta_0 + \beta_1 \cdot Year + \beta_2 \cdot is_great_coach + \beta_3 \cdot (is_great_coach \times Year) + \epsilon$$

分析的关键步骤：

1. 时间段划分：根据执教情况将奥运会数据分为三个时期：

• 执教前：教练接手前的三届奥运会。

执教期：这位伟大教练积极执教的时期。

教练离职后时期：教练离开后的时期。

2. 指标计算：

• 奖牌得分：按国家和项目取平均值。

• 总奖牌数：按国家和项目汇总。

3. 模型拟合与稳健性检验：使用断点回归模型评估金牌教练对奖牌数量的影响。检验交互项系数 (β_3) 的显著性，以确定教练效应是否随年份变化。然后，将因变量替换为 “奖牌得分” 并重新拟合模型。最后，比较不同国家和项目的结果。

8.4 案例研究分析（聚焦三项重点运动）

8.4.1 引言：3 个代表性案例

为了分析 “伟大教练” 对奖牌数量的影响，我们分析了奖牌变化数据，并确定了三个符合该情况的代表性国家：

Country	Sport	Coach
China	Artistic Swimming	Keiko Kageyama
United Kingdom	Cycling	Dave Brailsford
United States	Women's Gymnastics	Béla and Marta Károlyi

表 10：国家、运动项目及对应教练

8.4.2 结果分析

为了量化优秀教练对奖牌数量的影响，我们使用以下公式计算了每位教练的贡献值(C_i):

$$C_i = \frac{\beta_i}{n_i}$$

其中：

• β_i ：教练对奖牌数量的直接影响（回归系数）。

D_i : 教练任期前后两届奥运会之间总奖牌数的加权平均差异。

通过分析奖牌数量的显著变化并参考相关数据，确定了 “伟大教练效应” 的三个典型案例：

1. 贝拉·卡罗利和玛尔塔·卡罗利（美国女子体操队）：回归系数(β_i) = 0.3。
2. 影山惠子（英国自行车队）：回归系数(β_i) = 6.9
3. 景山惠子（中国花样游泳）：回归系数(β_i) = 1.3

使用上述公式，为每位教练计算了贡献值(C_i):

- 贝拉·卡罗利和玛尔塔·卡罗利：贡献值(C_i) = $\frac{0.3}{0.1764} = 1.7$
- 影山惠子（英国自行车队）：贡献值 (C_i) = $\frac{6.9}{4.1778} = 1.7$
- 景山惠子（中国花样游泳）：贡献值(C_i) = $\frac{1.3}{0.7692} = 1.7$

结果表明，尽管回归系数(β_i)存在差异，但这些案例的调整贡献值均收敛于 1.7。这凸显了卓越教练对提升奖牌成绩具有一致且可衡量的影响，为在教练人才方面的战略投资提供了可操作的见解。




图 11: 英国说明文字




图 12: 美国说明文字




图 13: 中国的说明文字

如图 11、12 和 13 所示，围绕着一位金牌教练的任职情况对该项目的奖牌数量进行了分析。红线标记了分界线：左侧是教练任职前的奖牌数量，右侧是教练任职后直至其离开该国期间的奖牌数量。任职后的平均奖牌数显著超过任职前的数量，这体现了“金牌教练效应”。

8.4.3 国家和运动项目选择的原因

选择三个国家（中国、英国、美国）和三项运动（花样游泳、自行车、女子体操）构建了一个代表全球体育的框架。该框架着眼于政治体制和运动员类型方面的差异。

国家典型模式

中国：

- 自上而下的人才识别渠道
 - 体育 - 教育 - 政治一体化机构
 - 通过奖牌外交实现的文化软实力
- 英国：代表 28% 的发达国家所采用的技术官僚混合体系（例如德国、日本）。主要特征：
- 公私研发联盟（例如，英国体育的“边际收益”计划）
 - 以大学为基础的运动员发展生态系统
 - 训练优化中的精准分析

美国：是市场驱动的多元主义的典范，这种模式在 35% 的西方民主国家中占据主导地位（例如澳大利亚、加拿大）。其特点包括：

- 去中心化的大学体育基础设施
- 商业赞助驱动的融资模式
- 个人运动员品牌经济

运动类型学表征

- 花样游泳：
 - 类别：评分制团队运动（占奥运会项目的 22%）
 - 分析重点：集体同步指标、主观评分偏差
- 自行车运动：
 - 类别：技术密集型耐力运动（占奥运会项目的 18%）
 - 分析重点：设备研发投入回报率、空气动力学效率阈值
- 女子体操：
 - 类别：生物力学复杂技能型运动（占奥运会项目的 26%）
 - 分析重点：规则变更适应率、injury 风险管理

9 “伟大教练” 效应的实际应用

9.1 需要优秀教练的运动项目选择

9.1.1 数据利用

1. 汇总 2016 年和 2020 年的分数数据，计算每年的平均值和标准差。
2. 选择第 20 百分位，阈值为 0.15。
3. 检查得分接近 0.15 的分布中体育项目的占比，确保其与实际观察结果一致。

选择标准：

- 一项运动在 2016 年和 2020 年的得分都必须大于 0.15。
- 2024 年的得分必须低于 0.15。

9.2 结果

经过初步筛选，尼日利亚、波兰和印度被选为重点关注国家。根据上述标准，选出了需要引进金牌教练的运动项目。潜在需要金牌教练的运动项目最终名单包括：

- 波兰：田径、皮划艇静水、帆船
- 尼日利亚：足球
- 印度：羽毛球、举重、摔跤

9.2.1 结论验证：教练影响计算

根据第 2.1 节，确定教练对这项运动的贡献率为 $u = 1.7$ 。这意味着在引入教练后，2024 年的得分比引入教练前的得分增加了 ux 。通过比较结果，我们发现选定国家在这些运动项目中获得奖牌的可能性在引入教练后有所提高。

10 其他见解：主办国对邻国奖牌率的溢出效应

10.1 分析与结果

我们分析了 2016 年、2020 年和 2024 年奥运会上各国的奖牌率，重点关注了东道主邻国（陆上接壤国家）在奖牌率方面的差异。具体而言，我们将这些邻国在当届奥运会上的奖牌率与其在前两届奥运会上的平均奖牌率进行了比较。我们找出了奖牌率呈正向差异的国家，并将这些进步情况绘制成图。这些地图的结果清晰地展示了“东道主效应”。

不仅提高了东道主国家的奖牌率，还对邻国的奖牌率产生了积极影响。



图 14：法国周边的溢出效应



图 15：巴西周边的溢出效应



图 16：日本周边的溢出效应

图 17：溢出效应

我们的分析证实，“东道国效应” 会提高邻国的奖牌率。

10.2 对各国奥委会的战略建议

10.2基于阶段的适应性训练：

2. 第二阶段（比赛前 6 个月）：在官方场馆进行训练。

- 跨境训练集群：
 - 在主办城市 500 公里范围内为运动员设立联合训练中心。
 - 共享主办国的反兴奋剂实验室和康复设施。

11 敏感性分析

在任务 1.1 中，我们分析了四个关键特征：Host Boost (X_{Host})、Athlete Pool (X_{Ath})、Competitiveness Index (X_{Comp}) 和 Historical Momentum (X_{Hist})。由于 X_{Host} 是一个二元变量（0 或 1），在敏感性分析中，它被固定为 $X_{Host} = 1$ （主办场景）。其余特征在其初始值的基础上变化 $\pm 10\%$ ，以评估它们对模型预测的影响。

初始特征值和敏感度范围

每个特征的初始值和敏感度范围如下所列：

表 11：初始值与敏感度范围

Feature	Initial Value	Range (-10%)	Range (+10%)
Athlete Pool (X_{Ath})	719	647	791
Competitiveness Index (X_{Comp})	17.85	16.07	19.64
Historical Momentum (X_{Hist})	121	109	133

结果与观察




图 18: 历史势头对预测奖牌数的影响

图 19: 运动员对预测奖牌数的影响

图 20: 竞争力指数对预测奖牌数的影响

这三个因素特征都与预测的奖牌数呈正相关。回归线的斜率表明，随着每个因素的上升，奖牌数稳步增加。阴影区域表示预测中可能出现的波动，为模型的准确性和可靠性提供了见解。

12 优势与劣势

优势

· 综合特征集成（MLR-FNN）：MLR-FNN 模型结合了特征提取和关系学习来预测 2028 年奖牌榜。它涵盖了参赛人数、东道主效应、历史奖牌数和竞争力等因素，能提供具有置信区间的可靠预测，这些置信区间反映了现实情况。

· 平衡的可解释性与复杂性（LR-RF）：LR-RF 模型结合了逻辑回归清晰的结果与随机森林处理复杂关系和对因素进行排序的能力。这使其成为分析奥运数据的强大工具。

战略体育评估（SIAMOS）：SIAMOS 模型通过四个因素来衡量体育运动的重要性，分别是国家奖牌占比（NMP）、全球竞争占比（GCP）、长期成绩稳定性（LAS）和运动员项目分布（ASD）。该模型提供了有益的见解，有助于集中资源并提升奥运会表现。

· 教练影响的因果分析（RDD）：回归不连续性模型通过观察数据中的自然断点，并考虑跨国和时间变化来衡量“优秀教练效应”。它为如何在教练方面进行投资以改善奖牌结果提供了明确建议。

弱点

· 有限的功能范围：一些模型，如 MLR-FNN，没有包含东道国溢出效应等重要因素，这限制了分析。

主观设计选择：部分公式未经计算便被选用，这使得模型主观性更强，普适性可能更低。例如，模型假设新运动员的表现与不再参赛的运动员相同。这保证了运动员的数量和构成保持不变。

参考文献

- [1] 国际奥委会, 各国奥委会, <https://www.olympics.com/ioc/national-olympic-committees?os=&ref=app>, 访问日期: 2025 年 1 月 27 日。
- [2] 曼奇尼·西蒙娜和特里基 [名]。 “体育大型赛事期间基于用户偏好的旅游套餐优化选择”。《欧洲运筹学杂志》, 第 302 卷, 第 3 期, 2022 年 11 月, 第 819-830 页。
- [3] 伯纳德 (A. B.) 和布斯 (M. R.) (2004)。《谁赢得奥运会: 经济资源与奖牌总数》。《经济与统计评论》, 第 86 卷, 第 1 期, 第 413-417 页。 <https://doi.org/10.1162/003465304774201824>。
- [4] 杰伊·贝朗格、威廉·P·福克斯、王洁茂和杨子 (2017)。《数学建模竞赛 (MCM) 的规范写作》。高等教育出版社。
- [5] 奥运会。 (2024)。 “2024 年巴黎奥运会花样游泳: 中国队在集体自由自选项目中创下历史新高。” 取自 <https://www.olympics.com/zh/news/paris-2024-results-artistic-swimming-team-free-routine-wrap-up>。
- [6] Way We Do. (2024)。《边际收益策略: 英国自行车队的胜利之路》。取自 <https://www.waywedo.com/blog/marginal-gains-strategy/>。
- [7] 维基百科. (2024)。 “贝拉·卡罗利”。取自 https://en.wikipedia.org/wiki/B%C3%A9la_K%C3%A1rolyi。

人工智能使用报告

1. OpenAI ChatGPT (2023 年 11 月 5 日版本, ChatGPT-4o)

查询 1: <请提供关于美国女子体操以及贝拉·卡罗利和玛尔塔·卡罗利的报告的引用格式>

输出: <以下是关于贝拉·卡罗利的维基百科文章的引用格式: 贝拉·卡罗利。(2024 年 11 月 23 日)。见于《维基百科, 自由的百科全书》。取自https://en.wikipedia.org/wiki/Bella_Caroly这种格式包括文章标题、最后更新日期、来源以及供参考的 URL。>

2. OpenAI ChatGPT (2023 年 11 月 5 日版本, ChatGPT-4o)

问题 1: <请简要解释多元线性回归 (MLR) 和前馈神经网络 (FNN) 之间的异同>

输出: <多元线性回归 (MLR) 和前馈神经网络 (FNN) 都是监督学习方法, 旨在建模输入变量和输出变量之间的关系。它们支持多个输入变量, 并受益于归一化等预处理技术以提高性能。然而, MLR 是一种假设线性关系的统计模型, 通过系数提供可解释性, 而 FNN 是一种能够学习非线性和复杂模式的计算模型, 通常被视为 “黑箱”。MLR 更简单, 需要的数据点更少, 并且涉及直接的解析解, 而 FNN 更灵活但计算密集, 依赖反向传播等迭代优化方法。>



夜乐园 数